



Pontifícia Universidade Católica de São Paulo

PUC-SP

NOME DA UNIDADE CURRICULAR	Consultoria Especializada em Ciência de Dados 1	
CURSO	Ciência de Dados e Inteligência Artificial (Bacharelado)	
PERÍODO	6º	
Nº DE CRÉDITOS		
CARGA HORÁRIA	72 horas-aula / 60 horas-relógio, 4 h/a semanais às terças-feiras Distribuição: teórica 15, prática 30 e extensão 15 (horas-relógio).	
SEMESTRE / ANO	2º/2026	
PROFESSOR	Giovani Giulio Tristão Thibes Vieira	
FACULDADE	Faculdade de Estudos Interdisciplinares — PUC-SP	
DEPARTAMENTO		
A DISCIPLINA CONTEMPLA ATIVIDADES EXTENSIONISTAS	(X) Sim () Não	Horas extensionistas previstas: 15 h/a. Horas executadas pelos alunos em atividades externas: 15 h/a.
Em caso de resposta afirmativa, qual é a modalidade de horas extensionistas que a sua Disciplina Desenvolve?	(X) Projetos (X) Cursos e oficinas () Eventos () Prestação de Serviços	
Todos os alunos participarão das atividades extensionistas? (X) Sim () Não		A Atividade Extensionista é interdisciplinar? () Sim (X) Não Informe a disciplina: —
Ementa		
Seleção e avaliação de modelos de aprendizado de máquina. Abordagem de tópicos como validação, validação cruzada, busca exaustiva, curvas de validação e curvas de aprendizado. Desenvolvimento de ações extensionistas, por meio de projetos de diagnóstico, oficinas e palestras, com a criação de produtos voltados para o atendimento de necessidades do público e de organizações como escolas, bibliotecas e organizações do terceiro setor. Disponibilização dos produtos em repositórios institucionais e repositórios públicos de software, como o GitHub, ou em bancos de soluções empresariais para a comunidade externa.		
Objetivos		
Objetivo geral: capacitar o estudante a avaliar e selecionar modelos de aprendizado de máquina com rigor metodológico e a conduzir um projeto extensionista aplicando essas competências. Objetivos específicos: – escolher métricas adequadas de classificação e de regressão; – aplicar validação hold-out e validação cruzada (estratificada, por grupos e temporal); – evitar vazamento de dados com Pipelines; – ajustar hiperparâmetros por busca exaustiva e aleatória; – diagnosticar modelos com curvas de validação e de aprendizado; – comparar e selecionar modelos com critério estatístico; – ajustar o limiar de decisão e calibrar probabilidades; – assegurar reprodutibilidade e publicar os resultados; – desenvolver o projeto extensionista em parceria com o Hospital Santa Lucinda.		
Conteúdo Programático		
Data / Semana	Conteúdo por Aula	Observações
1ª aula — 04/08	Fundamentos da avaliação de modelos: generalização, sobreajuste/subajuste, viés-variância e vazamento de dados.	



Pontifícia Universidade Católica de São Paulo

2ª aula — 11/08	Métricas de classificação I: matriz de confusão, acurácia, precisão, recall, F1 e classes desbalanceadas.	Apresentação do projeto extensionista; formação dos grupos.
3ª aula — 18/08	Métricas de classificação II: ROC-AUC, curva PR, log-loss e médias macro/micro/weighted.	
4ª aula — 25/08	Métricas de regressão: MAE, MSE, RMSE, R^2 , MAPE e análise de resíduos.	
5ª aula — 01/09	Validação hold-out; treino/validação/teste; Pipeline e ColumnTransformer contra vazamento.	
6ª aula — 08/09	Validação cruzada I: k-fold, estratificado, leave-one-out e repetida.	
7ª aula — 15/09	Validação cruzada II: por grupos, séries temporais e validação aninhada.	
8ª aula — 22/09	Busca exaustiva de hiperparâmetros (grid search) com GridSearchCV.	
9ª aula — 29/09	Busca aleatória (RandomizedSearchCV); grid × aleatória; menção a AutoML.	
10ª aula — 06/10	Curvas de validação: desempenho × hiperparâmetro; ler sobreajuste e subajuste.	Desafio 3 - Substitutivo
11ª aula — 13/10	Curvas de aprendizado: desempenho × tamanho do treino; viés × variância.	
20/10	Semana Acadêmica	
12ª aula — 27/10	Seleção e comparação de modelos: regra de 1 desvio, testes pareados, McNemar.	
13ª aula — 03/11	Limiar de decisão e calibração de probabilidades (curvas de calibração, Brier).	
14ª aula — 10/11	Vazamento avançado e reprodutibilidade: seeds, joblib e model card.	
15ª aula — 17/11	Seleção de atributos avaliada corretamente (dentro da validação cruzada).	
16ª aula — 24/11	Estudo de caso integrado: pipeline completo de avaliação e seleção.	
17ª aula — 01/12	Comunicação e reprodutibilidade dos resultados; publicação do repositório.	Desafio 6 - Substitutivo
18ª aula — 08/12	Revisão integrada e apresentações finais dos projetos.	Apresentação e entrega final.
Metodologia ou Estratégias de Ensino		
Cada encontro combina exposição teórica (≈ 30 min) e laboratório prático em Python (≈ 180 min), com scikit-learn (model_selection e metrics). Antes da aula os alunos terão uma aula de 30 a 60 min que eles terão que assistir pelo youtube. Em sala de aula dúvidas são tiradas sobre essa aula e uma revisão é feita. No tempo restante em sala de aula os alunos fazem exercícios de aplicação da teoria. Esses exercícios fazem parte da composição da média, como apresentado abaixo. Os outros componentes da média são os desafios-que ocorrem sem data marcada, buscando que os alunos comparem a todas as aulas e que estejam sempre com a matéria estudada e o projeto extensionista aplicado a uma organização, cujos produtos são publicados em repositório público.		

Avaliação

Data da Avaliação	Forma de Avaliação	Tipo: Individual / Grupo	Pesos
Desafio substitutivo (06/10);	Atividades Semanais individuais Desafios 1 e 2 sem data marcada Desafio 3 substitutivo ao 1 ou 2 no dia 06/10	Atividades e Desafios são individuais	P1 = 30% atividades+ 70% desafios
Desafio substitutivo (24/11);	Atividades Semanais individuais Desafios 4 e 5 sem data marcada Desafio 6 substitutivo ao 4 ou 5 no dia 24/11	Atividades e Desafios são individuais	P2 = 30% atividades+ 70% desafios
Projeto Extensionista	Avaliação do grupo, autoavaliação e avaliação dos pares	Individual e em grupo	PE= 40%Grupo+ 20%Autoavaliação+ 40%Avaliação dos Pares

$$\text{Média} = (1.5 \cdot P1 + 1.5 \cdot P2 + PE) / 4$$

Bibliografias Básica e Complementar

Básica

CASTRO, L. N. de. Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.
 FERREIRA, R. G. C. et al. (org.). Preparação e análise exploratória de dados. Porto Alegre: Sagah, 2021.
 SUD, K.; ERDOGMUS, P.; KADRY, S. Introduction to Data Science and Machine Learning. Londres: IntechOpen, 2020.

Complementar

BELUSSI, A. et al. Distributed and parallel architectures for spatial data. Basel: MDPI, 2020.
 HUTTER, F.; KOTTHOFF, L.; VANSCHOREN, J. (ed.). Automated machine learning. Londres: Springer, 2019.
 OLIVEIRA, C. L. V.; ZANETTI, H. A. P. Projetos com Python e Arduino. São Paulo: Érica, 2020.
 SOLOMON, C.; VILLAMARÍN, R.; MENDOZA, E. Statistical machine learning for human behaviour analysis. Basel: MDPI, 2020.
 SOUZA, V. F. de. Mineração de dados educacionais com aprendizagem de máquina. Revista Educar+, Curitiba, v. 5, n. 2, 2021.