

DATA SCIENCE • POSTGRADUATE CLASS

The Impact of Artificial Intelligence on Energy Consumption

Energy concepts, impacts on the power grid, data centers and sustainability

O que vamos percorrer

Conceitos de energia, impactos na rede elétrica e sustentabilidade — em dez partes.

- 1. Introdução: por que IA e energia agora
- 2. Conceitos de energia (Watt, Wh, GW vs TWh, rede)
- 3. De onde vem o consumo de energia
- 4. Data centers de IA (arquitetura, PUE/WUE/CUE)
- 5. Impacto energético dos modelos (treino, RAG, inferência)
- 6. Impactos no sistema elétrico
- 7. Emissões de carbono e sustentabilidade
- 8. Estratégias de mitigação

Partes finais

- 9. Futuro da IA e da energia
 - AGI, demanda, flexibilidade
- 10. Conclusões
 - Aprendizados, desafios, pesquisa
- Apoio
 - Referências ABNT, perguntas e 20 questões no caderno

Cientistas alertam: data centers podem causar crise de água e energia

Como os gestores, a ciência e a sociedade podem fiscalizar esses empreendimentos

Por: Diélen Borges

Publicado em 22/09/2025 às 15:33 - Atualizado em 30/09/2025 às 07:40

Compartilhar:     

1

PARTE 1

Introdução: por que IA e energia, agora?

- Evolução histórica da IA e o salto dos modelos modernos
- Escalonamento de parâmetros e de computação
- Modelos fundacionais e LLMs
- A ponte entre IA, computação e eletricidade
- Os principais números globais do setor

A.I. TIMELINE

1950

TURING TEST

Computer scientist Alan Turing proposes a test for machine intelligence. If a machine can trick humans into thinking it is human, then it has intelligence



1961

UNIMATE

First industrial robot, Unimate, goes to work at GM replacing humans on the assembly line

1964

ELIZA

Pioneering chatbot developed by Joseph Weizenbaum at MIT holds conversations with humans



1966

SHAKY

The 'first electronic person' from Stanford, Shakey is a general-purpose mobile robot that reasons about its own actions



A.I. WINTER

Many false starts and dead-ends leave A.I. out in the cold

1997

DEEP BLUE

Deep Blue, a chess-playing computer from IBM defeats world chess champion Garry Kasparov



1998

KISMET

Cynthia Breazeal at MIT introduces Kismet, an emotionally intelligent robot insofar as it detects and responds to people's feelings



1999

AIBO


Sony launches first consumer robot pet dog AIBO (AI robot) with skills and personality that develop over time



2002

ROOMBA

First mass produced autonomous robotic vacuum cleaner from iRobot learns to navigate and clean homes



2011

SIRI

Apple integrates Siri, an intelligent virtual assistant with a voice interface, into the iPhone 4S



2011

WATSON

IBM's question answering computer Watson wins first place on popular \$1M prize television quiz show Jeopardy



2014

EUGENE

Eugene Goostman, a chatbot passes the Turing Test with a third of judges believing Eugene is human



2014

ALEXA

Amazon launches Alexa, an intelligent virtual assistant with a voice interface that completes shopping tasks



2016

TAY

Microsoft's chatbot Tay goes rogue on social media making inflammatory and offensive racist comments




2017

ALPHAGO

Google's A.I. AlphaGo beats world champion Ke Jie in the complex board game of Go, notable for its vast number (2¹⁷⁰) of possible positions


A adoção de IA



Fontes de dados: The New York Times [3]; Our World in Data (para Internet) [4]

Difusão de IA pela economia

Difusão da IA pela economia




Fonte de dados: Relatório técnico de difusão de IA, AI for Good Lab [5]

Difusão de IA vs GDP (PIB)




Source: GDP sourced from World Bank and CEIC (Taiwan)

O motor de hardware: explosão na demanda por GPUs



O impacto das escolhas na economia

PIB real per capita – Filipinas vs. Coreia do Sul



Fonte de dados: PIB per capita, Indicadores de Desenvolvimento Mundial do Banco Mundial [2]

- No final dos anos 1970, o governo sul-coreano identificou semicondutores como prioridade estratégica e fez parcerias com o setor privado para investir estrategicamente.
- A economia da Coreia do Sul disparou, crescendo 6,2% ao ano e dobrando o padrão de vida a cada onze anos. Em contraste, a economia filipina cresceu 1,8% ao ano, próximo à média mundial, permanecendo mais atrelada a commodities primárias, especialmente agricultura, mineração e serviços de terceirização.


Quem irá colher os investimentos em IA?

➤ **AI takeover: Share of frontier tech market could quadruple by 2033**

AI market projected to hit \$4.8 trillion by 2033, emerging as dominant frontier technology

Estimated frontier technology market size and share of selected technologies, 2023 and 2033

Artificial intelligence Internet of things Blockchain Electric vehicles Solar photovoltaic Other



Source: UN Trade and Development (UNCTAD) based on various online market research reports.

Note: Market size data capture the revenue generated by the sales of products and services. The graphs show the top four of 17 frontier technologies by market share for each year. The remaining 13 are grouped under "other".

2

PARTE 2

Conceitos de energia que você vai precisar

- Potência (Watt) vs. energia (Watt-hora): a distinção central
- A escada de unidades: W, kW, MW, GW e Wh, kWh, MWh, TWh
- Capacidade (GW) vs. consumo (TWh) e fator de capacidade
- Demanda, curva de carga e o equilíbrio da rede elétrica
- Intensidade de carbono e intensidade energética da IA

Potência vs. energia: Watt vs. Watt-hora

A confusão mais comum — e mais cara — do debate sobre IA e energia.

Potência (Watt, W)

- É a taxa instantânea de uso de energia — quão rápido se consome.

Energia (Watt-hora, Wh)

- É a quantidade total consumida ao longo do tempo.

A ponte

- Energia = Potência × Tempo. Ex.: 1.000 W durante 1 h = 1.000 Wh = 1 kWh.

Em uma frase

- **Watt**
 - o quão rápido (velocidade)
- **Watt-hora**
 - o quanto no total (distância)
- **Conta de luz**
 - você paga por kWh (energia), não por W

A escada de unidades de potência

Cada degrau é 1.000× o anterior. Referências para calibrar a intuição.

1 W

uma lâmpada LED pequena

1 kW

= mil W • um forno micro-ondas / chaleira

1 MW

= mil kW • ~uma pequena fábrica

1 GW

= mil MW • ~uma cidade média

100 MW

um data center de IA de médio porte

1–5 GW

um campus de IA (Stargate)

Regra de ouro: GW mede POTÊNCIA (capacidade instalada). Cada degrau multiplica por mil.

A escada de unidades de energia

As mesmas referências, agora em ENERGIA (acumulada ao longo do tempo).

1 Wh

~uma consulta de texto à IA ($\approx 0,3$ Wh)

1 kWh

= mil Wh • lavar uma carga de roupa

~200 kWh

conta de luz mensal de uma casa

1 MWh

= mil kWh • ~uma casa por ~5 meses

1 GWh

= mil MWh • treino do GPT-3 $\approx 1,3$ GWh
• treino do GPT-4 $\approx 50-70$ GWh

1 TWh

= mil GWh • data centers globais: 415 TWh/ano

Regra de ouro: TWh mede ENERGIA (consumo ao longo do tempo). 1 TWh = 1 bilhão de kWh.

Pondo os números para trabalhar

Com uma única fórmula, estimamos do consumo de uma GPU ao de um data center.

Exemplos resolvidos (Energia = Potência × Tempo)

- GPU de 1.000 W ligada 24 h = 24.000 Wh = 24 kWh/dia.
- Data center de 100 MW × 24 h = 2.400 MWh = 2,4 GWh por dia.
- 1 bilhão de consultas/dia × 0,3 Wh = 300 MWh/dia ≈ 110 GWh/ano.

O caminho inverso

- Consumo anual ÷ horas do ano (8.760 h) = potência média.
- 415 TWh/ano ÷ 8.760 h ≈ 47 GW de potência média contínua.

Capacidade (GW) vs. consumo (TWh)

Duas grandezas diferentes

- Capacidade (GW): a potência máxima que pode ser entregue
- Consumo/energia (TWh): o quanto efetivamente flui ao longo do tempo.

Fator de capacidade


$$Fator\ de\ Capacidade_{médio} = \frac{Energia\ Consumida}{Capacidade * Tempo}$$

$$Fator\ de\ Capacidade_{instantâneo} = \frac{Potência\ Consumida}{Capacidade}$$


Valores usuais:

- Data center: alto (~70–90%) — opera quase o tempo todo, dia e noite.
- Eólica ~25–45% — dependem do recurso e da época
- Solar: baixo (~15–25%);
- Por isso 1 GW de data center exige MUITO mais que 1 GW de solar para ser suprido.

Demanda, carga e o perfil da IA




A rede elétrica em um slide




Intensidade energética

O QUE É PUE? EFICIÊNCIA DE USO DE ENERGIA






INTERPRETAÇÃO DOS RESULTADOS DO PUE



Intensidade de carbono

A intensidade de carbono

- Emissões = energia × intensidade da matriz (gCO₂/kWh).



https://ember-energy.org/data/electricity-data-explorer/?entity=Brazil&metric=pct_share&chart=single_year&mode=stacked

ENTENDENDO O CONSUMO DE ENERGIA DA IA


COMO A IA DEMANDA ENERGIA: UMA ANÁLISE EM NÍVEIS

VISÃO VERTICAL INTEGRADA


3. CAMADA SISTÊMICA: IMPACTO NA REDE E SOCIEDADE



2. CAMADA DE INFRAESTRUTURA: O HARDWARE FÍSICO




1. CAMADA COMPUTACIONAL: TREINAMENTO E INFERÊNCIA



Energy consumption per ChatGPT query is small compared to everyday electricity use

EPOCH AI




Pessimistic estimates of the energy usage of ChatGPT with GPT-4o across for different query lengths: typical (<100 words), long (~7,500 words), and maximum context length (~75,000 words), with an average response length of 400 words.

Por que estudar o consumo energético da IA

How much of global electricity is used for data centres?


Measured in terawatt-hours (TWh). Estimates for 2025; IEA projections for 2030.



Note: Projections for 2030 are based on the IEA's base case, and come with significant uncertainty.
Data source: Calculated based on IEA, Key questions on Energy and AI (2026) and Ember (2026).

IEA scenarios of electricity demand from data centres

Global data centre electricity consumption (TWh). Four IEA scenarios for 2030 and 2035.




Note: 2035 figures are exploratory given the high level of uncertainty around data centre demand growth.
Data source: IEA, Key questions on Energy and AI (2026).

Por que estudar o consumo energético da IA

Share of electricity used by data centres, 2025

Data centre electricity consumption as a percentage of total electricity generation.




Note: Regional electricity totals are based on Ember (2026). Regional boundaries may not align exactly with IEA definitions.

Data source: Calculated based on IEA, Key questions on Energy and AI (2026) and Ember (2026).

Por que estudar o consumo energético da IA

Data centres' share of electricity demand growth to 2030

How much of total electricity demand growth from 2025 to 2030 comes from data centres?



Note: Based on IEA Base Case for data centre growth. Regional electricity growth estimated from recent trends.

Data source: Calculated based on IEA, Key questions on Energy and AI (2026) and Ember (2026).

Por que estudar o consumo energético da IA

Seis razões que tornam o tema central para engenharia, política pública e ciência de dados.

~10%

do crescimento global da demanda elétrica até 2030 virá de data centers (IEA)

até 50%

do crescimento da demanda elétrica dos EUA atribuível a data centers (IEA)

4,4%

da eletricidade dos EUA já foi para data centers em 2023 (LBNL: 176 TWh)

189 Mt

de CO₂e estimados para data centers em 2025 (UNU-INWEH)

30×

crescimento projetado da demanda de IA nos EUA até 2035: 4→123 GW (Deloitte)

~20%

dos projetos de data center em risco de atraso por restrições de rede (IEA)


3

PARTE 3

De onde vem o consumo de energia?

- Chips, memória, comunicação, armazenamento e sistemas auxiliares
- Métricas: TDP, FLOPs/W e Performance per Watt
- Eficiência computacional e o 'memory wall'
- Do chip ao rack: um balanço energético numérico
- Divergências entre fontes na composição do consumo

BALANÇO DO DATA CENTER MODERNO



O objetivo do PUE (Power Usage Effectiveness) é reduzir as fatias de suporte para maximizar a energia em TI.

O CUSTO DA MOVIMENTAÇÃO DE DADOS



Memória

Até 30% da potência do servidor. A correlação entre uso de memória e potência da GPU é de $\rho \approx 0,95$.



Comunicação

Switches operam com 80-90% da potência mesmo ociosos. Placas de rede podem consumir 400W.



Armazenamento

Checkpoints de treino geram picos de E/S. Em DCs intensivos, o storage representa 40% do consumo.

INFRAESTRUTURA DE SUPORTE

O Desafio Térmico

Para cada 1W de TI, gasta-se até 1W adicional em refrigeração e perdas elétricas.

- Energia: Perdas de conversão em UPS (~9%) e PDUs (~3%).
- Fans: A potência do ventilador cresce com o cubo da velocidade.

$$P \propto v^3$$

| EFICIÊNCIA COMPUTACIONAL

5x/ano
Crescimento da Computação

O Paradoxo de Jevons

Embora a eficiência do hardware melhore 1,3x ao ano, a demanda cresce exponencialmente. Ganhos de eficiência tornam o uso da tecnologia mais barato, o que paradoxalmente **aumenta o consumo total**.

O GPT-4 foi 2,8x mais eficiente que o GPT-3, mas a escala de treino massiva anulou a economia absoluta.

| DO CHIP À INSTALAÇÃO



Multiplicação de escala: como o consumo térmico de um chip escala para megawatts em nível de instalação.

4

PARTE 4

Data centers de IA

- Arquitetura, clusters de treino e infraestrutura elétrica
- Refrigeração, UPS, baterias e geradores
- Métricas: PUE, WUE e CUE
- Data center tradicional vs. data center de IA
- Estudos de caso reais

Métrica PUE: Evolução da Eficiência



PUE = Energia Total ÷ Energia de TI. Quanto mais próximo de 1.0, menor o overhead de infraestrutura.

Métricas Ambientais: WUE e CUE



Água (WUE)

Um DC de 100MW utiliza ~2 milhões de litros/dia. Equivale ao consumo de 6.500 residências.



Carbono (CUE)

Emissões de CO2 dependem da matriz local. Redes nucleares/ renováveis reduzem CUE em 10x.



Escala Global

Consumo de água passará de 560 bi para 1.200 bi de litros/ano até 2030.

Diferenciais Estratégicos

Parâmetro	DC Tradicional	Data Center de IA
Densidade por Rack	5 - 15 kW	30 - 150 kW
Escala Total	10 - 50 MW	100 MW - 1 GW+
Refrigeração	Ar (CRAC/CRAH)	Líquido / Imersão
Perfil de Carga	Estável / Sazonal	Picos / 100% no Treino
Conexão Elétrica	Rede de Distribuição	Rede de Transmissão

Anthropic invests \$50 billion in American AI infrastructure

12 de nov. de 2025

Projeto Stargate: como serão novos data centers bilionários da OpenAI nos EUA

Criadora do ChatGPT vai ampliar iniciativa bilionária para mais cinco cidades americanas. Parceria com a SoftBank e a Oracle busca ampliar infraestrutura de IA dos EUA.

Por **Redação g1**

24/09/2025 00h00 · Atualizado há 8 meses


A **OpenAI**, criadora do **ChatGPT**, planeja construir mais cinco data centers no projeto Stargate, iniciativa bilionária com as empresas de telecomunicações SoftBank e de servidores Oracle.

O projeto Stargate promete investir US\$ 500 bilhões (cerca de R\$ 2,6 trilhões) para ampliar a infraestrutura de inteligência artificial nos Estados Unidos.

Na terça-feira (23), a empresa informou que o projeto receberá mais cinco data centers e, nos próximos três anos, vai ampliar sua capacidade para 7 gigawatts (ou 7.000 megawatts) – saiba mais abaixo.

Our gigafactory of compute.

Built in 122 days — outpacing every estimate — Colossus was the most powerful AI training system yet. Then we doubled it in 92 days to 200k GPUs. This is just the beginning.



- Projetada a expansão para 500k GPUs (650MW)
- Atualmente 300MW

O que levar da Parte 4

3 métricas

PUE (energia), WUE (água), CUE (carbono)

~1,1

PUE dos melhores; média global ainda ~1,5

30–150 kW

densidade de rack de IA (vs 5–15 tradicional)

4,35 L

água por kWh (média EUA, incl. geração)

$CUE = \beta \cdot PUE$


carbono depende da matriz, não só da eficiência

GW

a nova unidade de escala dos campi de IA

What Ireland's Data Center Crisis Means for the EU's AI Sovereignty Plans

LOUIS BOYD-MADSEN / DEC 18, 2025



What Ireland's Data Center Crisis Means for the EU's AI Sovereignty Plans

LOUIS BOYD-MADSEN / DEC 18, 2025

Electricity demand in Ireland

Terawatt-hours




What Ireland's Data Center Crisis Means for the EU's AI Sovereignty Plans

LOUIS BOYD-MADSEN / DEC 18, 2025

Share of electricity generation in Ireland

Percentage share



Datacenters farão consumo de energia dobrar no Brasil em quatro anos

Levantamento da MIT aponta salto de 1,7% para 3,9% da demanda nacional de eletricidade até 2029, impulsionado pela alta demanda da IA

Consumo de Energia Elétrica

- Participação dos data centers em 2024:
- Representaram 1,7% do consumo total de energia elétrica no Brasil.
- Equivalente a 8,2 TWh, em um total nacional de 650,4 TWh.
- Projeção para 2029:
- Estima-se que o consumo dos data centers chegue a 27,3 TWh.
- Isso representaria 3,6% do consumo nacional previsto.

Consumo de Água

Dados de 2022:

- O uso consuntivo dos data centers foi de 0,003% do total de água utilizada no país.
- Aproximadamente 2 bilhões de litros, equivalente ao consumo anual de cerca de 34,9 mil pessoas.

TikTok inicia obra de mega data center no Ceará

O empreendimento está sendo construído em Caucaia, no perímetro da Zona de Processamento de Exportação (ZPE) do Ceará.

Por **Leonardo Igor**, g1 CE

16/01/2026 15h40 · Atualizado há 4 meses

Já estão em andamento as obras para a construção do **mega data center da big tech chinesa ByteDance, empresa controladora do TikTok**, nas imediações do Porto do Pecém, no Ceará. O empreendimento é o pontapé do complexo de cinco data centers, com investimentos de mais de R\$ 580 bilhões, de acordo com o Ministério do Desenvolvimento e da Indústria.

Com capacidade inicial de 200 MW de processamento, o data center em construção agora será o maior individual (de um único cliente) do Brasil e também será o primeiro voltado para a exportação - os dados processados aqui serão referentes a usuários de outros países.

5

PARTE 5

Impacto energético dos modelos de IA

- Treino, fine-tuning, RAG e inferência: quem consome o quê
- kWh por treino, kWh por consulta, energia por token e por imagem
- Diferenças de eficiência entre modelos
- O 'quebra-cabeça dos 98%' e a dificuldade de medir
- A pegada de um dia de uso de IA

Onde a energia é gasta ao longo da vida do modelo

Treino é um pico único; inferência é um fluxo contínuo que, somado, domina.

~30–40%

do consumo de vida é treino + preparação do modelo

~60%

é inferência (no Google); pode chegar a >90% em escala


~10%

é preparação de dados e fine-tuning

80–90%

da energia operacional total da IA é inferência (UNU-INWEH)

Energia de treino: ordens de magnitude entre modelos



Fontes: de Vries (2023); Krishnam (2025); UNU-INWEH (2026); Cruzes (2025). GPT-4: ponto médio 50-62 GWh.

Escala logarítmica. GPT-4 = ponto médio da faixa 50–62 GWh reportada por diferentes fontes.

Da casa dos MWh aos GWh

- GPT-2: ~1,4 MWh.
- GPT-3: 1.287 MWh (~120 residências/ano nos EUA).
- Llama 3.1 405B: ~21 GWh.
- GPT-4: ~50–62 GWh (alimenta São Francisco por ~3 dias).
- **Cinco ordens de magnitude do GPT-2 ao GPT-4.**

kWh por treinamento em perspectiva

Grande por execução, pequeno no agregado — mas com pegada ambiental concentrada.

Comparações úteis

- Treino do GPT-4 $\approx$ eletricidade diária de ~ 28.500 residências de economia avançada.
- Todos os grandes modelos treinados desde 2020 $\approx 1,7$ TWh $\approx 0,001\%$ da eletricidade global (IEA).

Mas há pegadas além da energia

- GPT-4 (estimativa UNU-INWEH): ~ 25.000 t CO₂e; ~ 600 milhões de litros de água.
- A fabricação dos chips também consome: TSMC usou >20 TWh em 2023.

Treino do GPT-4

- $\sim 50\text{--}62$ GWh
- energia de uma execução
- ~ 25.000 t
- CO₂e (estimativa)
- ~ 600 mi L
- água (~ 237 piscinas olímpicas)

Fine-tuning: adaptar sem retreinar

Ajustar um modelo pré-treinado a uma tarefa custa uma fração do pré-treino.

Conceito

- Parte-se de um modelo fundacional e ajustam-se os pesos para uma tarefa/domínio específico.
- Muito mais barato que treinar do zero — reaproveita o pré-treino.

Técnicas eficientes (PEFT)

- LoRA / PEFT: ajustam poucos parâmetros, cortando energia em até ~70% vs. fine-tuning completo.
- Fine-tuning seletivo pode reduzir a energia em até ~64% (Chen et al.).
- Modelos menores especializados podem cortar >50% da energia vs. um 7B+ genérico.

até 70%

economia com LoRA/PEFT vs. fine-tuning completo

até 64%

economia com fine-tuning seletivo

>50%

economia usando modelo menor especializado

RAG: Retrieval-Augmented Generation

Em vez de embutir todo o conhecimento nos pesos, busca-se informação externa em tempo de inferência.

Como funciona

- O sistema recupera documentos relevantes e os fornece como contexto ao LLM.
- Permite usar modelos menores com conhecimento atualizado, sem retreinar.


Trade-off energético

- Economia: evita retreinos caros e pode usar um modelo-base menor.
- Custo: aumenta o tamanho do contexto (mais tokens) → mais energia por consulta.
- Adiciona o consumo do sistema de busca/recuperação (banco vetorial).

RAG: balanço

- **Economiza**
 - evita retreino; permite modelo menor
- **Custa**
 - contexto maior = mais tokens/energia
- **Líquido**
 - depende do caso; medir é essencial

Energia por consulta: do texto curto ao raciocínio



Fontes: Ritchie (2026); Chen et al. (2025); UNU-INWEH (2026); MIT Tech Review (2025).

Escala logarítmica. Valores incluem estimativas de empresas e medições independentes.

Faixa de ~150×

- Texto curto: ~0,24–0,3 Wh (Gemini, ChatGPT).
- Imagem: ~2,9 Wh.
- Raciocínio longo: 30–40 Wh (GPT-o3, DeepSeek-R1).
- **O modo de uso importa tanto quanto o modelo.**

Energia por token e o custo do 'pensar'

A unidade fundamental da inferência é o token gerado — e gerar mais tokens custa mais.

A mecânica

- Cada token gerado exige uma passagem completa pelo modelo (forward pass).
- Energia por consulta $\approx$ energia por token $\times$ número de tokens gerados.

Por que o raciocínio custa caro

- Modelos de raciocínio geram longas 'cadeias de pensamento' internas antes da resposta.
- Resultado: $\sim 43\times$ mais energia para problemas simples (vs. resposta direta).
- Comparação clássica: consulta a LLM ~ 3 Wh vs. busca tradicional $\sim 0,3$ Wh ($\sim 10\times$).

43×

mais energia em modelos de raciocínio (problema simples)

$\sim 10\times$

LLM (~ 3 Wh) vs. busca tradicional ($\sim 0,3$ Wh)

1 token

= 1 forward pass completo pelo modelo

Geração de imagem e vídeo

Mídia generativa é muito mais cara que texto — e o vídeo é o extremo.

2,9 Wh

por imagem padrão (~60× uma resposta curta de texto)

1,22 g

CO₂e por imagem; ~28,6 mL de água

>415 Wh

por vídeo curto de alta resolução

~3,4 mi J

vídeo de 5 s (modelo recente) — 30× o anterior

~34 mi

imagens de IA geradas por dia (2023)

–99%

economia ao reduzir frames + resolução + passos

O 'quebra-cabeça dos 98%'

As contas de inferência de chatbots explicam só uma fração da energia atribuída à IA.

A conta de guardanapo da IEA

- 10 bilhões de consultas/dia $\times$ ~ 1 Wh = 10 GWh/dia = $\sim 3,65$ TWh/ano.
- Mas os data centers de IA consumiram ~ 155 TWh em 2025.
- Logo, as consultas de texto explicam apenas $\sim 2\%$ do total.

Onde estão os outros $\sim 98\%$?

- Treino, geração de imagem/vídeo, IA difusa em produtos, sobre capacidade e baixa utilização.

~ 155 TWh (2025)

- $\sim 2\%$
- explicado por consultas de texto
- $\sim 98\%$
- treino, imagem/vídeo, IA embutida, overhead
- Lição
- a IA é mais que o chatbot visível

Eficiência varia enormemente entre modelos

Arquitetura e otimização podem mudar o consumo em ordens de magnitude para capacidade similar.

Casos de eficiência

- DeepSeek: arquiteturas que reduzem energia de inferência em 50–70%.
- DeepSeek-V3: 80–90% menos computação de treino que o Llama (reportado).
- GPT-OSS-120B: pegada de treino ~30× menor que o GPT-4.

Implicação

- Modelos abertos e eficientes podem democratizar a IA com menor custo energético...
- ...mas barateamento estimula mais uso (Jevons) — efeito líquido incerto.

50–70%

menos energia de inferência (arquiteturas DeepSeek)

~30×

menor pegada de treino: GPT-OSS-120B vs GPT-4

80–90%

menos computação de treino reportada (DeepSeek-V3)

Por que as estimativas divergem tanto

A mesma pergunta — 'quanta energia?' — recebe respostas que diferem por ordens de magnitude.

Exemplos de divergência

- Treino do GPT-4: 42,4 GWh (IEA) vs. 50 GWh (MIT) vs. 50–70 GWh (UNU-INWEH).
- Consulta de texto: de ~0,0005 Wh (Ifri) a ~0,3–0,42 Wh (MIT/UNU).

Fontes da incerteza

- Escopo: só GPU vs. instalação inteira (PUE); modelo, hardware e utilização variam.
- Falta de transparência: fabricantes não divulgam dados oficiais.
- Postura correta: apresentar faixas, não números pontuais.

Boas práticas

- Faixas, não pontos
- reporte incerteza
- Declare o escopo
- GPU-only ou total?
- Cite a fonte
- e o ano da estimativa

A pegada de um dia de uso de IA

Tornando concreto: quanto consome o uso pessoal intenso de IA por dia.

2,9 kWh

um dia de uso (15 textos + 10 imagens + 3 vídeos) — MIT

~650 g

CO₂e desse dia na Califórnia (vs >1.150 g na Virg. Ocidental)

2,4 kWh

usuário intenso de agentes (24 consultas/dia × 100 Wh)

~7%

do consumo elétrico diário de um americano médio (uso intenso)

O mesmo uso emite ~2× mais CO₂ dependendo da matriz elétrica local (hora e lugar importam).

6

PARTE 6

Impactos no sistema elétrico

- Crescimento da demanda e novos centros de carga
- Impactos em transmissão, distribuição e confiabilidade
- Estabilidade dinâmica: frequência, RoCoF e qualidade de energia
- Planejamento da expansão e mercados de capacidade
- Flexibilidade operacional e resposta da demanda

A demanda elétrica dos data centers nos EUA

Pontos de virada

- 2014–2016: estável (~60 TWh).
- 2017: servidores de IA aceleram a curva.
- 2023: 176 TWh = 4,4% da eletricidade dos EUA.
- 2028: 74–132 GW de potência (50% utilização).

Leitura: Estável até 2017, depois disparou; 2028 entre 325 e 580 TWh (6,7%–12% da eletricidade dos EUA).

Quanto vai crescer? Projeções divergem

Atenção ao escopo

- Goldman: 66 GW de demanda nos EUA até 2027.
- RAND: 68 GW de capacidade global de IA em 2027.
- Deloitte: 123 GW de IA nos EUA até 2035 (30×).
- RAND: 327 GW globais em 2030 (alta).

Leitura: Escopos e horizontes diferentes: não compare os números diretamente sem ler as definições.

Novos centros de carga concentrados

A IA cria 'ilhas' de demanda gigantesca onde antes não havia carga relevante.

Concentração geográfica

- ~80% da carga de data centers dos EUA está em 15 estados (2023).
- Quase metade dos DCs dos EUA em cinco clusters regionais.
- Northern Virginia: >2,5–5 GW; Irlanda: 21% da eletricidade nacional.

Por que importa

- Um único campus pode demandar 1–5 GW — comparável a uma metrópole.
- A rede local não foi projetada para essa densidade de carga.

~80%

da carga de DC dos EUA em 15 estados

1–5 GW

demanda de um único campus de IA

5 GW

campus = energia de ~5 milhões de residências

Impacto na transmissão e filas de conexão

A construção de data centers (1–2 anos) é muito mais rápida que a expansão da rede (anos a décadas).

O descompasso temporal

- Conectar grandes cargas: filas de 4–8 anos; alguns pedidos esperam 7 anos.
- Filas de interconexão de geração nos EUA excedem a frota existente.
- Data center: construído em 1–2 anos; linha de transmissão: 5–10+ anos.

Consequências

- ~20% dos projetos de DC em risco de atraso por restrições de rede (IEA).
- Pressão por geração local (gás, nuclear dedicado) para contornar a rede.

4–8 anos

fila típica de conexão de grande carga

7 anos

espera em alguns pedidos (Deloitte)

~20%

dos projetos de DC em risco de atraso (IEA)

Impacto na distribuição e qualidade de energia

Cargas eletrônicas de alta densidade introduzem distúrbios que a rede local precisa absorver.

Qualidade de energia

- Distorção harmônica (THD) frequentemente >5–10%, acima de limites da IEEE 519.
- 3º, 5º e 7º harmônicos dominantes; UPS de dupla conversão são fonte.
- Quedas de tensão (sags) por variações abruptas de 10–20 MW.

Efeitos

- Fator de potência degradado reduz eficiência de transmissão em 10–15%.
- Mitigação: filtros ativos (APF/SVG) reduzem THD para <3%.

Qualidade de energia

- **THD**
 - >5–10% (limite IEEE 519: 5%)
- **Causa**
 - eletrônica de potência (UPS, PSU)
- **Solução**
 - filtros ativos → THD <3%

Confiabilidade: eventos reais na rede

Cargas grandes que se desconectam ou variam abruptamente ameaçam a estabilidade.

2.600 MW

perda súbita no ERCOT levou a frequência a 60,4 Hz

1,5 GW

trip de carga em 60 DCs (Dominion)

60 DCs

desconectaram juntos na Virgínia (2024)

~1.500 MW

perda em evento de sobrefrequência (jul/2024)

298 MW

rampa de queda em 25 s (instalação cripto, NERC)

±5–10%

desvios de tensão em redes fracas

Cargas de IA podem ligar/desligar em segundos — comportamento atípico para o qual a rede não foi planejada.

Estabilidade transitória: frequência e RoCoF

Em redes com pouca inércia, perdas súbitas de carga causam variações rápidas de frequência.

O caso irlandês (evento real)

- Uma falha causou queda de 204 MW de demanda de DC.
- RoCoF de 0,12 Hz/s e pico de frequência de 50,22 Hz.
- DCs na Irlanda: 800 MW de 7 GW de pico → rumo a 1,6 GW (~30%) em 2030.

Conceitos

- RoCoF = taxa de variação da frequência; alta = risco de disparo de proteções.
- Cargas de IA pulsantes ('flapping') e síncronas amplificam o efeito.

Por que é grave

- **Menos inércia**
 - renováveis reduzem a inércia da rede
- **Cargas pulsantes**
 - treino liga/desliga em bloco
- **RoCoF alto**
 - dispara proteções em cascata

Planejamento da expansão e mercados de capacidade

A demanda de IA já se reflete nos preços de capacidade e nos custos para o consumidor.

O caso PJM (maior mercado dos EUA)

- Leilão de capacidade: US\$ 2,2 bi (2024) → US\$ 14,7 bi (2025), ~7×.
- Preço 2026-27: US\$ 329/MW-dia vs. US\$ 28,9 anterior (>10×).
- Crescimento de pico 2024-2030: 32 GW, dos quais 30 GW (94%) de data centers.

Implicações

- Contas de luz podem subir ~8% até 2030 (até 25% em algumas regiões).
- Tensão entre atrair investimento e proteger consumidores (affordability).

7×

custo do leilão de capacidade PJM (2024→2025)

94%

do crescimento de pico do PJM vem de DCs

~8%

aumento projetado nas contas até 2030

Flexibilidade: a carga de IA pode ajudar a rede?

Se data centers aceitarem pequenas reduções de disponibilidade, liberam enorme capacidade de rede.

O potencial (estudo Duke)

- Reduzir 0,25% do uptime → libera 76 GW na rede dos EUA.
- Reduzir 1% do uptime → libera 126 GW (~10% da capacidade dos EUA).

Por que é viável

- >50% das cargas de IA são tolerantes a atraso (treino, batch).
- A rede dos EUA opera a ~53% da capacidade — há folga fora do pico.
- Armazenamento e geração local permitem 'esconder' picos da rede.

76 GW

liberados com 0,25% menos uptime

126 GW

liberados com 1% menos uptime

>50%

das cargas de IA toleram atraso

Resposta da demanda e deslocamento de carga

Mover cargas no tempo e no espaço alivia a rede e reduz emissões.

Mecanismos

- Deslocamento temporal: rodar cargas adiáveis fora do pico (preços/sinais de rede).
- Deslocamento espacial: enviar trabalho para regiões com folga ou energia limpa.
- Acoplamento com VEs e armazenamento como cargas/recursos flexíveis.

Ganhos reportados

- Estratégia de preços coordenada reduz flutuações de carga em >20% e ocupação de linhas ~15%.
- Deslocamento espacial sensível a carbono corta emissões ~10%.

Duas dimensões

- **Tempo**
 - rodar quando há folga/energia limpa
- **Espaço**
 - rodar onde há folga/energia limpa
- **Resultado**
 - -20% flutuação; -10% emissões

Mercados e regulação se adaptando

Marcos regulatórios tradicionais encontram um crescimento de demanda sem precedentes.

Novos instrumentos

- ERCOT (Texas) SB-6: redefine interconexão para cargas >75 MW.
- PJM: proposta de 'Non-Capacity-Backed Loads' (>50 MW) e 'kill switch' remoto.
- FERC: caso Amazon-Talen (co-location nuclear) rejeitado 2-1 (nov/2024).

Lacunas

- NERC governa diretamente <5% da capacidade de DC dos EUA.
- Tensão entre estabilidade, sustentabilidade, affordability e não-discriminação.

Cinco tensões

- Estabilidade da rede
- Sustentabilidade
- Acessibilidade (preço)
- Não-discriminação
- Independência regulatória

O que levar da Parte 6

4,4%→12%

eletricidade dos EUA em DCs: 2023 → 2028 (LBNL)

94%

do crescimento de pico do PJM vem de DCs

4–8 anos

filas de conexão vs. 1–2 anos para construir um DC

60,4 Hz

desvio de frequência por perda de 2.600 MW
(ERCOT)

126 GW

liberáveis com 1% menos uptime (flexibilidade)

5 tensões

o desafio regulatório (Lo Schiavo)

7

PARTE 7

Emissões de carbono e sustentabilidade

- Pegada de carbono da IA: treino e inferência
- Por que a matriz elétrica define as emissões
- Energia renovável, PPAs e o renascimento nuclear
- Água, terra, e-lixo e comparação entre países

A pegada de carbono da IA em números

Pequena no total energético global, mas crescente, concentrada e mais 'suja' que a média.

180 Mt

CO₂ de data centers em 2024 (IEA)

300 Mt

projeção para 2035, Cenário Base (IEA)

189 Mt

CO₂e de data centers em 2025 (UNU-INWEH)

+48%

intensidade de carbono dos DCs vs. média dos EUA

<1,5%

das emissões do setor de energia (mantém-se)


~5%

emissões que a IA poderia EVITAR na economia (IEA)

Treino do GPT-4 ≈ 25.000 t CO₂e; a inferência, repetida em escala, domina as emissões operacionais.

O carbono depende de onde a IA roda

A mesma IA, pegadas diferentes: carbono por país



Fonte: UNU-INWEH (2026) e dados de intensidade de rede por país.

Intensidade de carbono da eletricidade por país (aprox.). Fonte: UNU-INWEH (2026).

Até ~19× de diferença

- França/Suécia: ~37–40 g (nuclear/hidro/renovável).
- EUA/Alemanha: ~370–380 g (mix).
- China/Índia: 580–713 g (carvão).
- **CUE = $\beta \times$ PUE: a localização é a maior alavanca.**
- Brasil: baixa intensidade (hidrelétrica), mas alto uso de água.

Energia limpa e a busca por energia firme

As big techs compram muita renovável — mas a IA 24/7 reacende o nuclear e o gás.

Compras corporativas de renováveis (2021)

- Google 18,3 TWh; Microsoft 13 TWh; Meta 9,4 TWh; Apple 2,8 TWh.
- PPA (Power Purchase Agreement): contrato de longo prazo (10–25 anos) de energia limpa.
- IEA: metade do crescimento de demanda de DC até 2035 atendido por renováveis.

Energia firme: o renascimento nuclear

- Renováveis intermitentes não bastam para carga 24/7 (lembre o fator de capacidade).
- Microsoft–Three Mile Island (835 MW); AWS–Talen (960 MW); Google–Kairos SMRs (~2030).

18,3 TWh

renováveis do Google (2021)

835 MW

Three Mile Island religado p/ Microsoft

1/2

do crescimento de DC por renováveis (IEA)

Neutralidade de carbono: promessas e limites

As metas existem — mas o 'quando' e o 'como' exigem escrutínio.

Metas corporativas

- Meta: net-zero operacional desde 2020; Amazon: net-zero até 2040.
- Microsoft/Google: meta de operar com energia limpa 24/7 (CFE).

As três perguntas críticas

- Quando? Compensação ANUAL ≠ energia limpa 24/7 (à noite roda-se com a rede suja).
- Adicionalidade: o PPA criou capacidade limpa NOVA ou só comprou existente?
- Líquido: a demanda cresce mais rápido que a oferta limpa?

Perguntas críticas

- Quando?
 - limpo 24/7 ou só na média anual?
- Adicional?
 - capacidade nova ou existente?
- Líquido?
 - demanda supera a oferta limpa?

Água, terra e e-lixo: as outras pegadas

A sustentabilidade da IA é multidimensional — e há trade-offs entre as dimensões.

Água

- Data centers (2025): ~4,5 trilhões de litros; intensidade média EUA ~4,35 L/kWh.
- Dois terços dos novos DCs dos EUA em regiões de estresse hídrico.

Terra, materiais e e-lixo

- Pegada de terra (2025): ~6.900 km² (~4,5× a Grande Londres).
- E-lixo: até 2,5 milhões de toneladas/ano até 2030.
- Materiais críticos (ex.: gálio — China refina ~99%): vulnerabilidade geopolítica.

4,5 tri L

água de data centers em 2025

2/3

dos novos DCs em estresse hídrico

2,5 mi t

e-lixo/ano até 2030

Comparando países: carbono, água e contexto

País	Carbono vs. média	Água vs. média	Contexto
França	-88% (≈37 g/kWh)	baixa	Nuclear dominante
Suécia	muito baixa	+110%	Hidro/nuclear; alta água
EUA	-18%	alta absoluta	45% dos DCs globais
China	+21%	—	25% dos DCs; carvão+renováveis
Índia	+51%	—	Rede a carvão
Brasil	baixa (hidro)	+191%	Hidrelétrica; alta água

Valores relativos à média global (UNU-INWEH, 2026). Um país 'limpo' em carbono pode ser intensivo em água.

8

PARTE 8

Estratégias de mitigação

- Quatro camadas: modelo, hardware, data center, sistema
- Compressão de modelos e Mixture of Experts
- Refrigeração avançada e IA para otimizar data centers
- Ganhos reportados e os limites da eficiência (Jevons)

Quatro camadas de mitigação

A energia pode ser reduzida em cada nível — e os ganhos se compõem.

Da computação à rede

- 1) Modelo: compressão (quantização, distillation, pruning) e MoE.
- 2) Hardware: aceleradores eficientes, FP8/INT8, FLOPs/W.
- 3) Data center: refrigeração avançada, recuperação de calor, PUE baixo.
- 4) Sistema: alocação inteligente, flexibilidade, integração com renováveis.

Princípio

- Eficiência composta: ganhos no modelo × hardware × PUE × matriz limpa se multiplicam.

Pilha de eficiência

- **Modelo**
 - compressão, MoE
- **Hardware**
 - FP8, ASICs, FLOPs/W
- **Data center**
 - refrigeração, PUE
- **Sistema**
 - scheduling, renováveis

Compressão: quantização, distillation, pruning

Reduzir o tamanho efetivo do modelo corta memória, computação e energia.

Quantização — menos bits

- Int4: ~4× menos memória; 8/4 bits podem ~reduzir pela metade a energia. FP8 no treino (DeepSeek).

Distillation — aluno e professor

- Um modelo pequeno aprende a imitar um grande: inferência muito mais barata.

Pruning — remover o redundante

- Esparsidade estruturada de 50%: -75% de memória, +40% de vazão.
- Todas atacam o 'memory wall': menos bytes movidos = menos energia.

~4×

menos memória com int4

até 70%

economia com LoRA/PEFT (fine-tuning)

>90%

economia possível combinando técnicas

Mixture of Experts: ativar só o necessário

Um modelo enorme dividido em 'especialistas', dos quais poucos são ativados por token.

O conceito

- Muitos 'experts'; um roteador escolhe poucos por token.
- Capacidade total alta, mas computação por token baixa.
- DeepSeek-V3: 671 bi de parâmetros totais, mas só ~37 bi ativos por token (~5,5%).

Ganho e desafio

- Energia de inferência cai na proporção dos experts ativados.
- Desafio: balanceamento de carga e overhead de roteamento.

671 bi

parâmetros totais do DeepSeek-V3

~37 bi

ativos por token (~5,5%)

∝ experts

energia cai com nº de experts ativos

Hardware eficiente e refrigeração avançada

As camadas físicas: mais FLOPs/W e menos energia para remover o calor.

Hardware

- Especialização (GPU→TPU→ASIC) e precisão reduzida (FP8/INT8) elevam os FLOPs/W.
- Limite: eficiência do hardware cresce $\sim 1,3\times$ /ano; a demanda, $4-5\times$ /ano.

Refrigeração avançada

- Líquido/imersão: $-30-40\%$ de energia de refrigeração (PUE até $\sim 1,03$).
- Free cooling (clima frio): $-50-70\%$. Elevar a temperatura: $-20-40\%$.
- Recuperação de calor: reaproveita o calor residual (aquecimento, estufas).

30–40%

economia de refrigeração com líquido

$\sim 1,03$

PUE alcançável com imersão

1,3 vs 4–5×

eficiência de HW vs. demanda/ano

Alocação inteligente e IA para otimizar data centers

Decidir o que rodar, quando, onde e a que velocidade — e usar ML para isso.

Alocação inteligente de cargas

- DVFS (ajustar frequência/tensão): -27% com -10% de frequência.
- Consolidação de VMs; escalonamento sensível a energia/carbono.

IA otimizando o data center

- DeepMind no Google: -40% de energia de refrigeração via redes neurais.
- Digital twins + RL: -41% em refrigeração; previsão de carga (LSTM).
- Agentes realocam cargas entre data centers para minimizar custo/carbono.

-40%

refrigeração (DeepMind/Google)


-27%

com DVFS (-10% de frequência)

até -50%

energia com governança por IA (<9% perda)

Ganhos energéticos reportados na literatura



Fontes: EfficientLLM; Hu et al. (2025); Kumar et al. (2022); Ali (2026). Metodologias distintas.

Economias reportadas por técnica (valores representativos; metodologias distintas).

Leitura crítica

- Ganhos variam por método e contexto.
- Metodologias e baselines diferentes — não são somáveis.
- Muitos vêm de simulação ou casos específicos.
- Combinados na pilha, multiplicam-se...
- **...mas Jevons pode anular o ganho líquido.**

O paradoxo de Jevons: o limite da eficiência

Tornar a IA mais eficiente pode aumentar — não reduzir — o consumo total.

O mecanismo

- Eficiência ↓ custo por tarefa ↓ preço ↑ demanda ↑ consumo total.
- GPT-4 foi ~2,8× mais eficiente que GPT-3 em 18 meses — e o uso explodiu.

Implicações

- Eficiência é necessária, mas não suficiente para reduzir o impacto absoluto.
- É preciso também descarbonizar a OFERTA e flexibilizar a carga.
- A pergunta certa: não só 'mais eficiente?', mas 'qual o consumo total e como descarbonizá-lo?'.

Jevons na IA

- **Eficiência sobe**
 - custo por consulta cai
- **Uso explode**
 - mais usuários, respostas, agentes
- **Consumo total**
 - pode subir mesmo assim

9

PARTE 9

Futuro da IA e da energia

- AGI e a incerteza da demanda futura
- IA como ferramenta de otimização energética
- Data centers flexíveis e integração com renováveis
- Armazenamento de energia e a co-evolução IA–rede
- Cenários de longo prazo: o que vigiar

AGI e o crescimento futuro da demanda

Se a busca por IA mais geral continuar, a escala de computação — e energia — pode crescer ordens de magnitude.

8 GW

potência de um único treino em 2030 (RAND) — 8 reatores

327 GW

capacidade global de IA em 2030, cenário alto (RAND)

1 milhão

GPUs por cluster projetado até 2026

700–1.700

TWh: faixa de demanda de DC em 2035 (IEA)

A trajetória rumo à AGI é a maior fonte de incerteza: pode acelerar a demanda ou estabilizá-la se a escala saturar.

IA como ferramenta de otimização energética

A mesma tecnologia que demanda energia pode tornar todo o sistema energético mais eficiente.

Aplicações na rede (IEA)

- Detecção de falhas reduz duração de quedas em 30–50%.
- Até 175 GW de capacidade de transmissão 'destravados' sem novas linhas.
- Previsão de carga e geração renovável (ex.: Random Forest, LSTM).

Em toda a economia

- Otimização industrial, transporte e edificações: grande potencial de economia.
- IA poderia evitar emissões $\approx$ 5% das do setor de energia em 2035.

30–50%

redução na duração de quedas (IA)

175 GW

transmissão destravada sem novas linhas

~5%

emissões evitáveis na economia (2035)

SpaceX offers details on orbital data center satellites

by Jeff Foust

March 22, 2026



Scaling for massive capacity

1 Billion

Optimus robots
to do the work

10 Million

Tons of mass/year
launched into orbit

1 TW+

Solar power
needed

Optimus

Starship V3



AI Sat Mini



A SpaceX illustration showing the Starship V3 rocket on the same scale as its planned AI Sat Mini orbital data center spacecraft. Credit: SpaceX

[Home](#) > [Blog](#) >

Exploring a space-based, scalable AI infrastructure system design

November 4, 2025 · Travis Beals, Senior Director, Paradigms of Intelligence

A rectangular graphic with a yellow-to-orange gradient background. The text "Project Suncatcher" is centered in white.

Project Suncatcher

Data centers flexíveis, renováveis e armazenamento

O futuro: o data center deixa de ser carga passiva e vira ativo ativo da rede.

O modelo prosumer

- Data centers com geração própria, armazenamento e flexibilidade de carga.
- Participam de resposta da demanda e serviços de rede (regulação de frequência).
- Recuperação de calor integrada a sistemas de energia distrital.

Paralelo com os VEs

- Como os veículos elétricos (V2G), grandes cargas flexíveis podem estabilizar a rede.
- Armazenamento (HESS) é o elo que viabiliza essa flexibilidade.

Carga → ativo

- **Gera**
 - renovável on-site + PPA
- **Armazena**
 - baterias/HESS
- **Flexibiliza**
 - DR e serviços de rede
- **Aproveita**
 - calor residual

Cenários de demanda: o leque de futuros possíveis

O que vigiar

- Ritmo de eficiência (MoE, FP8, hardware).
- Saturação ou não das leis de escala.
- Gargalos de rede e de chips.
- Descarbonização da oferta.

Leitura: Em 2035 a demanda pode variar de 700 a 1.700 TWh — a incerteza é a mensagem.

10

PARTE 10

Conclusões

- Principais aprendizados
- Desafios técnicos e energéticos
- Oportunidades de pesquisa
- Mensagens finais

Principais aprendizados

O consumo energético da IA é um problema de sistemas — atravessa computação, infraestrutura e rede.

- Escala impulsiona consumo: computação de fronteira cresce 4–5×/ano; energia segue.
- A inferência domina (80–90%), não o treino — onde otimizar importa.
- Data centers: 1,5% da eletricidade global (2024) rumo a ~3% (2030); IA é o motor.
- O impacto não é só energia: é rede (GW concentrados), carbono, água e materiais.
- A matriz elétrica e a localização definem a pegada tanto quanto a eficiência.
- Eficiência é necessária, mas Jevons exige descarbonizar a oferta e flexibilizar a carga.

Desafios técnicos e energéticos

Técnicos

- Medir e reportar consumo com transparência e escopo claro.
- Estabilidade da rede com cargas grandes, pulsantes e síncronas.
- Qualidade de energia (harmônicos, tensão) em alta densidade.
- Refrigerar racks de 50–150 kW de forma eficiente.
- Desacoplar capacidade de energia (MoE, quantização, hardware).

Energéticos e sistêmicos

- Expansão de rede (anos) vs. data centers (meses).
- Energia firme e limpa 24/7 (nuclear, armazenamento).
- Affordability: quem paga a nova infraestrutura.
- Água e materiais em regiões sob estresse.
- Regulação que acompanhe o ritmo da demanda.

Oportunidades de pesquisa

Onde um cientista de dados ou engenheiro pode contribuir.

Modelagem e medição

- Modelos abertos e reprodutíveis de consumo (treino e inferência) por arquitetura.
- Previsão de carga de data centers e de geração renovável com ML.

Eficiência e sistemas

- Compressão e MoE com garantias de qualidade; co-design hardware-modelo.
- Escalonamento sensível a carbono/energia; data centers como recursos flexíveis.
- Estabilidade de redes com alta penetração de cargas de IA e baixa inércia.

Linhas promissoras

- **Medição aberta**
 - benchmarks de energia por tarefa
- **Carbon-aware ML**
 - escalonar por carbono
- **Co-design**
 - modelo + hardware + DC
- **Grid + IA**
 - estabilidade e flexibilidade

Mensagens finais

- **A IA é, hoje, também um problema de energia e de sistemas elétricos.**
- Pense em faixas e cenários, não em números pontuais: a incerteza é estrutural.
- A inferência em escala — não o treino — domina o consumo operacional.
- Onde e quando a IA roda importa tanto quanto quão eficiente ela é.
- **Eficiência + descarbonização da oferta + flexibilidade da carga = caminho sustentável.**
- Como cientistas de dados, otimizar acurácia E energia é parte do nosso ofício.

Mensagens finais

- <https://www.youtube.com/watch?v=cNI4N3-FcEI>
- <https://www.youtube.com/watch?v=xXEcrIfhPJo>
- https://www.youtube.com/shorts/E41X5s_BpgM
- <https://www.youtube.com/shorts/sHEyyL9mx4M>