

Fundamentos da avaliação de modelos

Generalização, sobreajuste, viés e variância, e vazamento de dados

Objetivo da aula

- **Sair do 'como treinar'** — e entrar no 'quão bom é este modelo?' — o foco vira avaliar e selecionar.
- **Entender generalização** — o que importa é acertar em dados novos, não decorar o treino.
- **Diagnosticar** — sobreajuste, subajuste e o tradeoff viés e variância a partir de curvas simples.
- **Reconhecer vazamento** — o erro mais perigoso e mais comum, na forma óbvia e na sutil.
- **Preparar o laboratório** — toda a teoria alimenta os exercícios de hoje em pandas e scikit-learn.

AO FINAL VOCÊ SABERÁ

Avaliar

- Por que treino nunca basta
- Ler uma curva de complexidade
- Detectar e evitar vazamento
- Manter o teste intocável

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R ² , resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	Projeto: dados
9 — 29/09	Busca aleatória e menção a AutoML	

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 06/10	Curvas de validação	Desafio 3 (subst.)
11 — 13/10	Curvas de aprendizado	
12 — 20/10	Seleção e comparação de modelos	
13 — 27/10	Limiar de decisão e calibração	
14 — 03/11	Target Leakage e reprodutibilidade	
15 — 10/11	Seleção de atributos	
16 — 17/11	Estudo de caso integrado	
17 — 24/11	Comunicação e reprodutibilidade dos resultados	Desafio 6 (subst.)
18 — 01/12	Revisão integrada e apresentações	Apresentação final

Como essa disciplina vai funcionar:

Terça-Feira

- **Pré-aula (Enviada via Youtube) – 30-60 min**
- **Aula (15 min de revisão e solução de duvidas)**
- **Aula (Restante da aula – Exercícios)**

Prof Giovani

Como a média será calculada

$$\text{Média final} = (1.5P1 + 1.5P2 + PE) / 4$$

P1 — Primeira parte

- Atividades em sala de aula – 30%
- Desafios-surpresa (40 min) – 70%

P2 — Segunda parte

- Atividades em sala de aula – 30%
- Desafios-surpresa (40 min) – 70%


Por que os desafios são surpresa (não tem data marcada)?

Presença em Sala de Aula

Mantém vocês sempre focados, com a matéria em dia.

Em tempos de IA, é uma atividade feita em sala de aula sob vigilância com tempo limitado.

Mas e se eu perder um desafio?



PARTE 1

Qual a função dessa disciplina na formação do cientista de dados?

1

Onde esta disciplina se encaixa

- **Vocês já sabem ajustar um modelo aos dados** — regressão, árvores, k-NN, redes
- **Agora o foco muda** — A ideia dessa disciplina é auxiliá-los a entender como avaliar se um modelo é bom e selecionar o melhor modelo entre as alternativas.

Por que preciso entender o conteúdo dessa disciplina?

- **Numa conversa com o teu cliente você precisará apresentar a ele com honestidade o quanto o teu modelo acerta na estimativa**
- **Esse número precisa ser um valor honesto**— um resultado inflado leva a decisões erradas e caras.
- **Porque você escolheu o modelo A ao invés do modelo B? Como vc assegura que a metodologia escolhida foi a correta?** — o cliente pergunta 'como você avaliou?' — você precisa responder com rigor.
- **Evitar retrabalho** — detectar vazamento cedo evita refazer todo o projeto no fim.

NO PROJETO REAL

Confiar

- Número honesto
- Método defensável
- Risco controlado

O objetivo real: generalização

- **Generalizar / O modelo treinado com os teus dados de treino quando trazido para o mundo real se comporta de forma correta?** — acertar em exemplos novos, que não estavam nos dados de treino / um modelo que memoriza o treino pode falhar feio no mundo real.
- **Imaginem que um professor passa uma prova completamente diferente das listas de exercícios, e o aluno vai mal** — as listas são os seus dados de treino, a prova é o mundo real, o aluno é o teu modelo.

Dois erros diferentes

- **Erro de treino** — o quanto o modelo erra nos dados que ele já viu.
- **Erro de generalização** — o quanto ele erra em dados novos — o que realmente importa.

Erro de treino $\neq$ Erro em dados novos

PARTE 2

O Risco da Ilusão: Acurácia no Dado de Treino

Por que avaliar o modelo nos mesmos dados em que ele aprendeu gera conclusões falsas.

2

O erro mais básico

Medir Onde Treinou

- **A Prova com Gabarito** — Avaliar a performance no mesmo conjunto usado para ajustar os parâmetros do modelo.
- O resultado é artificialmente inflado, pois o algoritmo decorou as respostas em vez de aprender padrões gerais.

A Regra de Ouro

- **Isolamento Absoluto** — Nunca avalie métricas finais em dados utilizados durante a fase de ajuste.
- Reserve uma amostra inédita que o modelo jamais viu para simular a aplicação no mundo real.

Exemplo: Árvore Sem Limite

- Uma árvore de decisão sem limite de profundidade decorou perfeitamente os dados de treino.
- Esse gap é a prova definitiva de Overfitting: alta capacidade de memorização, baixíssima capacidade de generalização.

MÉTRICAS COMPARATIVAS

- **Treino: 1.000** — 100% de acurácia
- **Teste: 0.740** — queda expressiva

A Solução: A Divisão Treino / Teste

O que é a Técnica Hold-Out?

- **1. Particionamento Direto** — Consiste em dividir o conjunto de dados original em partes mutuamente exclusivas (Treino e Teste).
- **2. Divisão Típica (70/30)** — Aloca a maior fatia (70%-80%) para o ajuste de parâmetros e reserva o restante (20%-30%) em sigilo absoluto.
- **3. Simulação de Futuro** — O subconjunto de teste simula dados inéditos do mundo real, avaliando o poder de generalização.

Como Funciona a Divisão Hold-Out?

- **1. O Split Inicial** — O dataset total de 100% é fatiado de forma estanque. O teste é trancado em um “cofre” simbólico.
- **2. Ajuste do Modelo** — O algoritmo aprende padrões olhando apenas para a fatia de treino (X_{train} , y_{train}).
- **3. A “Prova Final”** — Avaliamos o modelo em X_{test} . Comparamos com y_{test} para simular a performance no mundo real.

CÓDIGO

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.30, random_state=42)
```


Cuidados Essenciais ao Fazer o Split

Estratificação

Sem Data Leakage

Reprodutibilidade

Gap Treino vs Teste



Hold-out: vantagens e limites

Aspecto	Vantagens	Limitações
Simplicidade	Rápido de implementar e de baixo custo computacional.	Requer volumes de dados suficientemente grandes.
Clareza	Proporciona uma separação limpa para avaliação inicial.	A métrica pode variar dependendo da divisão estocástica.
Casos de Uso	Ideal para datasets massivos e prototipagem ágil.	Para datasets pequenos, prefira a Validação Cruzada (K-Fold).

PARTE 3

Sobreaajuste e subajuste

Complexidade demais decora; complexidade de menos não aprende. Onde fica o meio?

3

Definições

Sobreajuste (overfitting)

- **Modelo complexo demais** — captura ruído além do padrão.
- **Treino ótimo, teste ruim** — decorou os exemplos.
- **Variância alta** — muda muito conforme o dado.

Subajuste (underfitting)

- **Modelo simples demais** — não captura o padrão real.
- **Treino e teste ruins** — erra até onde já viu.
- **Viés alto** — rígido demais para os dados.

Sinais de sobreajuste

- **Acurácia de treino altíssima** — perto de 1.0, enquanto o teste fica bem abaixo.
- **Diferença crescente** — quanto mais complexo o modelo, maior a distância treino e teste.
- **Instabilidade** — pequenas mudanças no dado mudam muito o modelo.
- **Desempenho piora no novo** — a promessa do treino não se cumpre em produção.

DIAGNÓSTICO

Gap alto

- Treino sobe
- Teste estagna ou cai
- A distância denuncia

Sinais de subajuste

- **Treino já é baixo** — o modelo nem nos dados vistos consegue acertar bem.
- **Teste igualmente baixo** — treino e teste ruins e próximos um do outro.
- **Modelo rígido demais** — poucos parâmetros, profundidade mínima, forte regularização.
- **Solução** — aumentar a complexidade ou usar features mais informativas.

DIAGNÓSTICO

Ambos baixos

- Treino baixo
- Teste baixo
- Falta capacidade

Complexidade do modelo: profundidade da árvore

- **Complexidade** — o quanto o modelo pode se moldar aos dados — quantos padrões consegue expressar.
- **Na árvore de decisão** — a profundidade (`max_depth`) controla a complexidade diretamente.
- **Profundidade baixa** — poucas divisões, regra simples — tende ao subajuste.
- **Profundidade alta** — muitas divisões, uma folha quase por exemplo — tende ao sobreajuste.
- **Ideia geral** — vale para qualquer modelo: há um botão de complexidade a ajustar.

A curva treino e teste

Profundidade	Acurácia treino	Acurácia teste	Gap (treino - teste)
1	0.70	0.68	0.02
2	0.78	0.75	0.03
3	0.84	0.80	0.04
5	0.91	0.83	0.08
8	0.97	0.81	0.16
12	0.995	0.77	0.23
20	1.000	0.74	0.26

- **O gap cresce com a complexidade** — quanto mais fundo, maior a distância entre treino e teste.
- **Início da curva** — treino e teste sobem juntos — o modelo está aprendendo o padrão.
- **Ponto ótimo** — onde o teste é máximo; aqui, profundidade próxima de 5.
- **Depois do ótimo** — o treino continua subindo, mas o teste cai — puro sobreajuste.

ESCOLHA DO MODELO

melhor complexidade = a que maximiza o desempenho no teste

Intuição para guardar

Complexidade de menos

- **Régua reta num padrão curvo** — nunca encaixa direito.
- **Erra sistematicamente** — em treino e em teste.
- **É subajuste** — aumente a capacidade.

Complexidade demais

- **Linha que passa por cada ponto** — inclusive pelo ruído.
- **Perfeito no treino** — péssimo no novo.
- **É sobreajuste** — simplifique o modelo.

PARTE 4

O tradeoff viés e variância

A mesma curva, contada por outro ângulo: o equilíbrio que minimiza o erro.



O que é Viés (Bias)?

Erro de Simplificação

- **Definição Direta** — É a incapacidade do modelo de capturar a verdadeira relação nos dados devido a premissas simplistas demais.

Exemplo & Causa Raiz

- **Exemplo** — Forçar uma Regressão Linear (reta simples) para prever um comportamento altamente parabólico ou cíclico.
- **Diagnóstico** — Modelo “simples demais”. Necessita de maior capacidade, novas features ou menor restrição.

O que é Variância (Variance)?

Sensibilidade Excessiva

- **Definição Direta** — É o quanto a previsão do modelo oscila drasticamente se trocarmos o conjunto de dados de treino.

Exemplo & Causa Raiz

- **Exemplo** — Uma Árvore de Decisão profunda sem limite, que cria regras exclusivas para memorizar até o ruído aleatório.
- **Diagnóstico** — Modelo “complexo demais”. Precisa de regularização, mais dados ou poda (pruning).

A Intuição dos Alvos (Dartboards)

Alto Viés · Baixa Variância

Consistente, mas errado (Underfitting)

Baixo Viés · Alta Variância

Instável / Espalhado (Overfitting)

Alto Viés · Alta Variância

Pior Cenário Possível

Baixo Viés · Baixa Variância

O IDEAL (Ponto Doce)

Decomposição Matemática do Erro

- **1. Reduzir o Viés** — Aumentar a complexidade do modelo reduz o viés, permitindo aprender relações mais ricas.
- **2. Aumentar Variância** — Porém, modelos muito complexos ficam hipersensíveis, fazendo a variância disparar.
- **3. Ruído Irredutível** — Erros inerentes à coleta de dados que nenhum modelo jamais conseguirá eliminar.

Encontrando o Ponto Doce (Sweet Spot)

Como a Complexidade Afeta o Erro — Curva do Tradeoff Viés vs Variância

À medida que adicionamos parâmetros ao modelo, o comportamento das curvas muda drasticamente:

- **Modelo Simples (Poucos Parâmetros)** — Viés Alto | Variância Baixa → Underfitting
- **Modelo Equilibrado (Sweet Spot)** — Soma ($\text{Viés}^2 + \text{Variância}$) atinge o valor MÍNIMO no Teste.
- **Modelo Complexo (Muitos Parâmetros)** — Viés Baixo | Variância Alta → Overfitting

Guia Prático: Como Corrigir Cada Problema

Se você tem Alto Viés (Underfitting):

- **Aumente a complexidade** — Troque regressão linear por polinomial, árvore mais profunda ou rede neural.
- **Crie novas Features** — Combine variáveis (feature engineering) para trazer mais sinal.
- **Reduza a Regularização** — Diminua o parâmetro de penalidade (ex: reduza α no Ridge/Lasso).

Se você tem Alta Variância (Overfitting):

- **Colete mais dados** — Mais amostras ajudam o modelo a filtrar o ruído específico.
- **Aplique Regularização** — Adicione penalidades L1/L2 para encolher coeficientes inflados.
- **Use Métodos Ensemble** — Combine múltiplos modelos (Bagging/Random Forest) para suavizar a variância.

PARTE 5

Vazamento de dados

O erro mais perigoso: o modelo parece excelente e falha na vida real.

5

O que é vazamento (data leakage)

O Conceito

É quando o modelo treina com uma informação que ele não teria na hora de prever de verdade — algo do futuro ou que veio do próprio teste.

O Problema

Em vez de aprender o padrão de verdade, o modelo “cola”: acha um atalho que já entrega a resposta pronta.

O Impacto

As notas ficam ótimas no teste, mas o modelo desanda assim que vai para o uso real.

Por que é o erro mais perigoso

Invisível

Não dá nenhum erro no código. Tudo roda até o fim, sem aviso.

Enganoso

Mostra notas altas no papel e passa a falsa sensação de que deu tudo certo.

Caro

Costuma aparecer só depois que o modelo já está em uso — e joga fora semanas de trabalho.

Comum

É uma cilada comum: pega desde iniciantes até gente experiente.

Tipo A: A “Cola” Direta

Vazamento Óbvio

- **O que é** — usar no treino uma coluna que, na prática, já é a resposta (ou vem direto dela).
- **Exemplo** — prever o preço do jogador usando o “índice de popularidade” — só que esse índice já é calculado a partir do preço. É dar a resposta de brinde.
- **Consequência** — o modelo acerta o valor porque está olhando para o próprio valor disfarçado.
- **Sinal de Alerta** — uma coluna com correlação quase perfeita (perto de 1,0) com o alvo.

Cenário de Experimento	R² (Validação Cruzada)	Correlação com o Alvo	Diagnóstico
COM indice_popularidade	0.82	0.94 (Suspeito)	Ilusão: usa a “cola” e engana o teste.
SEM indice_popularidade	0.45	—	Realidade: desempenho honesto.

Análise do Resultado: o $R^2 = 0,82$ é ilusão, veio do vazamento. Tirando a coluna, o desempenho real cai para 0,45 — esse é o valor honesto.

Tipo B: Contaminação

A Solução Correta (Fluxo Sequencial)

O Erro Frequente

- Fazer o pré-processamento (padronizar, preencher nulos) na base inteira antes de separar treino e teste.

O Efeito Sutil

- Assim o treino já “espia” a média e o desvio do teste, e o teste deixa de ser novidade.

Como Detectar Vazamentos

- **Métricas Suspeitas** — acurácia, AUC ou R^2 altos demais logo na primeira tentativa.
- **Correlação Altíssima** — uma coluna sozinha com peso enorme, ou correlação altíssima com o alvo.
- **Variáveis do “Futuro”** — dados que só passam a existir depois que o evento aconteceu.
- **Salto Abrupto de Desempenho** — um salto grande e estranho de desempenho ao adicionar uma única coluna.

A Regra de Ouro

A PERGUNTA DE OURO

“Eu teria essa informação, desse jeito, na hora de fazer a previsão de verdade?”

- **Se a resposta for NÃO** — tire essa coluna do modelo.
- **Na linha do tempo** — nada que só aparece depois do evento pode entrar no modelo.
- **No código** — nenhuma conta feita sobre o teste pode influenciar o treino.

PARTE 6

O papel de cada conjunto

6

Treino, validação e teste

- **Treino (aprender)** — ajusta os parâmetros do modelo. É a fase de estudo do dia a dia — usado muitas vezes.
- **Validação (escolher)** — define os hiperparâmetros (ex.: profundidade da árvore) e escolhe o melhor modelo.
- **Teste (julgar)** — a medição final, honesta e sem filtro. Usado uma única vez, no encerramento.

TRÊS PAPÉIS

Cada um

- Treino: aprender
- Validação: escolher
- Teste: julgar

Por que o teste fica intocável

- **Simula o mundo real** — representa os dados novos que o modelo só vai ver quando estiver em uso.
- **Evita a contaminação** — decidir com base no teste faz o modelo "decorar" o gabarito.
- **Otimismo ilusório** — cada olhada no teste destrói a imparcialidade da sua métrica.

DISCIPLINA

Uma vez só

- Não espie
- Não ajuste pelo teste
- Reporte no fim

O fluxo de trabalho

- **1. Separe o teste primeiro** — esconda essa fatia dos dados antes de qualquer coisa.
- **2. Trabalhe no treino e na validação** — teste diferentes algoritmos e ajuste os parâmetros aqui.
- **3. Escolha o campeão** — use a validação (ou validação cruzada) para selecionar o melhor modelo.
- **4. Avaliação final** — rode o modelo campeão uma única vez no conjunto de teste.
- **5. Reporte a verdade** — o resultado do teste é o desempenho real que você deve apresentar.

Prévia: validação cruzada

- **O problema da divisão única** — um hold-out simples pode te dar sorte ou azar, dependendo de como os dados caíram.
- **Validação cruzada (k-fold)** — o treino é dividido em k partes, revezando quem é a validação da vez.
- **Resultado estável** — a média das k medições dá uma estimativa bem mais confiável.
- **Na prática** — no scikit-learn, isso é uma linha de código só.

POR QUE USAR

Estável

- Menos dependente do sorteio
- Aproveita mais dados
- Detalhes na Aula 5

Resumo: os três conjuntos

Conjunto	Para que serve	Quantas vezes é usado
Treino	Ajustar os parâmetros do modelo	Muitas vezes
Validação	Escolher o modelo e ajustar hiperparâmetros	Várias vezes
Teste	Obter a estimativa final e honesta	Uma só vez (no fim)

A METÁFORA DA PROVA

Treino = estudo diário · **Validação** = simulado · **Teste** = prova final oficial

Regra prática: só o teste vira o número que você reporta — e ele é intocável até lá.

PARTE 7

Erros comuns e boas práticas

Um checklist para não cair nas armadilhas mais frequentes.



Erros comuns

- **Avaliar no treino** — reportar acurácia de treino como se fosse desempenho real.
- **Não estratificar** — deixar uma classe sub-representada num dos lados.
- **Pré-processar antes de separar** — o vazamento sutil do scaler ou do imputador.
- **Espiar o teste** — ajustar decisões olhando o conjunto que deveria ser intocável.
- **Ignorar features suspeitas** — manter colunas que vazam o alvo por descuido.

Boas práticas

- **Separe o teste primeiro** — antes de qualquer transformação nos dados.
- **Estratifique e fixe a semente** — use stratify e random_state para experimentos reproduzíveis.
- **Monitore as curvas de aprendizado** — compare treino e teste para achar sobreajuste ou subajuste.
- **Pré-processamento isolado** — ajuste scaler/imputer só no treino — use Pipeline.
- **Audite suas features** — a pergunta de ouro: "eu teria essa informação na hora da previsão?"

Checklist antivazamento

Antes de treinar (preparação)

- Teste separado e guardado no "cofre".
- Features auditadas ("terei esse dado na hora da previsão?").
- Correlações checadas (nada colado demais no alvo).

Ao avaliar (validação / teste)

- Scalers e imputadores ajustados só no treino.
- Conjunto de teste tocado uma única vez.
- Resultado plausível (desconfie de acurácia 99,9%).

PARTE 8

Preparação para o laboratório

Cada conceito de hoje vira um exercício em pandas e scikit-learn.



Visão geral do laboratório

- **Ferramentas** — pandas, numpy, matplotlib e scikit-learn.
- **Dados de pacientes** — 1_pacientes.csv — risco metabólico (classificação).
- **Dados de jogadores** — 3_jogadores.csv — valor de mercado no futebol (regressão).
- **Objetivo** — ver, na prática, os quatro pilares vistos na teoria de hoje.

MAPA DO LAB

6 partes

- Treino e teste
- Complexidade
- Viés e variância
- Vazamento (2 tipos)

Referências

- **CASTRO, L. N. de** — Introdução à mineração de dados. São Paulo: Saraiva, 2016.
- **FERREIRA, R. G. C. et al.** — Preparação e análise exploratória de dados. Porto Alegre: Sagah, 2021.
- **SUD, K.; ERDOGMUS, P.; KADRY, S.** — Introduction to Data Science and Machine Learning. London: IntechOpen, 2020.

Bibliografia da disciplina Consultoria Especializada em Ciência de Dados 1.