

CONSULTORIA ESPECIALIZADA EM CIÊNCIA DE DADOS 1

Métricas de classificação I

Matriz de confusão, acurácia, precisão, recall, F1 e classes desbalanceadas

Aula 02 · 11/08/2026

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R ² , resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	Projeto: dados
9 — 29/09	Busca aleatória e menção a AutoML	

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 06/10	Curvas de validação	Desafio 3 (subst.)
11 — 13/10	Curvas de aprendizado	
12 — 20/10	Seleção e comparação de modelos	
13 — 27/10	Limiar de decisão e calibração	
14 — 03/11	Target Leakage e reprodutibilidade	
15 — 10/11	Seleção de atributos	
16 — 17/11	Estudo de caso integrado	
17 — 24/11	Comunicação e reprodutibilidade dos resultados	Desafio 6 (subst.)
18 — 01/12	Revisão integrada e apresentações	Apresentação final

Objetivo da aula

O objetivo da aula é entender **como avaliar um modelo de classificação** — decidir se ele é bom, e com qual número. Faremos isso partindo da **matriz de confusão** e entendendo as **principais métricas**.

O CAMINHO DE HOJE

- **Matriz de confusão** — VP, VN, FP, FN — a base de onde tudo sai.
- **Acurácia** — a métrica mais citada, e onde ela engana.
- **Precisão, recall e F1** — o que cada número realmente responde.
- **Desbalanceamento e custo do erro** — escolher a métrica pelo erro que dói mais.

CASO DE ESTUDO

- **Exemplo** — triagem de risco metabólico (dataset de pacientes).
- **Outros domínios** — fraude, spam, recomendação — aparecem ao longo da aula.
- Servem só para ilustrar as métricas.

Ponte da Aula 1 (treino e teste, sobreajuste, vazamento) para a Aula 2: agora, como pontuar o modelo.

Roteiro da aula

Fundamentos

- **Parte 1** — a matriz de confusão (VP, VN, FP, FN).
- **Parte 2** — acurácia: fórmula e quando engana.
- **Parte 3** — precisão, recall e o trade-off.
- **Parte 4** — F1 e F-beta: um número, com honestidade.

Uso na prática

- **Parte 5** — a armadilha da acurácia (o dummy).
- **Parte 6** — escolher a métrica pelo custo do erro.
- **Parte 7** — classification_report e boas práticas.
- **Parte 8** — preparação para o laboratório.

PARTE 1

A matriz de confusão

Onde toda avaliação de classificação começa: cruzar a verdade com a previsão.

1

Avaliar é comparar previsão e verdade

Avaliar um classificador é comparar, para cada exemplo, **o que o modelo previu com o que era verdade.**

- **Classe positiva (1)** — o evento de interesse — a classe que se quer detectar.
- **Classe negativa (0)** — todo o resto.
- **Por que um número não basta** — acertar "no geral" pode esconder erros graves em uma das classes — por isso olhamos caixa a caixa.

As quatro caixas: VP, VN, FP, FN

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo


Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

Toda métrica de classificação nasce dessas quatro caixas.

O alvo: quem é “alto risco”?

Neste caso de estudo, “alto risco” é a **classe que se quer detectar**. O alvo vem de transformar o **risco metabólico** (baixo / moderado / alto) em um **sim ou não**.

- **O que indica** — marcadores como glicemia, HbA1c, IMC, circunferência abdominal e pressão.
- **Como se define** — alto_risco = 1 só para a categoria “alto”; baixo e moderado = 0.
- **Classe rara** — 128 de 850 (~15%): a classe de interesse é a minoria.



Deixar passar um alto risco (FN) costuma ser o erro mais grave em triagens como essa.

Exemplo numérico: a matriz de uma árvore

	Previu alto	Previu não alto
Verdade: alto (38)	16 VP — alto detectado	22 FN — alto liberado
Verdade: não alto (217)	12 FP — falso alarme	205 VN — não alto correto

$255 \text{ do teste} = 38 \text{ alto} + 217 \text{ não alto (baixo/moderado)} \cdot \text{acertos } 205 + 16 = 221$

Teste = 30% dos 850, estratificado: 38 de alto risco e 217 de baixo/moderado (não alto). Acurácia = $221/255 = 0,867$.

PARTE 2

Acurácia

A métrica mais citada — e a mais fácil de interpretar mal.

Acurácia: o que é e como se calcula

ACURÁCIA


$$(VP + VN) / (VP + VN + FP + FN)$$

- **A pergunta** — de todos os exemplos, que fração o modelo classificou corretamente?
- **Numerador** — os acertos — a diagonal da matriz de confusão (VP + VN).
- **Denominador** — o total de exemplos avaliados.
- **No exemplo** — $(205 + 16) / 255 = 221 / 255 = 0,867$.

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

Quando a acurácia ajuda — e quando engana



A acurácia é confiável quando as classes têm **tamanho parecido** e os dois erros **custam igual**. Ela engana quando **uma classe é rara**.

Confie quando

- **Classes equilibradas** — tamanhos parecidos (ex.: 50/50).
- **Erros simétricos** — errar para um lado custa como para o outro.

Desconfie quando

- **Uma classe domina** — com 85% de uma classe, acertar a maioria já garante ~85%.
- **O raro é o que importa** — a acurácia dilui o desempenho na classe rara.

PARTE 3

Precisão, recall e o trade-off


Duas perguntas diferentes sobre a mesma classe positiva.

3

Precisão vs. recall: duas perguntas

	Previu alto	Previu não alto
Verdade: alto (38)	16 VP — alto detectado	22 FN — alto liberado
Verdade: não alto (217)	12 FP — falso alarme	205 VN — não alto correto

255 do teste = 38 alto + 217 não alto (baixo/moderado) · acertos 205+16 = 221



Mesma interseção (VP); muda apenas o denominador — o que marquei (precisão) ou o que era real (recall).

Precisão: das que sinalizei, quantas eram?

PRECISÃO

$$VP / (VP + FP)$$

- **A pergunta** — dos exemplos que o modelo marcou como positivos, quantos eram mesmo positivos?
- **Penaliza o FP** — cada falso alarme derruba a precisão.
- **No exemplo** — $16 / (16 + 12) = 16 / 28 = 0,571$ — dos 28 marcados, 16 eram de alto risco.

Recall: das que eram, quantas peguei?

RECALL (SENSIBILIDADE)

$$VP / (VP + FN)$$

- **A pergunta** — dos positivos reais, quantos o modelo conseguiu capturar?
- **Penaliza o FN** — cada doente liberado derruba o recall — a métrica-chave em triagens.
- **No exemplo** — $16 / (16 + 22) = 16 / 38 = 0,421$ — pegou menos da metade dos doentes.

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

ESPECIFICIDADE


- **VN / (VN + FP)** — o recall da classe negativa.
- No exemplo: $205 / 217 = 0,945$.

O trade-off precisão e recall

O modelo dá uma probabilidade; o **limiar** é o corte que a vira em decisão. Movê-lo **troca recall por precisão** — não dá para maximizar os dois ao mesmo tempo.

	Previu alto	Previu não alto
Verdade: alto (38)	16 VP — alto detectado	22 FN — alto liberado
Verdade: não alto (217)	12 FP — falso alarme	205 VN — não alto correto

255 do teste = 38 alto + 217 não alto (baixo/moderado) · acertos 205+16 = 221



Com o limiar no centro (simétrico), FN = FP e recall = precisão; ao movê-lo, um sobe e o outro cai.

Ajustar o limiar — na validação

Escolher o limiar é uma decisão: faz-se na validação. O teste só mede, uma vez, no fim.

```
# 1) escolher o limiar na VALIDACAO
proba = modelo.predict_proba(X_val)[:, 1]
for limiar in [0.3, 0.4, 0.5, 0.6]:
    y_pred = (proba >= limiar).astype(int)
    ...    # compara recall/precisao e escolhe o melhor

# 2) medir UMA vez no teste, com o limiar escolhido
proba = modelo.predict_proba(X_test)[:, 1]
y_pred = (proba >= limiar).astype(int)
```

- **`predict_proba(X_val)[:, 1]`** — a probabilidade de ser positivo, na validação — é onde se decide.
- **`for limiar in [...]`** — testa vários cortes e escolhe o que melhor equilibra recall e precisão.
- **no teste, uma vez** — com o limiar já fixado, mede o desempenho final e honesto.

Regra da Aula 1: ajustar o limiar é decisão, então vai na validação; o teste é tocado uma única vez.

Qual erro dói mais define a métrica

FN caro: priorize o recall

- **Regra** — quando perder um positivo é o pior desfecho, maximize o recall.
- **Aceite mais FP** — melhor um exame extra do que um doente liberado.
- **Exemplo** — triagem de doença, detecção de fraude.

FP caro: priorize a precisão

- **Regra** — quando o falso alarme é caro ou daninho, maximize a precisão.
- **Aceite mais FN** — perder um email bom no lixo custa caro.
- **Exemplo** — filtro de spam, bloqueio de conta.

PARTE 4

F1 e F-beta

Como resumir precisão e recall em um único número — com honestidade.




F1: a média harmônica de precisão e recall

F1

$$2 \cdot (\text{Precisão} \cdot \text{Recall}) / (\text{Precisão} + \text{Recall})$$

- **Por que combinar** — comparar modelos por dois eixos é incômodo; o F1 resume em um número.
- **Média harmônica** — sempre menor ou igual à aritmética; dominada pelo menor dos dois.



F1 no exemplo e o F-beta

F1 NO EXEMPLO

$$2 \cdot (0,571 \cdot 0,421) / (0,571 + 0,421) = 0,485$$

F-BETA

$$F_{\beta} = (1 + \beta^2) \cdot (P \cdot R) / (\beta^2 \cdot P + R)$$

- O parâmetro β — controla o peso do recall em relação à precisão.
- $\beta = 1$ — é o próprio F1 (peso igual).
- $\beta > 1$ (ex.: F2) — valoriza o recall — indicado quando o FN é o erro caro.

QUANDO USAR

- F1 — precisão e recall importam igual.
- F-beta — um dos dois pesa mais.

PARTE 5

A armadilha da acurácia

O classificador burro que acerta 85% e não serve para nada.

5


Classes desbalanceadas

Quando a classe que importa é **rara**, dá para acertar **85% sem aprender nada** — só chutando a maioria.

- **O que é** — a classe positiva é bem mais rara que a negativa (neste exemplo, ~15% de alto risco).
- **Onde aparece** — fraude, doença, defeito — o evento raro é justamente o que interessa.
- **O risco** — a acurácia é dominada pela classe grande e infla, escondendo a classe rara.

O dummy que acerta 85%

O **dummy** é um modelo que não aprende nada: sempre chuta a classe maioritária (baixo risco). Serve de **piso de comparação**.



$$\frac{VP + VN}{VP + VN + FP + FN}$$

$$\frac{VP}{VP + FN}$$

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

Dummy: acurácia 0,851 e recall 0,000. Árvore: 0,867 e 0,421. A acurácia mal os distingue; o recall os separa.

PARTE 6

Lendo o relatório e boas práticas

6

O relatório vem de uma linha de código

Em vez de calcular métrica por métrica, o scikit-learn imprime todas de uma vez.

```
from sklearn.metrics import classification_report

# y_test = verdade | y_pred = previsoes no teste
print(classification_report(y_test, y_pred))
```

- **classification_report(y_test, y_pred)** — compara verdade e previsão e devolve precisão, recall, F1 e suporte de cada classe, de uma vez.
- **print(...)** — imprime o relatório em texto — é exatamente a tabela do próximo slide.

A saída é o relatório do próximo slide — todos os números saem da mesma matriz de confusão.

O classification_report

A tabela abaixo é a saída de `print(classification_report(y_test, y_pred))`.

	precision	recall	f1-score	support
baixo (0)	0,90	0,94	0,92	217
alto (1)	0,57	0,42	0,49	38
accuracy			0,87	255
macro avg	0,74	0,68	0,70	255
weighted avg	0,85	0,87	0,86	255

- **Uma linha por classe** — a linha alto (1) é a classe rara — F1 = 0,49 revela a fraqueza.
- **macro avg** — média simples entre classes (cada classe pesa igual — dá voz à rara).
- **weighted avg** — ponderada pelo support (a classe grande pesa mais; aproxima-se da acurácia).

O detalhe das médias e o caso multiclasse ficam para a Aula 3.

