

CONSULTORIA ESPECIALIZADA EM CIÊNCIA DE DADOS 1

Métricas de classificação II

Curvas ROC e PR, AUC, log-loss

Aula 03 · 18/08/2026

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R ² , resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	Projeto: dados
9 — 29/09	Busca aleatória e menção a AutoML	

Objetivo da aula

Na Aula 2, escolhíamos **um limiar** específico que valorizava a métrica que queríamos. Hoje vamos avaliar o modelo em **todos os limiares de uma vez** — usando um **filtro de spam** como exemplo do começo ao fim.

O CAMINHO DE HOJE

- **Primeiro, a ideia** — nota, ordenar, corte e erros — no filtro de spam, sem matemática.
- **ROC e AUC** — o modelo ordena bem, sem depender de um corte?
- **PR e AP** — quando o 'sim' é raro, a visão honesta.
- **Log-loss** — a nota é confiável?

O EXEMPLO DE HOJE

- **Filtro de spam** — o modelo dá a cada e-mail uma nota de 'chance de ser spam'.
- **A teoria vale para tudo** — doença, fraude, crédito — muda só o nome.

Ponte da Aula 2: lá medíamos em um corte; aqui, o modelo em todos os cortes.

PARTE 1


Primeiro, sem matemática

Um filtro de spam para entender a ideia toda.




O modelo dá uma nota a cada caso

Um filtro de spam olha cada e-mail e devolve uma **nota de 0 a 100**: quanto maior, mais ele acha que é spam. **Todo modelo faz isso — dá uma nota de 'quão provável é o sim'.**



Repare: a nota ainda não é a decisão — é só o quanto o modelo suspeita de cada e-mail.

Para que serve a nota: ordenar os casos



A nota vira decisão quando escolhemos um **corte (limiar)**: acima dele, vai para o spam; abaixo, fica na caixa de entrada.

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

Então, duas perguntas diferentes

Com a nota em mãos, saem **duas perguntas independentes** — e cada uma tem suas métricas:

1. A nota ordena bem os casos?

- **A pergunta** — os positivos recebem nota maior que os negativos?
- **Independente do corte** — é a qualidade do ranking, antes de decidir 0 ou 1.
- **Métricas** — curva ROC / AUC e curva PR / AP — o foco de hoje.

2. No corte, a decisão acerta?

- **A pergunta** — fixado um limiar, quantos acertos e erros a decisão dá?
- **Depende do corte** — muda conforme o limiar escolhido (Aula 2).
- **Métricas** — precisão, recall e F1.

Um modelo pode ordenar muito bem (AUC alta) e ainda decidir mal num corte ruim — por isso medimos as duas coisas separadamente.

PARTE 2

Curva ROC e AUC

Recall contra falso alarme, varrendo todos os limiares.

2

ROC — definição, fórmula e exemplo

$$\text{PRECISÃO} \\ \text{VP} / (\text{VP} + \text{FP})$$

$$\text{RECALL (SENSIBILIDADE)} \\ \text{VP} / (\text{VP} + \text{FN})$$

CURVA ROC


eixo Y: TPR (recall) = $\text{VP} / (\text{VP} + \text{FN})$
eixo X: FPR (falso alarme) = $\text{FP} / (\text{FP} + \text{VN})$

- **Para que serve** — ver se o filtro ORDENA bem (spams com nota maior que e-mails bons), sem depender de um corte.
- **A curva** — recall (spams pegos) no eixo Y contra o falso alarme (bons barrados) no eixo X, variando o corte de 100 até 0.
- **Exemplo** — um filtro aleatório fica na diagonal; um bom filtro sobe rápido antes de começar a barrar e-mails bons.

	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

A curva ROC



Cada limiar vira um ponto (recall × falso alarme); ligando todos, temos a ROC. A área sob ela é a AUC.

AUC — definição, fórmula e exemplo

AUC (ÁREA SOB A ROC)

0,5 = acaso · 1,0 = ordenação perfeita

- **Para que serve** — resumir num único número quão bem o filtro ordena — ótimo para comparar dois filtros.
- **Conceito** — é a chance de um spam receber nota maior que um e-mail bom, sorteados ao acaso. Independe do corte.
- **Exemplo** — AUC = 0,80: em 80% dos pares (1 spam, 1 e-mail bom), o spam recebe a nota maior.

Forças e limites da ROC

Forças

- Resume todos os limiares em um número.
- Independe do limiar escolhido.
- Boa para comparar e ordenar modelos.

Limites

- Fica otimista quando o positivo é muito raro.
- Não diz qual limiar usar na prática.
- Para classe rara, prefira a curva PR.

PARTE 3

Curva Precisão-Recall

Quando o positivo é raro, olhe precisão contra recall.


3

Curva PR e AP — definição, fórmula e exemplo

CURVA PRECISÃO-RECALL

$\text{precisão} = \text{VP} / (\text{VP} + \text{FP})$ vs $\text{recall} = \text{VP} / (\text{VP} + \text{FN})$
AP (average precision) = área sob a curva PR

- **Para que serve** — focar em acertar os spams sem barrar e-mails bons — melhor que a ROC quando o spam é raro.
- **A curva** — precisão (acerto dos alarmes) contra recall (cobertura dos spams), variando o corte; a AP é a área.




	Previu Positivo (1)	Previu Negativo (0)
Verdade Positivo (1)	VP era positivo e previu positivo	FN era positivo, mas previu negativo
Verdade Negativo (0)	FP era negativo, mas previu positivo	VN era negativo e previu negativo

Diagonal = acertos (VP, VN) · fora da diagonal = erros (FP, FN)

ROC otimista, PR honesta

Mesmo modelo, classe rara: a ROC infla; a PR mostra a dificuldade real



Com classe rara há muitos negativos fáceis, que inflam a ROC. A PR foca em acertar os raros — prefira-a nesse caso.

PARTE 4

Log-loss: a qualidade da probabilidade



Não basta ordenar; às vezes a probabilidade precisa ser confiável.


Log-loss — definição, fórmula e exemplo

LOG-LOSS (UMA AMOSTRA)

$$- [y \cdot \log(p) + (1 - y) \cdot \log(1 - p)] \quad \cdot \quad \text{menor é melhor}$$

- **Para que serve** — checar se a NOTA é confiável: quando o filtro diz '95% spam', é mesmo perto de 95%? (p = nota; y = verdade).
- **Conceito** — pune o erro confiante — marcar um e-mail bom com nota altíssima e errar custa muito.
- **Exemplo** — era spam: se o filtro deu $p = 0,9 \rightarrow -\log(0,9) = 0,11$ (ótimo); se deu $p = 0,1 \rightarrow -\log(0,1) = 2,30$ (péssimo).

A penalidade cresce depressa



Errar com certeza (probabilidade baixa na classe certa) custa muito; acertar com confiança custa quase nada. Base de comparação: prever sempre a prevalência.

PARTE 6

Escolher a métrica pela pergunta

Cada objetivo pede uma métrica diferente.

6

Qual é o seu objetivo?

O que você quer	Métrica indicada
Ordenar / comparar modelos (sem limiar fixo)	AUC (ROC)
Achar os positivos raros e caros	AP (PR) e recall
Probabilidade confiável (calibrada)	Log-loss

Comece sempre pela pergunta; a métrica é uma decisão, não um padrão.

