

CIÊNCIA DE DADOS 1 · AULA 03 — REVISÃO

Métricas de classificação II

ROC, AUC, Precisão-Recall, AP e log-loss — quiz e os conceitos em código

Revisão · Aula 03

Questão 1

O que o filtro de spam entrega para cada e-mail, ANTES de decidir?

- A)** A decisão final: spam ou não spam.
- B)** Uma nota (probabilidade) de quão provável é ser spam.
- C)** A pasta onde o e-mail será arquivado.
- D)** O número de palavras suspeitas no texto.

Questão 1 — resposta

O que o filtro de spam entrega para cada e-mail, ANTES de decidir?

- A) A decisão final: spam ou não spam.
- B) Uma nota (probabilidade) de quão provável é ser spam. ✓**
- C) A pasta onde o e-mail será arquivado.
- D) O número de palavras suspeitas no texto.

Questão 2

Dizer que "o modelo ordena bem" significa que:

- A)** Os spams recebem nota maior que os e-mails bons.
- B)** Todos os spams recebem nota acima de 50.
- C)** O modelo acerta 100% dos casos.
- D)** Os e-mails ficam em ordem alfabética.

Questão 2 — resposta

Dizer que "o modelo ordena bem" significa que:

- A) Os spams recebem nota maior que os e-mails bons. ✓**
- B) Todos os spams recebem nota acima de 50.
- C) O modelo acerta 100% dos casos.
- D) Os e-mails ficam em ordem alfabética.

Questão 3

Baixar o limiar (marcar mais e-mails como spam) tende a:

- A)** Reduzir o recall e aumentar a precisão.
- B)** Aumentar o recall e reduzir a precisão.
- C)** Aumentar o recall e a precisão juntos.
- D)** Não mudar o recall nem a precisão.

Questão 3 — resposta

Baixar o limiar (marcar mais e-mails como spam) tende a:

- A) Reduzir o recall e aumentar a precisão.
- B) Aumentar o recall e reduzir a precisão. ✓**
- C) Aumentar o recall e a precisão juntos.
- D) Não mudar o recall nem a precisão.

Por que baixar o limiar sobe o recall e desce a precisão

Notas de spam de 10 e-mails: **4 spams e 6 bons**. Marcamos como spam quem fica **acima do limiar**. Spams: 0,90 · 0,80 · 0,60 · 0,40 | Bons: 0,50 · 0,45 · 0,30 · 0,20 · 0,10 · 0,05

Limiar	Marcados como spam	Recall (pegou os spams)	Precisão (acertou o alarme)
0,70 (exigente)	2 (só 0,90 e 0,80)	$2/4 = 0,50$	$2/2 = 1,00$
0,35 (baixo)	6 (os 4 spams + 2 bons)	$4/4 = 1,00$	$4/6 = 0,67$

Baixar o limiar = ser menos exigente → marca mais e-mails: pega TODOS os spams (recall 0,50 → 1,00), mas joga 2 bons no spam (precisão 1,00 → 0,67). Recall e precisão andam em sentidos opostos — é o trade-off da Aula 2.

Questão 4

No filtro de spam, um Falso Positivo (FP) é:

- A)** Um spam que passou para a caixa de entrada.
- B)** Um spam corretamente detectado.
- C)** Um e-mail bom que foi jogado no spam.
- D)** Um e-mail bom que ficou na caixa de entrada.

Questão 4 — resposta

No filtro de spam, um Falso Positivo (FP) é:

- A) Um spam que passou para a caixa de entrada.
- B) Um spam corretamente detectado.
- C) **Um e-mail bom que foi jogado no spam. ✓**
- D) Um e-mail bom que ficou na caixa de entrada.

Questão 5

Uma AUC = 0,5 indica que o modelo:

- A)** É perfeito.
- B)** Acerta metade das previsões.
- C)** Tem precisão de 50%.
- D)** Não ordena melhor que o acaso (uma moeda).

Questão 5 — resposta

Uma AUC = 0,5 indica que o modelo:

- A) É perfeito.
- B) Acerta metade das previsões.
- C) Tem precisão de 50%.
- D) **Não ordena melhor que o acaso (uma moeda).** ✓

Questão 6

A curva ROC coloca, ao variar o corte:

- A)** Recall (acerto nos positivos) contra o falso alarme.
- B)** Precisão contra recall.
- C)** Acurácia contra o limiar.
- D)** Log-loss contra a AUC.

Questão 6 — resposta

A curva ROC coloca, ao variar o corte:

- A) Recall (acerto nos positivos) contra o falso alarme. ✓**
- B) Precisão contra recall.
- C) Acurácia contra o limiar.
- D) Log-loss contra a AUC.

Questão 7

Quando a classe positiva é RARA, qual visão é mais honesta?

- A)** A curva ROC e a AUC.
- B)** A acurácia.
- C)** A curva PR (precisão-recall) e a AP.
- D)** O log-loss apenas.

Questão 7 — resposta

Quando a classe positiva é RARA, qual visão é mais honesta?

- A) A curva ROC e a AUC.
- B) A acurácia.
- C) **A curva PR (precisão-recall) e a AP.** ✓
- D) O log-loss apenas.

Questão 8

O log-loss serve principalmente para:

- A)** Contar quantos acertos o modelo teve.
- B)** Medir se a nota (probabilidade) é confiável, punindo o erro confiante.
- C)** Ordenar os e-mails por tamanho.
- D)** Escolher o limiar ótimo automaticamente.

Questão 8 — resposta

O log-loss serve principalmente para:

- A) Contar quantos acertos o modelo teve.
- B) Medir se a nota (probabilidade) é confiável, punindo o erro confiante. ✓**
- C) Ordenar os e-mails por tamanho.
- D) Escolher o limiar ótimo automaticamente.

REVISÃO 2

Os conceitos no Python

Código pronto para copiar (scikit-learn).

2

A nota do modelo e o limiar (ligação com a Aula 2)

Todo classificador dá uma **nota (probabilidade)**; o **limiar** a transforma em decisão.

```
from sklearn.linear_model import LogisticRegression
modelo = LogisticRegression(max_iter=1000).fit(X_train, y_train)
proba = modelo.predict_proba(X_test)[:, 1] # nota da classe positiva
pred = (proba >= 0.5).astype(int) # decisão no limiar 0,5
```

Matriz de confusão, precisão e recall (Aula 2)

```
from sklearn.metrics import confusion_matrix, precision_score, recall_score
print(confusion_matrix(y_test, pred))          # [[TN, FP], [FN, TP]]
print("precisão:", precision_score(y_test, pred))
print("recall:  ", recall_score(y_test, pred))
# mudar o 0.5 por 0.3 ou 0.7 move o trade-off recall x precisão
```

ROC e AUC — o modelo ordena bem, sem depender do corte

```
from sklearn.metrics import roc_curve, roc_auc_score
fpr, tpr, limiares = roc_curve(y_test, proba) # falso alarme x recall
auc = roc_auc_score(y_test, proba)
print("AUC:", round(auc, 3))                # 0,5 = acaso; 1,0 = perfeito
```

AUC = probabilidade de o modelo dar nota maior a um positivo do que a um negativo sorteados ao acaso.

Precisão-Recall e AP — a visão honesta quando o positivo é raro

```
from sklearn.metrics import precision_recall_curve, average_precision_score
prec, rec, limiares = precision_recall_curve(y_test, proba)
ap = average_precision_score(y_test, proba)
print("AP:", round(ap, 3))                # área sob a curva PR
```

Com pouquíssimos positivos, a ROC pode parecer ótima; a curva PR mostra o custo real dos falsos positivos.

Log-loss — a nota é confiável?

```
from sklearn.metrics import log_loss
print("log-loss:", round(log_loss(y_test, proba), 3))
# quanto MENOR, melhor: probabilidades mais confiáveis
# ele pune com força o erro CONFIANTE (dizer 0,99 e errar)
```


Escolher o limiar pelo objetivo do negócio

Ex.: eu **exijo recall $\geq 0,90$** (quase não deixar spam passar). Qual limiar usar?

```
import numpy as np
prec, rec, limiares = precision_recall_curve(y_test, proba)
ok = rec[:-1] >= 0.90          # limiares que garantem recall >= 0,90
limiar = limiares[ok].max()    # o mais alto (mais preciso) entre eles
print("limiar escolhido:", round(limiar, 3))
```

Qual métrica para qual pergunta

A pergunta	A métrica
O modelo ordena bem, sem fixar um corte?	ROC e AUC
O positivo é raro — qual o custo real?	curva PR e AP
As probabilidades são confiáveis?	log-loss
Já tenho um corte — quantos acertos/erros?	matriz de confusão, precisão, recall

Reporte quase sempre um par: uma métrica de ranqueamento (AUC/AP) + uma no limiar escolhido (precisão/recall).