

CIÊNCIA DE DADOS 1 · AULA 04 — REVISÃO

Métricas de regressão

Revisão · Aula 04

REVISÃO 1

Os conceitos da aula

Erro, MAE, RMSE, R^2 e MAPE.

1

Erro (resíduo): a base de tudo

ERRO

$$\text{erro} = \text{valor real} - \text{valor previsto}$$

- **O sinal** — positivo = o modelo subestimou (real acima); negativo = superestimou.
- **Por que ao quadrado / módulo** — para os erros não se cancelarem ao somar (positivos com negativos).
- **As métricas** — MAE, RMSE, R^2 e MAPE são formas diferentes de RESUMIR esses erros num número.

MAE e RMSE — o erro na unidade do alvo

MAE / RMSE

$$\text{MAE} = \text{média de } |\text{erro}| \quad \cdot \quad \text{RMSE} = \sqrt{\text{média de erro}^2}$$

- **MAE** — o erro típico, lido direto na unidade: 'em média erramos X'. Ex.: erros 5,3,2,6,44 → MAE = 12.
- **RMSE** — eleva ao quadrado antes de somar → pune com força o erro grande. Mesmos erros → RMSE ≈ 20.
- **RMSE ≥ MAE** — quanto maior a diferença entre eles, mais há erros fora do padrão (outliers).

R^2 — o placar até 1 (pode ser negativo)

R^2 (COEFICIENTE DE DETERMINAÇÃO)

$$R^2 = 1 - (\text{soma dos erros}^2 \text{ do modelo}) \div (\text{soma dos desvios}^2 \text{ da média})$$

- **O que é** — a fração da variância do alvo que o modelo explica. 1 = perfeito; 0 = igual a prever a média.
- **Pode ser NEGATIVO** — quando o modelo é pior que prever a média (a soma dos erros² supera a variância).
- **A 'soma dos desvios² da média'** — é a VARIÂNCIA do alvo — o quanto os valores reais variam entre si.

Reforço das questões 4, 5 e 9 do formulário.

Existe 'um R^2 do erro' e 'outro do Pearson'?

Não. O R^2 é **sempre o coeficiente de determinação**: a fração da variância do alvo que o modelo explica. Avaliar o modelo (Aula 4) e o 'coeficiente de determinação' são **a mesma coisa**.

R^2

$$R^2 = 1 - (\text{soma dos erros}^2 \text{ do modelo}) \div (\text{soma dos desvios}^2 \text{ da média}) = 1 - SS_{\text{res}} \div SS_{\text{tot}}$$

- **Usa os resíduos** — depende do MODELO: entra a soma dos erros² das previsões.
- **Faixa** — no máximo 1; pode ser negativo (modelo pior que a média).

O coeficiente de Pearson e a ponte com o R^2

COEFICIENTE DE PEARSON (R)

$$r = \text{covariância}(X, Y) \div (\text{desvio de } X \times \text{desvio de } Y) \quad \cdot \quad r \text{ vai de } -1 \text{ a } 1$$

- **O que o Pearson mede** — a força e a direção da relação LINEAR entre DUAS variáveis — não depende de modelo nenhum.
- **A ponte** — na regressão linear SIMPLES (1 preditor, mínimos quadrados), $R^2 = r^2$ — o R^2 do modelo é o quadrado do Pearson entre x e y .
- **Caso geral** — para qualquer regressão por mínimos quadrados, $R^2 = [\text{Pearson entre } o \text{ y real e o } \hat{y} \text{ previsto}]^2$.

Diferenças e cuidados

$$r = \frac{\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N}}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{N}} \cdot \sqrt{\frac{\sum (y_i - \bar{y})^2}{N}}}$$

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

	Pearson r (→ r²)	R² (determinação)
Mede	relação linear entre 2 variáveis	quanto da variância de y o modelo explica
Conta	cov(X,Y) ÷ (desvioX × desvioY)	1 – SSres ÷ SStot (usa os resíduos)
Faixa	r: -1 a 1 (r²: 0 a 1)	≤ 1, pode ser NEGATIVO
Depende do modelo?	não — só das 2 variáveis	sim — usa as previsões
Quando coincidem	—	regressão simples: R² = r²(x, y)

Exemplo: os dois dão o mesmo número

Mesmos dados $X = (1, 2, 3, 4, 5)$ e $Y = (2, 5, 6, 8, 9)$.

Cálculo	Resultado
Pearson $r(X, Y)$	0,98
$r^2 = 0,98^2$	0,96
R^2 da regressão linear de Y em X	0,96
Se o modelo fosse ruim ($Y=(3,3,3,3,3)$): R^2	-1,5

Na regressão simples, $R^2 = r^2$ (0,96). Mas troque por um modelo ruim e o R^2 despenca para -1,5, enquanto o Pearson entre X e Y continua 0,98 — porque r mede a **RELAÇÃO** das variáveis, e o R^2 mede a **qualidade do MODELO**.

MAPE — o erro em porcentagem (e a armadilha)

MAPE

$$\text{MAPE} = \text{média de } (|\text{erro}| \div \text{valor real}) \times 100\%$$

- **Para que serve** — o erro em %, que não depende do tamanho do alvo: 'erramos, em média, 15%'.
- **A armadilha (questão 7)** — divide pelo valor real — quando ele é perto de ZERO, o % explode (errar 5 sobre 5 = 100%).

Comparar métricas entre modelos

Têm unidade

- **MAE e RMSE** — vêm na unidade do alvo (minutos, reais...).
- **Cuidado** — não se comparam entre alvos de escalas/ unidades diferentes.
- Ex.: 8 minutos × 8 mil reais não diz nada.

Sem unidade

- **R^2 e MAPE** — são adimensionais (fração e %).
- **Por isso** — servem para comparar alvos de escalas diferentes.
- Reporte um par: um erro em unidade + o R^2 .

REVISÃO 3

Quiz da Aula 04

Cada questão e, em seguida, a resposta.

Questão 1

O erro de uma previsão é definido como:

- A)** valor previsto – média dos valores
- B)** valor real – valor previsto
- C)** $|\text{valor real}| \div \text{valor previsto}$
- D)** sempre um número entre 0 e 1

Questão 1 — resposta

O erro de uma previsão é definido como:

- A) valor previsto – média dos valores
- B) **valor real – valor previsto** ✓
- C) $|\text{valor real}| \div \text{valor previsto}$
- D) sempre um número entre 0 e 1

Questão 2

O MAE (erro absoluto médio) é:

- A)** a média dos erros sem sinal (em módulo)
- B)** a raiz da média dos erros ao quadrado
- C)** o erro expresso em porcentagem
- D)** a variância dos valores reais

Questão 2 — resposta

O MAE (erro absoluto médio) é:

- A) a média dos erros sem sinal (em módulo) ✓**
- B) a raiz da média dos erros ao quadrado
- C) o erro expresso em porcentagem
- D) a variância dos valores reais

Questão 3

Por que o RMSE é mais sensível a erros grandes do que o MAE?

- A)** porque divide cada erro pelo valor real
- B)** porque ignora os erros pequenos
- C)** porque usa a mediana em vez da média
- D)** porque eleva cada erro ao quadrado antes de somar

Questão 3 — resposta

Por que o RMSE é mais sensível a erros grandes do que o MAE?

- A) porque divide cada erro pelo valor real
- B) porque ignora os erros pequenos
- C) porque usa a mediana em vez da média
- D) porque eleva cada erro ao quadrado antes de somar ✓**

Questão 4

Sobre a faixa de valores do R^2 , é correto afirmar:

- A)** varia sempre de 0 a 1
- B)** é medido na mesma unidade do alvo
- C)** vale no máximo 1 e pode ser negativo
- D)** quanto menor, melhor o modelo

Questão 4 — resposta

Sobre a faixa de valores do R^2 , é correto afirmar:

- A) varia sempre de 0 a 1
- B) é medido na mesma unidade do alvo
- C) **vale no máximo 1 e pode ser negativo** ✓
- D) quanto menor, melhor o modelo

Questão 5

Um R^2 negativo significa que o modelo:

- A)** acertou todas as previsões
- B)** é pior do que simplesmente prever sempre a média
- C)** tem erro igual a zero
- D)** é o melhor modelo possível

Questão 5 — resposta

Um R^2 negativo significa que o modelo:

- A) acertou todas as previsões
- B) é pior do que simplesmente prever sempre a média ✓**
- C) tem erro igual a zero
- D) é o melhor modelo possível

Questão 6

O MAPE expressa o erro:

- A)** na mesma unidade do alvo
- B)** elevado ao quadrado
- C)** como fração da variância
- D)** em porcentagem do valor real

Questão 6 — resposta

O MAPE expressa o erro:

- A) na mesma unidade do alvo
- B) elevado ao quadrado
- C) como fração da variância
- D) **em porcentagem do valor real** ✓

Questão 7

A principal armadilha do MAPE aparece quando:

- A)** os valores reais são muito grandes
- B)** o alvo é uma categoria (sim/não)
- C)** há valores reais próximos de zero
- D)** o modelo é linear

Questão 7 — resposta

A principal armadilha do MAPE aparece quando:

- A) os valores reais são muito grandes
- B) o alvo é uma categoria (sim/não)
- C) **há valores reais próximos de zero** ✓
- D) o modelo é linear

Questão 8

Para comparar dois modelos que preveem alvos de unidades/escalas diferentes (ex.: minutos × reais), o mais adequado é usar:

- A)** o MAE
- B)** o RMSE
- C)** o erro máximo em unidades
- D)** o R^2 ou o MAPE (métricas sem unidade)

Questão 8 — resposta

Para comparar dois modelos que preveem alvos de unidades/escalas diferentes (ex.: minutos × reais), o mais adequado é usar:

- A) o MAE
- B) o RMSE
- C) o erro máximo em unidades
- D) o R^2 ou o MAPE (métricas sem unidade) ✓**

Questão 9

No cálculo do R^2 , a "soma dos desvios² da média" representa:

- A)** o quanto os valores reais se espalham em torno da média (a variância)
- B)** o erro do modelo em cada previsão
- C)** o valor previsto médio
- D)** o MAPE do conjunto

Questão 9 — resposta

No cálculo do R^2 , a "soma dos desvios² da média" representa:

- A) o quanto os valores reais se espalham em torno da média (a variância) ✓**
- B) o erro do modelo em cada previsão
- C) o valor previsto médio
- D) o MAPE do conjunto

Qual métrica para qual pergunta

A pergunta	A métrica
De quantas unidades erramos, em média?	MAE
Erros grandes são especialmente ruins?	RMSE
Quanto da variação o modelo explica?	R^2
Qual o erro em %? (alvos sem valores ~0)	MAPE
Comparar modelos de alvos diferentes?	R^2 ou MAPE (sem unidade)

Reporte quase sempre um par: um erro na unidade (MAE/RMSE) + o R^2 .