

CIÊNCIA DE DADOS 1 · REVISÃO

Aula 05 — Revisão: hold-out e Pipeline

PARTE 1

Recapitulação

As ideias-chave da aula.

1

1. Por que não testar no treino

Avaliar no mesmo dado do treino mede **memorização**, não desempenho em dados novos.

- **O problema** — o modelo já 'viu' esses pontos; a nota sai inflada e mente sobre a generalização.
- **A solução** — separar um conjunto de TESTE que o modelo nunca vê no treino.
- **Três conjuntos** — treino (aprende), validação (decide modelo/limiar), teste (nota final, intocado).

2. Obter os três conjuntos, estratificar e semente

- **Dois cortes encadeados** — separa o teste primeiro; depois divide o resto em treino e validação.
- **stratify=y** — mantém a MESMA proporção das classes nos conjuntos — essencial quando a classe é rara.
- **random_state** — fixa o sorteio: mesma semente → mesmo corte → resultado reprodutível.

3. Vazamento e o jeito certo — Pipeline

REGRA DE OURO

o fit (aprender média/desvio) usa SÓ o treino · o transform aplica-se ao treino E ao teste

- **Na prática** — no treino: fit_transform (aprende e aplica); no teste: só transform, com as estatísticas do treino. As duas partes ficam na MESMA escala.
- **Vazamento** — dar fit no conjunto INTEIRO (ou no teste) deixa o teste 'espiar' o treino → nota otimista falsa.
- **ColumnTransformer** — aplica uma transformação por tipo de coluna (z-score nas numéricas, OneHot nas categóricas) de uma vez.
- **Pipeline** — junta pré-processamento + modelo; na validação cruzada refaz o fit DENTRO de cada dobra → sem vazar.

4. Hold-out no tempo

Com data, o corte é por **tempo**: treina no passado, testa no futuro — nunca sorteie.

- **Validar** — segure os últimos períodos conhecidos como teste (ex.: treina 2000–2023, prevê 2024–2025) e compare com o real.
- **Na hora de valer** — re-treine com TODOS os dados até o corte; a separação serviu só para medir.
- **Cuidado** — os períodos passados ficam no treino (ensinam a sazonalidade); só o trecho de teste, depois do corte, sai.

5. Um corte só; skew × drift

- **Um corte só é jogar a moeda** — a nota varia com a sorte do corte; a validação cruzada tira a média de vários cortes (Aula 06).
- **Skew × drift** — skew = treino ≠ produção AGORA (defesa: mesmo Pipeline); drift = dados mudam no TEMPO (defesa: monitorar e re-treinar).

Global holdout, com calma

Um grupo pequeno de usuários (**5–10%**) fica FORA de todas as mudanças por meses, para medir o **ganho real acumulado** do que a empresa lançou.

- **Como funciona** — sorteia-se 5–10% dos usuários que continuam na experiência ANTIGA; o resto recebe todas as novidades.
- **O que mede** — holdout $\times$ todos os outros = o efeito somado de TUDO, ao longo do tempo — não de um teste isolado.
- **Por que não somar os A/B** — somar o ganho de cada teste SUPERESTIMA: os efeitos se sobrepõem e a novidade perde força (decaimento).
- **No fim** — libera-se o holdout (recebe tudo) após medir. Trade-off: maior = mais preciso, porém mais gente sem as melhorias.

Fonte: práticas de experimentação (Statsig, Optimizely, Disney Streaming).

PARTE 2

E quando não há 1 e 0?

Validando modelos que preveem NÚMEROS (carga, geração...).


2

A matriz de confusão é para CLASSIFICAÇÃO

VP, VN, FP e FN só existem quando a resposta é um **rótulo (1 ou 0)**. Prever carga/geração devolve um **número** — não há 'acertou/errou'.

- **Classificação** — 'é spam? sim/não' → conta acertos e erros em quadrantes (a matriz de confusão).
- **Regressão (previsão de número)** — 'quantos MW às 19h?' → a pergunta vira 'errou por QUANTO?', não 'acertou ou não'.
- **Logo** — trocamos os quadrantes pelo ERRO = (valor real – valor previsto) e resumimos esse erro em métricas.

O erro, visto no tempo



A validação honesta de uma previsão contínua é comparar a curva PREVISTA com a REAL ao longo do tempo — e medir a distância entre elas.

Como validar: as quatro métricas de erro

hora	real (MW)	previsto (MW)	erro = real – previsto
1	400	410	-10
2	520	500	+20
3	610	560	+50
4	480	470	+10

RESUMO DO ERRO (DESTE EXEMPLO)

MAE = 22,5 MW · RMSE = 27,8 MW · MAPE = 4,2 % · R² = 0,86

- **MAE** — erro médio em MW; fácil de comunicar. RMSE pune mais os PICOS (o erro de +50 puxa o RMSE acima do MAE).
- **MAPE (%) e R²** — MAPE é o erro em %; R² é adimensional (0 a 1, pode ser negativo) e diz quanto da variação o modelo explica.

Cuidados e validação de previsões contínuas

- **RMSE para picos** — em carga/geração, errar o pico é caro — o RMSE (que eleva o erro ao quadrado) destaca isso.
- **MAPE perto de zero** — cuidado: geração solar à noite = 0 → dividir por zero faz o MAPE explodir/ficar indefinido.
- **Compare com uma baseline** — um modelo só presta se bate o ingênuo 'amanhã = hoje na mesma hora'. Se não bater, não serve.
- **Valide no TEMPO** — treine no passado, preveja as próximas horas/dias e compare com o real — é o hold-out temporal da aula.

Resumo: sem 1 e 0, a matriz de confusão sai; entram o ERRO e as métricas MAE, RMSE, MAPE e R^2 — com validação no tempo.

Quer acurácia, recall e precisão? Defina um EVENTO

Essas métricas precisam de **1 e 0**. Numa previsão contínua, crie o evento com um **limiar**: 'a carga vai passar de 500 MW (pico)?' — e vira classificação.

- **Marque o evento** — para cada hora, 1 se passou do limiar, 0 se não — tanto no REAL quanto no PREVISTO.
- **Aí sim há matriz de confusão** — dos ALERTAS de pico: VP, VN, FP, FN — e daí acurácia, recall e precisão.
- **O que cada uma diz** — recall = dos picos reais, quantos o modelo avisou; precisão = dos alertas dados, quantos eram pico de verdade.

Ou seja: a previsão continua sendo de um número; o EVENTO (passou do limiar?) é que vira 1/0 para medir alertas.

Exemplo: alerta de pico (limiar 500 MW)

hora	real	previsto	real>500?	previsto>500?	→
1	400	410	não	não	VN
2	520	500	SIM	não	FN
3	610	560	SIM	SIM	VP
4	480	470	não	não	VN

MÉTRICAS DO ALERTA DE PICO

VP=1 FN=1 FP=0 VN=2 → acurácia = 3/4 = 0,75 · recall = 1/2 = 0,50 · precisão = 1/1 = 1,00

- **Leitura** — o modelo avisou só METADE dos picos reais (recall 0,50), mas não deu alarme falso (precisão 1,00).

Assim se mede 'acerto de evento' numa previsão contínua — combine com MAE/RMSE, que medem o tamanho do erro em MW.

PARTE 3

Gabarito comentado

As 16 questões do formulário, uma a uma.

3

Questão 1

Por que NÃO se deve avaliar o modelo nos mesmos dados em que ele treinou?

- porque o treino demora mais
- porque ele decora os dados e a nota não mede a generalização (fica alta demais)
- porque o teste precisa ser maior que o treino
- porque assim não dá para usar árvores

Pense na sua resposta — a correção está no próximo slide.

Questão 1 — resposta

Por que NÃO se deve avaliar o modelo nos mesmos dados em que ele treinou?

- porque o treino demora mais
- ✓ **porque ele decora os dados e a nota não mede a generalização (fica alta demais)**
- porque o teste precisa ser maior que o treino
- porque assim não dá para usar árvores

POR QUÊ: Testar no dado de treino mede memorização, não desempenho em dados novos. Por isso separamos um teste.

Questão 2

No hold-out com três conjuntos, o papel de cada um é:

- treino ajusta, validação é intocado, teste escolhe o modelo
- os três servem para treinar
- treino ajusta, validação ajuda a decidir (modelo/limiar), teste dá a nota final intocada
- validação treina e teste ajusta

Pense na sua resposta — a correção está no próximo slide.

Questão 2 — resposta

No hold-out com três conjuntos, o papel de cada um é:

- treino ajusta, validação é intocado, teste escolhe o modelo
- os três servem para treinar
- ✓ **treino ajusta, validação ajuda a decidir (modelo/limiar), teste dá a nota final intocada**
- validação treina e teste ajusta

POR QUÊ: Treino aprende; validação orienta as decisões; o teste só é usado no fim, uma vez.

Questão 3

Como obter treino / validação / teste na prática?

- dois cortes encadeados: separa o teste; depois divide o resto em treino e validação
- um corte só, em três partes iguais e aleatórias sempre
- não é possível ter três conjuntos
- sorteando as linhas a cada época

Pense na sua resposta — a correção está no próximo slide.

Questão 3 — resposta

Como obter treino / validação / teste na prática?

✓ **dois cortes encadeados: separa o teste; depois divide o resto em treino e validação**

- um corte só, em três partes iguais e aleatórias sempre
- não é possível ter três conjuntos
- sorteando as linhas a cada época

POR QUÊ: Primeiro separa-se o teste (guardado); o restante é dividido em treino e validação.

Questão 4

Para que serve o `stratify=y` no `train_test_split`?

- para embaralhar melhor
- para padronizar as variáveis
- para acelerar o treino
- para manter a mesma proporção das classes no treino e no teste

Pense na sua resposta — a correção está no próximo slide.

Questão 4 — resposta

Para que serve o `stratify=y` no `train_test_split`?

- para embaralhar melhor
- para padronizar as variáveis
- para acelerar o treino
- ✓ **para manter a mesma proporção das classes no treino e no teste**

POR QUÊ: Sem estratificar, um sorteio pode desbalancear os conjuntos — grave quando a classe é rara.

Questão 5

O `random_state` (semente) serve para:

- melhorar a acurácia do modelo
- tornar o sorteio reprodutível — mesma semente, mesmo corte
- aumentar o tamanho do teste
- evitar valores ausentes

Pense na sua resposta — a correção está no próximo slide.

Questão 5 — resposta

O random_state (semente) serve para:

- melhorar a acurácia do modelo
- ✓ **tornar o sorteio reprodutível — mesma semente, mesmo corte**
- aumentar o tamanho do teste
- evitar valores ausentes

POR QUÊ: Fixar a semente garante que a divisão (e o resultado) seja o mesmo toda vez que rodar.

Questão 6

"Avaliar com uma única divisão treino/teste é como jogar a moeda." O que isso quer dizer?

- que o modelo escolhe a resposta ao acaso
- que a acurácia é sempre 50%
- que a nota varia conforme a sorte do corte; a solução é a média de vários cortes (validação cruzada)
- que não se deve usar teste

Pense na sua resposta — a correção está no próximo slide.

Questão 6 — resposta

"Avaliar com uma única divisão treino/teste é como jogar a moeda." O que isso quer dizer?

- que o modelo escolhe a resposta ao acaso
- que a acurácia é sempre 50%
- ✓ **que a nota varia conforme a sorte do corte; a solução é a média de vários cortes (validação cruzada)**
- que não se deve usar teste

POR QUÊ: Um corte pode ser fácil ou difícil; a estimativa tem variância. A validação cruzada tira a média de vários cortes.

Questão 7

Padronizar (StandardScaler) usando o conjunto INTEIRO antes de separar treino/teste é:

- vazamento — o teste 'espia' o treino, pois a média/desvio incluem o teste
- a forma recomendada
- irrelevante para o resultado
- necessário para o OneHotEncoder

Pense na sua resposta — a correção está no próximo slide.

Questão 7 — resposta

Padronizar (StandardScaler) usando o conjunto INTEIRO antes de separar treino/teste é:

✓ **vazamento — o teste 'espia' o treino, pois a média/desvio incluem o teste**

- a forma recomendada
- irrelevante para o resultado
- necessário para o OneHotEncoder

POR QUÊ: O certo é fit só no treino e transform no teste. Ajustar no todo deixa a informação do teste vazar.

Questão 8

A forma correta de aplicar o StandardScaler é:

- fit_transform no treino e fit_transform no teste
- fit no teste e transform no treino
- fit no treino; transform (sem fit) no teste
- fit_transform no conjunto inteiro

Pense na sua resposta — a correção está no próximo slide.

Questão 8 — resposta

A forma correta de aplicar o StandardScaler é:

- fit_transform no treino e fit_transform no teste
- fit no teste e transform no treino
- ✓ **fit no treino; transform (sem fit) no teste**
- fit_transform no conjunto inteiro

POR QUÊ: O fit (aprender média/desvio) usa SÓ o treino. O transform aplica-se aos DOIS: no treino fit_transform, no teste só transform. Nunca dar fit no teste.

Questão 9

O ColumnTransformer serve para:

- treinar vários modelos ao mesmo tempo
- aplicar uma transformação diferente para cada tipo de coluna (numérica × categórica) de uma vez
- dividir treino e teste
- calcular a acurácia

Pense na sua resposta — a correção está no próximo slide.

Questão 9 — resposta

O ColumnTransformer serve para:

- treinar vários modelos ao mesmo tempo
- ✓ **aplicar uma transformação diferente para cada tipo de coluna (numérica × categórica) de uma vez**
- dividir treino e teste
- calcular a acurácia

POR QUÊ: Ex.: StandardScaler nas numéricas e OneHotEncoder nas categóricas, juntando tudo numa matriz só.

Questão 10

Por que o Pipeline (pré-processamento + modelo) evita vazamento na validação cruzada?

- porque usa menos memória
- porque remove os valores ausentes
- porque escolhe o k sozinho
- porque refaz o pré-processamento DENTRO de cada dobra, só com o treino daquela dobra

Pense na sua resposta — a correção está no próximo slide.

Questão 10 — resposta

Por que o Pipeline (pré-processamento + modelo) evita vazamento na validação cruzada?

- porque usa menos memória
- porque remove os valores ausentes
- porque escolhe o k sozinho
- ✓ **porque refaz o pré-processamento DENTRO de cada dobra, só com o treino daquela dobra**

POR QUÊ: O Pipeline garante que o fit do pré-processamento use apenas o treino de cada divisão.

Questão 11

Quando os dados têm data, a divisão correta é:

- por tempo: treinar no passado e testar no futuro (não sortear)
- sortear as linhas aleatoriamente como sempre
- testar no passado e treinar no futuro
- usar só o mês mais antigo

Pense na sua resposta — a correção está no próximo slide.

Questão 11 — resposta

Quando os dados têm data, a divisão correta é:

✓ **por tempo: treinar no passado e testar no futuro (não sortear)**

- sortear as linhas aleatoriamente como sempre
- testar no passado e treinar no futuro
- usar só o mês mais antigo

POR QUÊ: Sortear no tempo deixa o modelo 'ver o futuro' no treino (vazamento temporal). Corte por data.

Questão 12

Vendas de 2000 a 2025 e você quer prever dezembro de 2026 (já tem jan–nov/2026). Sobre o treino:

- remover TODOS os dezembros de 2000–2025 do treino
- treinar só com 2026
- manter os dezembros passados no treino (ensinam a sazonalidade); nunca usar dados depois do ponto previsto
- usar apenas dezembros no treino

Pense na sua resposta — a correção está no próximo slide.

Questão 12 — resposta

Vendas de 2000 a 2025 e você quer prever dezembro de 2026 (já tem jan–nov/2026). Sobre o treino:

- remover TODOS os dezembros de 2000–2025 do treino
- treinar só com 2026
- ✓ **manter os dezembros passados no treino (ensinam a sazonalidade); nunca usar dados depois do ponto previsto**
- usar apenas dezembros no treino

POR QUÊ: A regra corta pelo TEMPO, não pelo mês. Dezembros passados são passado — e é o que ensina o padrão de dezembro.

Questão 13

Para estimar se o modelo temporal funciona (sem ter ainda o real de 2026), a melhor prática é:

- nunca testar; confiar no treino
- segurar os últimos anos conhecidos como teste (ex.: treina 2000–2023, prevê 2024–2025) e, aprovado, re-treinar com tudo
- testar em anos sorteados aleatoriamente
- usar o mesmo ano no treino e no teste

Pense na sua resposta — a correção está no próximo slide.

Questão 13 — resposta

Para estimar se o modelo temporal funciona (sem ter ainda o real de 2026), a melhor prática é:

- nunca testar; confiar no treino
- ✓ **segurar os últimos anos conhecidos como teste (ex.: treina 2000–2023, prevê 2024–2025) e, aprovado, re-treinar com tudo**
- testar em anos sorteados aleatoriamente
- usar o mesmo ano no treino e no teste

POR QUÊ: Simula-se o futuro com anos passados; a separação serve só para medir. Para valer, re-treina com todos os dados.

Questão 14

O "global holdout" (holdout de produto) serve para:

- ajustar os parâmetros do modelo
- padronizar as variáveis
- substituir o conjunto de teste do modelo
- manter um grupo de usuários fora de TODAS as mudanças, medindo o impacto real acumulado no negócio

Pense na sua resposta — a correção está no próximo slide.

Questão 14 — resposta

O "global holdout" (holdout de produto) serve para:

- ajustar os parâmetros do modelo
- padronizar as variáveis
- substituir o conjunto de teste do modelo
- ✓ **manter um grupo de usuários fora de TODAS as mudanças, medindo o impacto real acumulado no negócio**

POR QUÊ: Aqui 'hold-out' não treina modelo: avalia o PRODUTO. Compara-se um grupo sem novidades com o resto, ao longo do tempo.

Questão 15

Qual a diferença entre um teste A/B e o global holdout?

- o A/B mede UMA mudança (curto prazo); o global holdout mede o efeito de TUDO (longo prazo)
- são exatamente a mesma coisa
- o A/B não usa grupo de controle
- o global holdout serve para treinar o modelo

Pense na sua resposta — a correção está no próximo slide.

Questão 15 — resposta

Qual a diferença entre um teste A/B e o global holdout?

✓ **o A/B mede UMA mudança (curto prazo); o global holdout mede o efeito de TUDO (longo prazo)**

- são exatamente a mesma coisa
- o A/B não usa grupo de controle
- o global holdout serve para treinar o modelo

POR QUÊ: O A/B isola uma mudança; o global holdout mede o ganho somado de todos os lançamentos ao longo do tempo.

Questão 16

Na produção do modelo, skew e drift são:

- o mesmo problema com nomes diferentes
- erros de digitação no código
- skew = treino $\neq$ produção AGORA (defesa: mesmo Pipeline); drift = dados mudam com o TEMPO (defesa: monitorar e re-treinar)
- skew acontece no tempo e drift no deploy

Pense na sua resposta — a correção está no próximo slide.

Questão 16 — resposta

Na produção do modelo, skew e drift são:

- o mesmo problema com nomes diferentes
- erros de digitação no código
- ✓ **skew = treino $\neq$ produção AGORA (defesa: mesmo Pipeline); drift = dados mudam com o TEMPO (defesa: monitorar e re-treinar)**
- skew acontece no tempo e drift no deploy

POR QUÊ: Skew é problema de espaço (dois ambientes desalinhados no deploy); drift é problema de tempo (o mundo muda).

Fechamento

- **Validar = separar** — treino aprende, validação decide, teste dá a nota final intocada.
- **Sem vazamento** — fit só no treino; Pipeline garante isso, inclusive na validação cruzada.
- **Com data** — treina no passado, testa no futuro; re-treina com tudo para valer.
- **Sem 1 e 0** — para prever números (carga/geração), use o ERRO e as métricas MAE, RMSE, MAPE e R^2 — validando no tempo.

Dúvidas? Traga na próxima aula — ou use o campo aberto do formulário.