

CIÊNCIA DE DADOS 1 · REVISÃO

Validação cruzada — revisão e questionário

REVISÃO 1

Relembrando os conceitos

O essencial da validação cruzada.


1

Por que não avaliar com um corte só

Um corte pode ser 'fácil' ou 'difícil': a nota **balança pela sorte do sorteio**. A validação cruzada troca isso pela **média de vários cortes**.

- **O problema** — mesmo modelo e base, só mudando a semente, a acurácia vai de 0,82 a 0,76.
- **A ideia** — fazer vários cortes, testar em cada um e tirar a média — estimativa estável.
- **Reporte honesto** — média $\pm$ desvio, nunca um número solto.

k-fold: o rodízio que aproveita todo o dado



Divide em k pedaços; a cada rodada 1 é teste e os outros k-1 são treino. Todo dado é testado uma vez. Resultado = média $\pm$ desvio das k notas.

k-fold no scikit-learn

```
from sklearn.model_selection import cross_val_score, KFold
scores = cross_val_score(modelo, X, y, cv=5, scoring="accuracy")
print(scores)                # [0.80 0.90 0.70 0.85 0.75]
print(scores.mean(), scores.std()) # 0.80 0.07
```

cv=5 faz o rodízio sozinho. O resultado honesto é média $\pm$ desvio — nunca um número solto.

REVISÃO 2

Tirando as dúvidas

O que ficou perguntado na aula.

Quem separa treino e teste? O cv, sozinho

Você não separa nada à mão: o **cv=5** corta o X, y e faz o rodízio automaticamente.

rodada	teste	treino
1	pedaço 1	pedaços 2, 3, 4, 5
2	pedaço 2	pedaços 1, 3, 4, 5
3	pedaço 3	pedaços 1, 2, 4, 5
4	pedaço 4	pedaços 1, 2, 3, 5
5	pedaço 5	pedaços 1, 2, 3, 4

Esse X, y é só o bloco de treino/validação — o teste final fica separado e é tocado uma vez no fim.

Classe rara: o limite do k

Estratificar **não cria positivos**: logo, **k não pode passar do nº de positivos**.

Funciona: 8 positivos, k=5

- $8 \div 5 \approx 1,6$ por dobra
- Distribui 2, 2, 2, 1, 1
- Toda dobra tem positivo

Quebra: 3 positivos, k=5

- 3 para 5 dobras
- 2 dobras ficam com ZERO — métrica indefinida.
- Saída — baixe o k ou RepeatedStratifiedKFold.

Regra de bolso: $k \leq \text{nº de exemplos da classe mais rara}$.

LOO × k-fold, na mão ($n = 10$)

LOO é **k-fold com $k = n$** : cada exemplo, sozinho, vira teste uma vez.

k-fold ($k = 5$)

- **5 rodadas**
- **teste = 2 exemplos** — treino = 8.
- **5 notas** — cada uma já estável.

Leave-One-Out ($k = 10$)

- **10 rodadas**
- **teste = 1 exemplo** — treino = 9.
- **nota 0 ou 1** — só a média faz sentido.

LOO aproveita o máximo do dado, mas custa n treinos e dá notas 'nervosas'. Use com pouquíssimos dados.

O problema do grupo

Com **vários exames do mesmo paciente**, se o mesmo P1 cai no treino E no teste, o modelo **decora a pessoa** — não aprende a doença.

- **Por que infla** — ele reconhece o P1 no teste e acerta — não por entender o padrão.
- **Na vida real** — chegam pacientes NOVOS → a nota alta some.
- **A defesa** — GroupKFold: o grupo inteiro de um lado só (groups=id).

Um corte temporal ou vários?

Treinar 2000–2015 e segurar 2016–2021 é um **hold-out temporal**: o TimeSeriesSplit com um corte só.

Hold-out temporal (1 corte)

- **treino 2000–2015 · teste 2016–2021**
- **uma estimativa** — barata e realista.
- **risco** — aquele período pode ser atípico.

TimeSeriesSplit (vários)

- **repete andando no tempo**
- **várias estimativas** — média mais estável.
- **treina passado, testa futuro**

Os dois só ESTIMAM. Aprovado o modelo, re-treine com TODOS os dados para produção.

Está generalizando ou decorando?

O teste é a diferença entre o treino e **dados que o modelo nunca viu**: decorar aparece como nota alta no treino e baixa fora.

onde	nota	leitura
treino	0,98	o modelo nos próprios dados
validação (CV)	0,80 ± 0,02	média de vários cortes
teste final	0,79	conjunto guardado, uma vez

TAMBÉM AJUDA A VER

- **Curva de aprendizado** — validação muito abaixo do treino e sem subir = decorando.
- **Desvio da CV** — 0,80 ± 0,02 baixo = consistente entre os cortes.

Gap grande (treino » validação) = decorando; os três próximos entre si = generalizando. A nota que vale é a de dados fora do ajuste.

Quando re-treinar: o drift

Com o tempo os dados mudam (**drift**). Você monitora — sem esperar o modelo quebrar.

- **Desempenho no tempo** — acompanhe a métrica de referência nos dados novos; caiu do limiar → reavaliar.
- **Distribuição das entradas (data drift)** — features mudando de faixa/categoria (PSI, KS) — dá para ver antes dos rótulos.
- **Relação $X \rightarrow y$ (concept drift)** — o que previa bem deixou de prever; só se percebe pela queda de desempenho.
- **Como agir** — linha de base + limiar de alerta; backtesting temporal; re-treinar por gatilho ou agenda, com os dados recentes.

Data drift = as entradas mudam; concept drift = a relação muda. É o outro lado do hold-out temporal da Aula 05.

Qual esquema usar? (resumo)

Situação do dado	Esquema	Por quê
Classificação (padrão)	StratifiedKFold	mantém a proporção das classes em cada dobra
Regressão / dado comum	KFold (k=5 ou 10)	o rodízio simples já basta
Repetição por pessoa/loja/sensor	GroupKFold	o grupo inteiro de um lado só (sem vaziar)
Dados com data (série temporal)	TimeSeriesSplit	treina no passado, testa no futuro
Pouquíssimos dados	LOO / RepeatedKFold	aproveita ao máximo cada exemplo

Sem vazar: CV dentro do Pipeline

O pré-processamento tem de ser feito **dentro de cada dobra**, só com o treino daquela dobra.

```
from sklearn.pipeline import Pipeline
pipe = Pipeline([("prep", StandardScaler()), ("clf", modelo)])
cross_val_score(pipe, X, y, cv=5)  # o fit do scaler só no treino de cada dobra
```

Padronizar a base inteira ANTES da CV usa as médias do teste → vazamento e nota otimista.

Fechamento

Validação cruzada = **média de vários cortes** (estimativa estável), o **esquema certo** para cada dado, e tudo **dentro do Pipeline** (sem vazar).

- **Reporte** — média $\pm$ desvio, nunca um número solto.
- **Escolha pelo dado** — estratificado, por grupo ou temporal.
- **Na próxima** — escolher hiperparâmetros sem contaminar a nota (maldição do vencedor e Nested CV).

REVISÃO 3

Questionário

Primeiro a pergunta; no slide seguinte, a resposta.

3

Questão 1

1) "Avaliar com uma única divisão treino/teste é como jogar a moeda." Por quê?

A porque o modelo responde ao acaso

B porque a acurácia é sempre 50%

C porque a nota varia conforme a sorte do corte; a solução é a média de vários cortes (validação cruzada)

D porque não se deve usar teste

Questão 1 — resposta

1) "Avaliar com uma única divisão treino/teste é como jogar a moeda." Por quê?

A porque o modelo responde ao acaso

B porque a acurácia é sempre 50%

C porque a nota varia conforme a sorte do corte; a solução é a média de vários cortes (validação cruzada) ✓ correta

D porque não se deve usar teste

Por quê? Um corte pode ser fácil ou difícil — a estimativa tem variância. A validação cruzada tira a média de vários cortes.

Questão 2

2) Em `cross_val_score(modelo, X, y, cv=5)`, quem define o que é treino e o que é teste?

- A** você, separando as linhas à mão antes de chamar a função
- B** o `cv=5`: ele corta o `X`, `y` em 5 pedaços e faz o rodízio automaticamente
- C** o modelo, durante o fit
- D** é preciso passar dois conjuntos `X_treino` e `X_teste`

Questão 2 — resposta

2) Em `cross_val_score(modelo, X, y, cv=5)`, quem define o que é treino e o que é teste?

A você, separando as linhas à mão antes de chamar a função

B o `cv=5`: ele corta o `X`, `y` em 5 pedaços e faz o rodízio automaticamente ✓ correta

C o modelo, durante o fit

D é preciso passar dois conjuntos `X_treino` e `X_teste`

Por quê? O `cv=5` faz o rodízio sozinho: em cada rodada, 1 pedaço é teste e os outros 4 são treino.

Questão 3

3) O X, y que você passa para o `cross_val_score` deve:

A ser apenas o bloco de treino/validação — o teste final fica separado e é tocado uma vez no fim

B ser a base inteira, incluindo o teste final

C conter só a classe positiva

D já estar padronizado com o conjunto todo

Questão 3 — resposta

3) O X, y que você passa para o `cross_val_score` deve:

A ser apenas o bloco de treino/validação — o teste final fica separado e é tocado uma vez no fim ✓ correta

B ser a base inteira, incluindo o teste final

C conter só a classe positiva

D já estar padronizado com o conjunto todo

Por quê? A validação cruzada acontece dentro do treino. O teste final guardado não entra no `cross_val_score`.

Questão 4

4) Um 5-fold deu as acurácias [0,80; 0,90; 0,70; 0,85; 0,75]. A média é:

A 0,78

B 0,80

C 0,82

D 0,85

Questão 4 — resposta

4) Um 5-fold deu as acurácias [0,80; 0,90; 0,70; 0,85; 0,75]. A média é:

A 0,78

B 0,80 ✓ correta

C 0,82

D 0,85

Por quê? $(0,80+0,90+0,70+0,85+0,75)/5 = 4,00/5 = 0,80$.

Questão 5

5) O resultado honesto de uma validação cruzada é:

- A** a maior nota entre as dobras
- B** a nota da primeira dobra
- C** a média das dobras E o desvio-padrão (média $\pm$ desvio)
- D** um único número, sem desvio

Questão 5 — resposta

5) O resultado honesto de uma validação cruzada é:

- A** a maior nota entre as dobras
- B** a nota da primeira dobra
- C** a média das dobras E o desvio-padrão (média $\pm$ desvio) ✓ correta
- D** um único número, sem desvio

Por quê? Reporta-se a média (desempenho esperado) e o desvio (o quanto oscila entre os cortes).

Questão 6

6) O StratifiedKFold serve para:

- A** acelerar o treino
- B** padronizar as variáveis
- C** embaralhar melhor as linhas
- D** manter a mesma proporção das classes em cada dobra

Questão 6 — resposta

6) O StratifiedKFold serve para:

- A** acelerar o treino
- B** padronizar as variáveis
- C** embaralhar melhor as linhas

D manter a mesma proporção das classes em cada dobra ✓ correta

Por quê? Sem estratificar, um sorteio pode deixar uma dobra sem a classe rara. O estratificado mantém a proporção em CADA dobra.

Questão 7

7) Você tem 100 exemplos, mas só 3 positivos, e quer 5 dobras estratificadas ($k=5$). O que acontece?

- A** funciona: o StratifiedKFold cria positivos sintéticos para completar
- B** pelo menos 2 dobras ficam sem nenhum positivo — k não pode passar do nº de positivos
- C** o modelo fica mais preciso por ter classe rara
- D** a acurácia vira sempre 100%

Questão 7 — resposta

7) Você tem 100 exemplos, mas só 3 positivos, e quer 5 dobras estratificadas ($k=5$). O que acontece?

A funciona: o StratifiedKFold cria positivos sintéticos para completar

B pelo menos 2 dobras ficam sem nenhum positivo — k não pode passar do nº de positivos ✓ correta

C o modelo fica mais preciso por ter classe rara

D a acurácia vira sempre 100%

Por quê? Estratificar não cria positivos. Regra: $k \leq \text{nº da classe mais rara}$. Saída: baixar o k ou usar RepeatedStratifiedKFold.

Questão 8

8) O Leave-One-Out (LOO) é:

- A** o k-fold levado ao extremo, com $k = n$: cada exemplo, sozinho, é o teste uma vez
- B** um k-fold que usa sempre $k=2$
- C** treinar e testar no mesmo conjunto
- D** sortear 1 exemplo e ignorar o resto

Questão 8 — resposta

8) O Leave-One-Out (LOO) é:

A o k-fold levado ao extremo, com $k = n$: cada exemplo, sozinho, é o teste uma vez ✓ correta

B um k-fold que usa sempre $k=2$

C treinar e testar no mesmo conjunto

D sortear 1 exemplo e ignorar o resto

Por quê? Com n exemplos, o LOO faz n rodadas; em cada uma treina com $n-1$ e testa em 1. É o k-fold com $k = n$.

Questão 9

9) Uma consequência prática do LOO ($n=10$ exemplos) é:

- A** faz apenas 2 treinos
- B** cada rodada testa 5 exemplos
- C** faz 10 treinos e a nota de cada rodada é 0 ou 1 (teste de 1 exemplo) — só a média faz sentido
- D** não precisa treinar o modelo

Questão 9 — resposta

9) Uma consequência prática do LOO ($n=10$ exemplos) é:

A faz apenas 2 treinos

B cada rodada testa 5 exemplos

C faz 10 treinos e a nota de cada rodada é 0 ou 1 (teste de 1 exemplo) — só a média faz sentido ✓ correta

D não precisa treinar o modelo

Por quê? LOO aproveita o máximo do dado, mas custa n treinos e cada rodada mede em 1 ponto (acertou/errou).

Questão 10

10) O RepeatedKFold (k-fold repetido) faz:

- A** aumenta o número de dobras dentro de uma rodada
- B** repete o k-fold várias vezes, com sorteios diferentes, e tira a média de todas as notas
- C** usa o mesmo sorteio toda vez
- D** remove os exemplos difíceis

Questão 10 — resposta

10) O RepeatedKFold (k-fold repetido) faz:

- A aumenta o número de dobras dentro de uma rodada
- B repete o k-fold várias vezes, com sorteios diferentes, e tira a média de todas as notas ✓ correta**
- C usa o mesmo sorteio toda vez
- D remove os exemplos difíceis

Por quê? Ex.: 5-fold repetido $3 \times = 15$ notas. Repetir e mediar reduz o efeito da sorte de um único sorteio.

Questão 11

11) Vários exames do mesmo paciente caem no treino E no teste. O que acontece?

- A** não há problema algum
- B** o teste fica maior que o treino
- C** o modelo aprende melhor a doença
- D** o modelo "decora" o paciente e acerta por reconhecê-lo — nota inflada que some com pacientes novos

Questão 11 — resposta

11) Vários exames do mesmo paciente caem no treino E no teste. O que acontece?

- A** não há problema algum
- B** o teste fica maior que o treino
- C** o modelo aprende melhor a doença

D o modelo "decora" o paciente e acerta por reconhecê-lo — nota inflada que some com pacientes novos ✓ correta

Por quê? Vazamento pela identidade do grupo: o modelo reconhece a PESSOA, não o padrão. Em produção chegam pacientes novos.

Questão 12

12) O GroupKFold resolve isso porque:

- A** garante que todas as linhas de um mesmo grupo fiquem do mesmo lado (treino OU teste)
- B** remove os grupos com poucas linhas
- C** padroniza cada grupo separadamente
- D** treina um modelo por grupo

Questão 12 — resposta

12) O GroupKFold resolve isso porque:

A garante que todas as linhas de um mesmo grupo fiquem do mesmo lado (treino OU teste) ✓ correta

B remove os grupos com poucas linhas

C padroniza cada grupo separadamente

D treina um modelo por grupo

Por quê? Passando groups=id, o grupo inteiro vai para um lado só. Use com repetição por pessoa/loja/sensor.

Questão 13

13) Quando os dados têm data, a divisão correta é:

A por tempo: treinar no passado e testar no futuro (não sortear as linhas)

B sortear aleatoriamente como sempre

C testar no passado e treinar no futuro

D usar só o mês mais recente

Questão 13 — resposta

13) Quando os dados têm data, a divisão correta é:

A por tempo: treinar no passado e testar no futuro (não sortear as linhas) ✓ correta

B sortear aleatoriamente como sempre

C testar no passado e treinar no futuro

D usar só o mês mais recente

Por quê? Sortear no tempo coloca o futuro no treino (vazamento temporal). Corte por data.

Questão 14

14) Relação entre segurar 2016–2021 como teste (treino 2000–2015) e o TimeSeriesSplit?

- A** são coisas sem relação
- B** o TimeSeriesSplit sorteia as datas
- C** o primeiro é um hold-out temporal (1 corte); o TimeSeriesSplit é isso repetido em vários cortes, dando uma média mais estável
- D** o hold-out temporal usa o futuro no treino

Questão 14 — resposta

14) Relação entre segurar 2016–2021 como teste (treino 2000–2015) e o TimeSeriesSplit?

A são coisas sem relação

B o TimeSeriesSplit sorteia as datas

C o primeiro é um hold-out temporal (1 corte); o TimeSeriesSplit é isso repetido em vários cortes, dando uma média mais estável ✓
correta

D o hold-out temporal usa o futuro no treino

Por quê? O TimeSeriesSplit é o hold-out temporal repetido, andando no tempo. Os dois só estimam; depois re-treina-se com tudo.

Questão 15

15) Por que rodar a validação cruzada DENTRO de um Pipeline?

- A** para usar menos memória
- B** para escolher o k sozinho
- C** para remover valores ausentes
- D** porque o pré-processamento se refaz em cada dobra, só com o treino daquela dobra — sem vazar

Questão 15 — resposta

15) Por que rodar a validação cruzada DENTRO de um Pipeline?

A para usar menos memória

B para escolher o k sozinho

C para remover valores ausentes

D porque o pré-processamento se refaz em cada dobra, só com o treino daquela dobra — sem vazar ✓ correta

Por quê? O Pipeline garante que o fit do scaler/imputer use apenas o treino de cada divisão.

Questão 16

16) Padronizar (StandardScaler) usando o conjunto INTEIRO antes da validação cruzada é:

- A** vazamento — a média/desvio incluem os dados que serão teste em cada dobra, inflando a nota
- B** a forma recomendada
- C** irrelevante para o resultado
- D** necessário para o k-fold funcionar

Questão 16 — resposta

16) Padronizar (StandardScaler) usando o conjunto INTEIRO antes da validação cruzada é:

A vazamento — a média/desvio incluem os dados que serão teste em cada dobra, inflando a nota ✓ correta

B a forma recomendada

C irrelevante para o resultado

D necessário para o k-fold funcionar

Por quê? O certo é o fit do pré-processamento só no treino de cada dobra (via Pipeline). No todo, a informação do teste vaza.