

Nested CV

Validação aninhada

GridSearchCV × Nested CV: quem escolhe e quem mede

Os dois aparecem hoje, e é fácil confundi-los. O que separa um do outro é o que sobra na mão no fim.

GRIDSEARCHCV · ESCOLHE E ENTREGA O MODELO

O que ele faz — varre a grade com validação cruzada dentro do treino e devolve a combinação vencedora.

O que sobra na mão — o **best_params_** e o **best_estimator_** já treinado: o modelo que você entrega.

A nota que ele imprime — o **best_score_** é de validação e é o MÁXIMO de várias tentativas: vem inflada. Para um número honesto ele depende de um **teste separado**, tocado uma única vez.

NESTED CV · NÃO ESCOLHE NADA, SÓ AUDITA

O que ele faz — roda o GridSearchCV inteiro K vezes, cada vez medindo num pedaço que aquela busca não viu.

O que sobra na mão — **nenhum modelo**. Só um número: a média $\pm$ desvio das K rodadas externas.

A nota que ele dá — é honesta por construção: quem escolheu nunca viu o pedaço que mediu. E não precisa de teste separado — o papel de teste **roda** entre as K partes.

A FRASE QUE RESOLVE A CONFUSÃO

O Nested CV **não substitui** o GridSearchCV — ele **roda o GridSearchCV por dentro**. Um escolhe o modelo; o outro mede o quanto se pode confiar nessa escolha.

A busca em grade é o assunto da PRÓXIMA aula — como montar a grade, o custo, o que fazer quando ela explode. Hoje ela entra só como a ferramenta que o laço interno usa.

O que é um hiperparâmetro

Parâmetro (o modelo aprende)

- **Sai do treino** — o modelo ajusta sozinho, no fit.
- **Exemplos** — os pesos de uma regressão, os cortes de uma árvore.
- **Você não mexe nele à mão**

Hiperparâmetro (você define)

- **Definido ANTES** — configura COMO o modelo aprende.
- **Exemplos** — o k do k-NN, a profundidade da árvore, o C da regularização.
- **É o que vamos ajustar**

Receita de bolo: hiperparâmetro = a temperatura e o tempo do forno (você escolhe antes); parâmetro = como a massa cresce por dentro (resultado).

O trabalho: escolher o hiperparâmetro

O modelo não escolhe o hiperparâmetro. **Você** testa alguns valores e vê qual vai melhor na validação.

valor de C testado	nota na validação
0,1	0,78
1	0,85 ← melhor
10	0,82

O QUE FAZ SENTIDO

- Você ficaria com C = 1 (0,85).
- **Mas cuidado** — essa nota serve para ESCOLHER — não para reportar como desempenho final.

Testar valores e comparar na validação: isso é a 'busca de hiperparâmetros' (grid/random search).

A cilada: escolher e medir no mesmo lugar mente

Se a nota que **escolheu** o C também é a nota que você **reporta**, ela sai otimista.

- **Por quê** — você ficou com o MELHOR de várias tentativas — e o melhor sempre pega um tanto de sorte.
- **Quanto mais você testa** — maior o inchaço: o campeão de 100 tentativas quase sempre teve a sorte a favor.
- **O que falta** — um número medido em dados que a escolha NUNCA viu.

É a 'maldição do vencedor'. O Nested CV existe justamente para dar esse número honesto.

A ideia do Nested CV: dois laços

Dois laços com funções **diferentes**: um ESCOLHE o hiperparâmetro, o outro MEDE — em dados separados.

- **Laço INTERNO** — **escolhe** — dentro do treino, testa os valores de C e fica com o melhor.
- **Laço EXTERNO** — **mede** — guarda um pedaço à parte e só o usa para dar a nota.
- **O segredo** — o interno roda DENTRO do treino do externo — quem escolhe nunca toca em quem mede.

Aninhada = um laço dentro do outro. Interno escolhe, externo mede.

O mesmo código, com uma linha a mais

Nested CV não é outro algoritmo: é o GridSearchCV passado para dentro de um `cross_val_score`.

```
# O CAMINHO COMUM — a busca escolhe; um teste separado mede, UMA vez
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.3)
busca = GridSearchCV(pipe, grade, cv=5).fit(X_tr, y_tr)
busca.best_params_      # o modelo que você entrega
busca.score(X_te, y_te) # a nota honesta -> UM número, de UM corte

# HOJE — o MESMO objeto, agora medido por um laço externo
busca = GridSearchCV(pipe, grade, cv=5)      # idêntico: nada mudou aqui
notas = cross_val_score(busca, X, y, cv=5)    # <<< a única linha nova
notas.mean(), notas.std()                    # K números -> média E incerteza
```

O QUE ESSA LINHA FAZ

O `cross_val_score` trata a busca inteira como se fosse **um modelo qualquer**: em cada uma das 5 dobras externas ele chama o **fit** da busca — que por dentro roda a sua própria CV de 5 dobras — e depois pontua na dobra externa. **Cinco buscas independentes, cinco notas**; nenhuma viu o pedaço em que foi medida.

Custo: combinações × dobras internas × dobras externas. Uma grade 3×3 com cv 5 e 5 vira 225 ajustes — contra 45 da busca sozinha.

Passo a passo — rodada externa 1

30 exemplos em 3 partes: **A, B, C**. Nesta rodada, o teste externo é **A**; o treino é **B + C**.

laço INTERNO: testa o C dentro de B + C	nota
C = 0,1	0,78
C = 1	0,85 ← escolhe
C = 10	0,82

AGORA O LAÇO EXTERNO MEDE

treina com C = 1 em B + C → mede em A → 0,83 (A nunca entrou na escolha)

O pedaço A ficou de fora da escolha inteira — por isso a nota nele é honesta.

As três rodadas, de uma vez

Cada parte tem a sua vez de ser o teste externo. Em cada uma, o interno **re escolhe** o C do zero.

rodada	teste externo	C escolhido (laço interno)	nota no teste externo
1	A	C = 1	0,83
2	B	C = 10	0,81
3	C	C = 1	0,85

NOTA HONESTA

$$\text{média}(0,83 \cdot 0,81 \cdot 0,85) = 0,83$$

Cada rodada refaz TUDO: escolhe o C no treino e mede numa parte que a escolha não viu.

Peraí, o C mudou ($1 \rightarrow 10 \rightarrow 1$)?

Sim — e está **certo**. O Nested CV não mede 'o quão bom é o $C = 1$ '.

- **O que ele mede** — o quão bom é o PROCESSO de escolher o C e treinar.
- **Por isso o C varia** — cada rodada escolhe do zero, com dados um pouco diferentes.
- **O número que vale** — a média das notas externas (0,83), não um C específico.

Pense assim: você está auditando o seu MÉTODO de escolher, não um valor fixo.

Então qual modelo vai para produção?

O Nested CV te deu o **número honesto** (0,83) — não o modelo final.

- **Para entregar** — rode UMA busca (GridSearchCV) em TODOS os 30 exemplos → sai um único C.
- **Esse C vai para produção** — é o modelo que você usa de verdade.
- **O papel do Nested CV** — foi a auditoria feita antes, que te deixa dizer 'espero ~0,83' sem mentir.

Nested CV responde 'quão confiável é meu processo?'. A busca final responde 'qual C eu entrego?'.

O que muda — e o que NÃO muda

A nota do Nested CV costuma sair MENOR que a da busca sozinha. Isso é o método funcionando, não piorando.

O QUE VOCÊ GANHA

Uma nota que não depende da sorte de um corte. São K medições em vez de uma, e o desvio-padrão vem junto — dá para dizer " $0,83 \pm 0,03$ ".

Não precisa reservar um teste fixo. Todo dado é medido uma vez e treinado nas outras — o que importa quando a base é pequena.

O teste não "queima". Dá para refinar a grade e rodar de novo: o pedaço de medição volta a ser inédito para aquela busca.

O QUE VOCÊ NÃO GANHA

Não sai modelo. Não devolve um `best_estimator_` para produção — ele mede o PROCESSO. O modelo sai de uma busca final em toda a base.

Não melhora nada. A nota fica abaixo do `best_score_` porque o otimismo foi removido. O modelo é o mesmo; a régua é que ficou honesta.

Não dispensa a regra de ouro. É a MESMA regra de sempre — quem escolhe não mede — só que aplicada K vezes em vez de uma.

O ERRO DE LEITURA MAIS COMUM

Ver a nota do Nested (0,83) menor que o `best_score_` (0,88) e concluir que o modelo piorou. **Não piorou — os dois números medem coisas diferentes:** 0,88 é o melhor de nove tentativas na validação; 0,83 é o que se espera em dados novos. A diferença entre eles É o otimismo da busca.

A analogia da prova

Laço interno = simulados

- **Para que serve** — decidir qual método de estudo é o melhor.
- **O cuidado** — o melhor simulado calhou de ter o que você mais sabia — não é a sua nota real.

Laço externo = prova real

- **Para que serve** — medir, com questões inéditas, quão bom é 'escolher pelo simulado e estudar'.
- **É a nota que vale** — questões que a escolha nunca viu.

Medir-se pelo melhor simulado superestima; a prova real (dados novos) é o número honesto.

Qual dos dois usar

a sua situação	o que basta	por quê
Base grande, com um teste separado que ninguém nunca tocou	GridSearchCV no treino + 1 medição no teste	o teste já é, por construção, o pedaço que a escolha não viu
Base pequena: reservar 30% para teste dói de verdade	Nested CV	todo dado é medido uma vez; a nota ainda vem com desvio
Você já olhou o teste — refinou a grade depois de ver o resultado nele	Nested CV	aquele teste deixou de ser imparcial ao influenciar uma decisão
Você precisa do modelo que vai para produção	GridSearchCV em toda a base	só ele devolve best_params_ e best_estimator_
Você precisa anunciar "espero ~0,83 em dados novos"	Nested CV antes, GridSearchCV depois	um dá o número que você anuncia; o outro, o modelo que você entrega

NA PRÁTICA, OS DOIS JUNTOS

Primeiro o Nested CV, para **auditar o processo** e chegar ao número que você vai anunciar. Depois uma única busca em **toda** a base, para produzir o modelo que vai para produção. O Nested responde "**quão confiável é o meu jeito de escolher?**"; a busca final responde "**qual C eu entrego?**".

Resumo: quando usar

- **Use Nested CV quando** — você ajusta hiperparâmetros E quer reportar um desempenho honesto na mesma base pequena.
- **Não precisa quando** — você já tem um teste separado e intocado: busca no treino + 1 medição no teste já basta.
- **A regra de ouro** — quem escolhe não mede — sempre em dados separados.

EM UMA FRASE

Interno escolhe · externo mede · a nota honesta é a média das rodadas externas