

Gabarito

Como o desafio foi montado — e por que o seu caderno é diferente do meu

Todos receberam os **mesmos seis exercícios**, mas em **ordem embaralhada** e com **CSVs gerados individualmente**. Por isso a correção é por TIPO de exercício, e cada resposta foi conferida contra o gabarito calculado a partir dos dados daquele aluno.

O QUE ERA IGUAL PARA TODOS

Os seis enunciados, palavra por palavra, e o código de cada célula.

A estrutura dos dados: mesma quantidade de linhas, mesmas colunas, mesmo tipo de armadilha em cada exercício.

Os pesos de cada exercício e de cada item.

O QUE MUDAVA DE ALUNO PARA ALUNO


Os números dentro dos CSVs — logo, todos os VP, FP, FN, recall, AUC, MAE, R^2 e a profundidade da árvore.

A ordem em que os seis exercícios apareciam no caderno.

Consequência: a resposta certa do colega pode ser um número diferente do seu. O que vale é a conta bater com os SEUS dados.

Nestes slides eu uso o conjunto de referência do professor. Compare o raciocínio, não os valores.

Exercício 1 (1,5) — Dois modelos e o custo do erro



O ENUNCIADO

Um modelo detecta **falha** em um equipamento. Um **FN** (falha não detectada) causa uma parada cara; um **FP** (alarme falso) é barato (só uma checagem). O gráfico mostra a matriz de confusão de dois modelos, A e B.

O QUE A RESPOSTA DEVERIA CONTER

a) (0,60) Calcule o **recall** e a **precisão** de A e de B.

Resp. esperada — os **quatro números**: recall e precisão de A e de B, 0,15 cada, calculados com os dados do SEU caderno.


b) (0,45) Qual modelo você escolhe para ESTE caso? Justifique pelo **custo dos erros**.

Resp. esperada — escolher o **modelo A** (0,25) e justificar **pelo custo do FN** (0,20) — a falha não detectada é o erro caro, o alarme falso não.

c) (0,45) O que você faria com o **limiar** do modelo escolhido para melhorar ainda mais o que importa aqui? Explique o efeito em recall e precisão.

Resp. esperada — **baixar** o limiar (0,20), dizer que o **recall sobe** (0,125) e que a **precisão cai** (0,125).

Exercício 2 (1,5) — Acurácia alta = modelo bom?



O ENUNCIADO

O código dá VP, VN, FP, FN (limiar 0,5), a proporção de positivos e as curvas ROC e PR.

O QUE A RESPOSTA DEVERIA CONTER

a) (0,45) Calcule **acurácia**, **recall** e **precisão** a partir de VP, VN, FP e FN.

Resp. esperada — acurácia, recall e precisão — 0,15 cada, a partir de VP, VN, FP e FN.


b) (0,60) O desenvolvedor disse que o modelo é bom **porque a acurácia é alta**. Ele está certo? Justifique usando a **proporção de positivos** e o que a ROC e a PR mostram.

Resp. esperada — dizer que **não** está certo (0,15); apontar a **classe rara**, citando a proporção de positivos (0,20); e a segunda metade da justificativa (0,25): **a ROC é otimista no desbalanceado OU a PR lida contra a linha de base**.

c) (0,45) Se o modelo passasse a acertar **2 dos FN** (viram VP), qual seria o **novo recall**? Mostre a conta.

Resp. esperada — montar $(VP+2) \div (VP+FN)$ mantendo o denominador (0,25) e dar o **valor** (0,20).

Exercício 3 (2,0) — Limiar, matriz de confusão e ROC



O ENUNCIADO

O gráfico mostra a nota de 15 e-mails (cor = spam real ou não) com o limiar em **0,5** (spam = positivo).

O QUE A RESPOSTA DEVERIA CONTER

a) (0,50) Com o limiar 0,5, defina VP, VN, FP e FN.

Resp. esperada — VP, VN, FP e FN contados no gráfico — 0,125 cada.

b) (0,40) O ideal é o **maior recall possível**. O que fazer com o limiar? Explique.

Resp. esperada — **baixar** o limiar (0,25) e explicar o mecanismo (0,15): mais e-mails passam a ser chamados de spam, então menos FN.

(continuação)



c) (0,40) Avalie a **ROC/AUC**: o que ela representa e o que faria a curva melhorar?

Resp. esperada — o que a **AUC mede** (0,25): a probabilidade de dar nota maior a um spam do que a um não-spam sorteados ao acaso — a separação em todos os limiares; e o que a **melhoria** (0,15): notas que separem melhor as classes, não mexer no limiar.

d) (0,70) Agora suba o limiar para **0,7**: dê os **novos VP, FP e FN** e **recalcule precisão e recall**. Compare com o de 0,5.

Resp. esperada — os **novos VP, FP e FN** em 0,7 (0,25); o **recall recalculado** (0,15); a **precisão recalculada** (0,15); e a **comparação explícita com 0,5** (0,15).

Exercício 4 (1,5) — Log loss: o preço da confiança errada



O ENUNCIADO

Dois modelos (A e B) preveem os mesmos 5 exemplos.

acurácia A: 0.8 | acurácia B: 0.8
log loss A: 0.435 | log loss B: 0.875

O QUE A RESPOSTA DEVERIA CONTER

a) (0,50) Os dois têm a MESMA acurácia. Por que o **log loss** difere?

Resp. esperada — B erra um exemplo com muita confiança — o log loss pesa a PROBABILIDADE dada à classe certa, a acurácia só olha a decisão binária. Item único: a resposta fecha ou não fecha.

b) (0,40) Qual modelo é preferível e por quê?


Resp. esperada — escolher o A (0,20) e justificar pela **calibração / menor log loss** (0,20).

c) (0,60) Olhando a **perda por exemplo** de B, qual exemplo mais pesa no log loss? Explique com o valor.

Resp. esperada — identificar o **exemplo de maior perda** (0,30), citar o **valor** dessa perda (0,20) e dizer **por que ele domina a soma** (0,10) — o enunciado escreve "explique com o valor".


Exercício 5 (2,0) — MAE, RMSE, R² e MAPE: qual usar?

Coluna A — grande, com outlier
MAE=15.94 RMSE=32.93 R²=0.182 MAPE=5.8%



Resp. esperada — não dá para comparar (0,20), porque MAE e RMSE ficam na unidade de cada coluna (0,20).

Coluna B — pequena, perto de zero
MAE=0.36 RMSE=0.4 R²=0.966 MAPE=238.7%



escalas (0,15).

e) (0,40) Se o MAIOR erro da Coluna A dobrasse, qual muda mais: **MAE** ou **RMSE**? Por quê?

Resp. esperada — o **RMSE** muda mais (0,20), porque **eleva ao quadrado** — dobrar o erro quadruplica a contribuição — enquanto o MAE cresce em linha reta (0,20).

Exercício 5 (2,0) — MAE, RMSE, R^2 e MAPE: qual usar?

O QUE A RESPOSTA DEVERIA CONTER

a) (0,40) Na Coluna A, por que MAE e RMSE ficam tão diferentes?

Resp. esperada — o RMSE **eleva o erro ao quadrado** (0,20) e por isso **o outlier domina** a conta (0,20).

b) (0,40) Dá para comparar o MAE da Coluna A com o da Coluna B para dizer onde o modelo é melhor? Por quê?

Resp. esperada — **não** dá para comparar (0,20), porque MAE e RMSE ficam **na unidade de cada coluna** (0,20).

O ENUNCIADO

MAE, RMSE, R^2 e MAPE para duas colunas de escalas diferentes.

(continuação)

c) (0,40) Por que o MAPE da Coluna B fica tão alto?

Resp. esperada — o MAPE **divide pelo valor real** (0,20) e valores **perto de zero** fazem o percentual explodir (0,20).


d) (0,40) Qual medida é a mais adequada para julgar o modelo? Justifique.

Resp. esperada — escolher o R^2 (0,25), porque é **adimensional** e portanto comparável entre escalas (0,15).

e) (0,40) Se o MAIOR erro da Coluna A **dobrasse**, qual muda mais: **MAE** ou **RMSE**? Por quê?

Resp. esperada — o **RMSE** muda mais (0,20), porque **eleva ao quadrado** — dobrar o erro quadruplica a contribuição — enquanto o MAE cresce em linha reta (0,20).

Exercício 6 (1,5) — Overfitting × underfitting



O ENUNCIADO

A acurácia de treino e teste por profundidade da árvore.

O QUE A RESPOSTA DEVERIA CONTER

a) (0,40) Aponte a região de **underfitting** e a de **overfitting**.

Resp. esperada — underfitting nas profundidades **baixas** (0,20); overfitting nas **altas**, compatível com o pico do teste do SEU gráfico (0,20).

b) (0,35) O que acontece com treino e teste em cada região?

Resp. esperada — underfitting: **treino e teste baixos** (0,175); overfitting: **o treino sobe rumo a 1,0 e o teste estaciona ou cai** (0,175).

(continuação)

c) (0,30) Qual complexidade você escolheria e por quê?

Resp. esperada — o critério — a profundidade de **acurácia de TESTE máxima** (0,15) — e o **número** (0,15).

d) (0,45) A partir de qual profundidade o **vão treino–teste** começa a se abrir, e o que isso indica?

Resp. esperada — a profundidade em que o **vão abre** (0,25) e **o que isso indica**: overfitting, perda de generalização (0,20).