

Aula 08 — Busca de hiperparâmetros (Grid Search)

PARTE 1

Relembrando os conceitos

1

Parâmetro × hiperparâmetro, e a regra de ouro

O que o modelo aprende sozinho, o que você define, e quem pode escolher.

PARÂMETRO × HIPERPARÂMETRO

Parâmetro: o modelo APRENDE no fit. Os pesos da logística, os cortes de cada nó da árvore.

Hiperparâmetro: VOCÊ define antes de treinar. O C da regularização, a profundidade máxima da árvore, o k do k-NN.

Na analogia do bolo: o tempo e a temperatura são hiperparâmetros; como a massa cresce por dentro é o parâmetro.

A REGRA DE OURO

Treino aprende, VALIDAÇÃO escolhe, TESTE confirma — uma vez só.

Quem escolhe não mede. A busca inteira vive na validação cruzada, dentro do treino.

O teste fica guardado e é tocado uma única vez, no fim, com o campeão (Aula 05).

É a questão 2 — a que mais derrubou a turma. Voltamos a ela na Parte 2.

A busca exaustiva e a conta do custo

O GridSearchCV testa TODAS as combinações da grade, cada uma com validação cruzada.

$$\text{treinos} = (\text{opções do eixo 1}) \times (\text{opções do eixo 2}) \times \dots \times (\text{dobras da CV})$$

grade	combinações	treinos (5 dobras)
C {0,1; 1; 10} × class_weight {None, balanced}	3 × 2 = 6	6 × 5 = 30
+ um eixo com 4 opções	6 × 4 = 24	24 × 5 = 120

O QUE A CONTA ENSINA

Cada eixo novo **MULTIPLICA** o total — não soma.

É por isso que a grade **explode** e a Aula 09 troca o "testar tudo" por sortear com orçamento.

Boa prática: comece com uma grade pequena e refine em volta do melhor.

Exaustiva = a grade inteira, sem atalho. Sortear combinações é a busca ALEATÓRIA, assunto de hoje.

O que sai da busca: quatro atributos, quatro papéis

Confundir os quatro é o que derrubou as questões 12 e 15.

atributo	o que é	serve para
best_params_	um DICIONÁRIO: a combinação de melhor média de CV	saber o que venceu
best_score_	a MÉDIA de CV dessa combinação (validação, não teste)	escolher — não para reportar
best_estimator_	o Pipeline com a melhor combinação, JÁ TREINADO (refit=True)	levar ao teste: .predict direto
cv_results_	a TABELA completa: média e desvio de cada combinação	ver o platô e o pódio inteiro

O NÚMERO QUE SE REPORTA

O do teste, tocado uma vez com o `best_estimator_`. O `best_score_` é o máximo de várias médias ruidosas — tende a ser otimista (maldição do vencedor, Aula 07).

Lendo o resultado: platô e sinal de alerta

Na tabela da aula: $0,61 \cdot 0,68 \cdot 0,71 \cdot 0,79 \cdot 0,70 \cdot 0,74$ — venceu C = 1, balanced.

O PLATÔ

Diferença dentro do desvio não é diferença.

Se várias combinações empatam, escolha a mais SIMPLES: é mais estável e mais fácil de defender.

Por isso se olha o `cv_results_` inteiro, e não só o topo.

VALIDAÇÃO × TESTE

Teste perto do `best_score_` ($0,76 \times 0,79$): cenário saudável.

Teste MUITO abaixo: a busca se sobreajustou — grade grande para poucos dados, topo por sorte nas dobras.

O que fazer: encolher a grade, CV mais robusta, desconfiar de vazamento.


"Sobreajustar a busca" é exatamente a dúvida que a turma deixou no formulário. Ela ganha a Parte 3 inteira.

A dúvida, e o que quer dizer "forçar" a validação

Pergunta da turma: "Uma dúvida que fiquei é: como a gente percebe, na prática, que uma busca de hiperparâmetros está começando a forçar demais os dados da validação?"

Sinal 1 — a validação sobe, a nested CV não acompanha

Árvore de decisão (Aula 01) nas músicas: grades cada vez maiores de `max_depth` (profundidade) × `min_samples_leaf` (mínimo de exemplos por folha).



LENDO O GRÁFICO

Até 16 combinações as duas linhas andam juntas: a diferença é de 0,01.


De 16 para 196 o `best_score_` sobe (0,378 → 0,433), mas a `nested CV` não sai do lugar (0,367 → 0,359).

A distância entre as duas linhas é o termômetro: 0,011 com 16 combinações, 0,074 com 196. O modelo não melhorou; a escolha é que ficou mais sortuda.

A `nested CV` (Aula 07) mede com dobras que a busca não viu — por isso ela revela o otimismo sem gastar o teste guardado.

Sinal 2 — o teste do placebo: embaralhe os rótulos

Com o alvo sorteado, não há padrão nenhum a aprender. Tudo o que a busca "achar" é sorte.



O QUE APARECEU

Com uma combinação só: AP 0,147 — perto do acaso (0,122).

Com 1.960 combinações (4 hiperparâmetros da árvore): AP 0,196, 60% acima do acaso, com rótulos SEM sentido.

Esse excesso é a medida do quanto a busca consegue "forçar" a validação só por testar muitas opções.

```
y_falso = y_tr.sample(frac=1, random_state=0).values # embaralha o alvo
GridSearchCV(pipe, grade, cv=cv, scoring="average_precision").fit(X_tr, y_falso).best_score_
```

Sinal 3 — troque a semente da CV e veja se o vencedor muda

A mesma busca, 10 vezes, só mudando o random_state do StratifiedKFold.

busca	vencedores diferentes em 10 rodadas	best_score_ variou de	leitura
grade da Aula 08 nas músicas (6 combinações, logística)	3	0,691 a 0,753	as 6 empatam: 0,706 a 0,721, desvio $\pm 0,09$ — é platô
grade grande nas músicas (196 combinações, árvore de decisão)	9	0,382 a 0,489	o "campeão" é quase sorteado pela divisão das dobras

COMO LER

Se o vencedor troca a cada semente, a busca não está achando um ótimo: está escolhendo entre empatados pelo ruído.

Note o tamanho do balanço: de 0,06 a 0,11 só por trocar a semente — mais que a diferença entre as primeiras combinações.

O QUE FAZER

Olhe o cv_results_ com o desvio e trate como empate o que cabe dentro dele.

Prefira o mais simples do platô.

Use RepeatedStratifiedKFold para uma média menos dependente da semente.

Resumo da dúvida: cinco sinais e o que fazer

Nenhum sinal sozinho prova nada. Dois ou três juntos, sim.

OS SINAIS DE QUE A BUSCA ESTÁ FORÇANDO

1. O `best_score_` sobe com a grade, mas a nested CV não sobe junto.
2. Com rótulos embaralhados, a busca fica bem acima do acaso.
3. O vencedor muda quando você troca a semente da CV.
4. As primeiras colocadas diferem menos que o desvio entre dobras.
5. O vencedor está na BORDA da grade, num valor extremo e isolado.

O QUE FAZER

Encolha a grade: poucos valores, só nos hiperparâmetros que importam.

Deixe a CV mais robusta: mais dobras ou repetida (RepeatedStratifiedKFold).

Meça com quem não escolheu: nested CV ou teste guardado, tocado uma vez.

Na aula de hoje (09) isso volta: a busca aleatória controla quantas tentativas você faz — e menos tentativas, menos chance de forçar.

PARTE 4

O questionário, questão a questão

As 16 perguntas do formulário — a pergunta, depois a resposta.



Questão 1 de 16

Qual destes é um HIPERPARÂMETRO (e não um parâmetro)?

- A os pesos aprendidos por uma regressão logística
- B a profundidade máxima de uma árvore de decisão
- C os pontos de corte que a árvore escolhe em cada nó
- D o coeficiente angular estimado numa regressão linear

Pense antes de virar o slide.

Questão 1 — resposta

Qual destes é um HIPERPARÂMETRO (e não um parâmetro)?

B) a profundidade máxima de uma árvore de decisão

CORRETA

POR QUÊ?

Parâmetro é o que o modelo APRENDE durante o fit (pesos, cortes, coeficientes). Hiperparâmetro é o que VOCÊ define antes de treinar: C da regularização, profundidade da árvore, k do k-NN. Na analogia do bolo, o parâmetro é como a massa cresce; o hiperparâmetro é o tempo e a temperatura que você escolheu.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 2 de 16

A regra de ouro do ajuste de hiperparâmetros é:

- A treino aprende, teste escolhe, validação confirma
- B escolher pelo teste e confirmar na validação, que é maior
- C usar o mesmo conjunto para escolher e para medir, desde que a CV tenha muitas dobras
- D treino aprende, VALIDAÇÃO escolhe, TESTE confirma — uma vez só

Pense antes de virar o slide.

Questão 2 — resposta

A regra de ouro do ajuste de hiperparâmetros é:

D) treino aprende, VALIDAÇÃO escolhe, TESTE confirma — uma vez só

CORRETA

POR QUÊ?

Quem escolhe não mede. A busca inteira vive na validação; o teste é tocado uma única vez, no fim, com o campeão. Testar muitas opções no teste "gasta" a imparcialidade dele — é vazamento.

O tropeço da turma — dois respondentes erraram: um marcou "treino aprende, teste escolhe, validação confirma" (papéis invertidos); outro, "o mesmo conjunto, desde que a CV tenha muitas dobras" (mais dobras não curam a seleção).

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 3 de 16

O GridSearchCV é chamado de busca EXAUSTIVA porque:

- A testa a grade inteira, sem deixar nenhuma combinação de fora
- B roda até o desempenho parar de melhorar
- C esgota a memória da máquina em grades grandes
- D sorteia combinações até cobrir a maior parte do espaço

Pense antes de virar o slide.

Questão 3 — resposta

O GridSearchCV é chamado de busca EXAUSTIVA porque:

A) testa a grade inteira, sem deixar nenhuma combinação de fora

CORRETA

POR QUÊ?

Você define as opções de cada hiperparâmetro; ele varre todas as combinações, avalia cada uma por validação cruzada e fica com a de melhor média. Sortear combinações é a busca ALEATÓRIA, que vem na Aula 09 justamente porque a grade cheia fica cara.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 4 de 16

Na grade do bolo (3 tempos $\times$ 3 temperaturas), quantas combinações são testadas e qual venceu?

- A 6 combinações; venceu 30 min $\times$ 180 °C
- B 3 combinações; venceu 50 min $\times$ 200 °C
- C 9 combinações; venceu 40 min $\times$ 180 °C, com nota 9,0
- D 9 combinações; venceu 40 min $\times$ 200 °C, com nota 7,0

Pense antes de virar o slide.

Questão 4 — resposta

Na grade do bolo (3 tempos $\times$ 3 temperaturas), quantas combinações são testadas e qual venceu?

C) 9 combinações; venceu 40 min $\times$ 180 °C, com nota 9,0

CORRETA

POR QUÊ?

A grade é o produto dos eixos: $3 \times 3 = 9$ duplas. A melhor nota da tabela é 9,0, em 40 min $\times$ 180 °C. É exatamente o que o GridSearchCV faz, trocando tempo e temperatura por C e class_weight.

O tropeço da turma — um respondente marcou "40 min $\times$ 200 °C, nota 7,0" — o 7,0 está na tabela, mas não é a maior nota.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 5 de 16

Com a grade $C \in \{0,1; 1; 10\} \times \text{class_weight} \in \{\text{None}, \text{balanced}\}$ e uma CV de 5 dobras, quantos modelos são TREINADOS?

- A 6, um por combinação
- B 5, um por dobra
- C 11, a soma das opções com as dobras
- D 30 — $3 \times 2 = 6$ combinações, cada uma avaliada em 5 dobras

Pense antes de virar o slide.

Questão 5 — resposta

Com a grade $C \in \{0,1; 1; 10\} \times \text{class_weight} \in \{\text{None}, \text{balanced}\}$ e uma CV de 5 dobras, quantos modelos são TREINADOS?

D) 30 — $3 \times 2 = 6$ combinações, cada uma avaliada em 5 dobras

CORRETA

POR QUÊ?

A conta é (opções do eixo 1) $\times$ (opções do eixo 2) $\times \dots \times$ (nº de dobras). $3 \times 2 \times 5 = 30$ modelos treinados só para uma grade pequena. É o preço da busca exaustiva.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 6 de 16

Acrescentando à mesma grade um terceiro hiperparâmetro com 4 opções, o número de treinos passa de 30 para:

- A 34 — soma-se o novo eixo
- B 120 — cada eixo novo MULTIPLICA o total
- C 38 — somam-se as 4 opções às 5 dobras
- D 30 — o número de dobras não muda

Pense antes de virar o slide.

Questão 6 — resposta

Acrescentando à mesma grade um terceiro hiperparâmetro com 4 opções, o número de treinos passa de 30 para:

B) 120 — cada eixo novo MULTIPLICA o total

CORRETA

POR QUÊ?

$6 \times 4 = 24$ combinações $\times 5$ dobras = 120 treinos. Cada eixo novo multiplica tudo. É essa explosão que motiva a busca aleatória da Aula 09 — e a boa prática de começar com uma grade pequena e refinar.

O tropeço da turma — um respondente marcou "38 — somam-se as opções às dobras". As opções se multiplicam: $6 \times 4 \times 5 = 120$.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 7 de 16

A tabela da aula deu estas médias de CV (AP): C=0,1/None 0,61 · C=0,1/balanced 0,68 · C=1/None 0,71 · C=1/balanced 0,79 · C=10/None 0,70 · C=10/balanced 0,74. O que o GridSearchCV guarda em `best_params_` e `best_score_`?

A `best_params_ = {C: 1, class_weight: balanced}` e `best_score_ = 0,79`

B `best_params_ = {C: 10, class_weight: balanced}` e `best_score_ = 0,74`

C `best_params_ = {C: 1, class_weight: balanced}` e `best_score_ = 0,71`

D `best_params_ =` a média das seis combinações, 0,705

Pense antes de virar o slide.

Questão 7 — resposta

A tabela da aula deu estas médias de CV (AP): C=0,1/None 0,61 · C=0,1/balanced 0,68 · C=1/None 0,71 · C=1/balanced 0,79 · C=10/None 0,70 · C=10/balanced 0,74. O que o GridSearchCV guarda em `best_params_` e `best_score_`?

A) `best_params_ = {C: 1, class_weight: balanced}` e `best_score_ = 0,79`

CORRETA

POR QUÊ?

`best_params_` é a combinação de MELHOR MÉDIA de CV e `best_score_` é essa média. Atenção: 0,79 é validação, não teste.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 8 de 16

Numa busca sobre um Pipeline, por que a grade é escrita como `{"clf__C": [0.1, 1, 10]}` e não `{"C": [0.1, 1, 10]}`?

- A porque o underscore duplo indica que o valor é uma lista
- B porque "clf" é o nome da métrica usada no scoring
- C porque o prefixo `nome_do_passo__parametro` diz a QUAL passo do Pipeline o hiperparâmetro pertence
- D porque o sklearn exige nomes com prefixo em qualquer busca, com ou sem Pipeline

Pense antes de virar o slide.

Questão 8 — resposta

Numa busca sobre um Pipeline, por que a grade é escrita como `{"clf__C": [0.1, 1, 10]}` e não `{"C": [0.1, 1, 10]}`?

C) porque o prefixo `nome_do_passo__parametro` diz a QUAL passo do Pipeline o hiperparâmetro pertence

CORRETA

POR QUÊ?

O Pipeline tem vários passos nomeados; sem o prefixo o GridSearchCV não sabe em qual deles mexer e levanta erro. Errar o prefixo (ou o scoring) faz a busca otimizar a coisa errada: a grade fica certa, mas a escolha não.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 9 de 16

Num problema com classe rara, definir `scoring="accuracy"` na busca é um erro porque:

- A a acurácia não é aceita pelo GridSearchCV em problemas binários
- B prever sempre a classe majoritária já dá acurácia alta — a busca escolheria o modelo que ignora a classe rara
- C a acurácia só pode ser usada com validação cruzada estratificada
- D a acurácia é sempre menor que o F1, então subestima o modelo

Pense antes de virar o slide.

Questão 9 — resposta

Num problema com classe rara, definir `scoring="accuracy"` na busca é um erro porque:

B) prever sempre a classe majoritária já dá acurácia alta — a busca escolheria o modelo que ignora a classe rara

CORRETA

POR QUÊ?

Com 1% de positivos, prever "negativo" para todo mundo dá 99% de acurácia e zero utilidade. Escolha a métrica que importa: F1, `average_precision` ou `roc_auc`. O `scoring` é o que a busca está de fato maximizando.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 10 de 16

Em classificação, o cv recomendado na busca é o StratifiedKFold porque ele:

- A é mais rápido que o KFold comum
- B embaralha os dados, o que o KFold não faz
- C usa todas as dobras para treino e nenhuma para validação
- D preserva a proporção das classes em cada dobra — sem isso a classe rara pode sumir de uma delas

Pense antes de virar o slide.

Questão 10 — resposta

Em classificação, o cv recomendado na busca é o StratifiedKFold porque ele:

D) preserva a proporção das classes em cada dobra — sem isso a classe rara pode sumir de uma delas

CORRETA

POR QUÊ?

Se uma dobra ficar sem nenhum positivo, a métrica daquela dobra vira lixo e contamina a média que decide o vencedor. O shuffle é uma opção tanto do KFold quanto do StratifiedKFold — o que distingue é a estratificação.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 11 de 16

Por que o GridSearchCV deve receber o PIPELINE inteiro, e não só o classificador com os dados já pré-processados?

- A porque o Pipeline deixa a busca mais rápida
- B porque só o Pipeline aceita o parâmetro scoring
- C porque assim o pré-processamento é reajustado dentro de cada dobra, usando só o treino dela — pré-processar antes vaza informação da validação
- D porque fora do Pipeline o sklearn não consegue calcular best_score_

Pense antes de virar o slide.

Questão 11 — resposta

Por que o GridSearchCV deve receber o PIPELINE inteiro, e não só o classificador com os dados já pré-processados?

C) porque assim o pré-processamento é reajustado dentro de cada dobra, usando só o treino dela — pré-processar antes vaza informação da validação

CORRETA

POR QUÊ?

É o mesmo cuidado da Aula 07: quem faz o fit do scaler/imputer no conjunto inteiro já deixou a média e o desvio da validação entrarem no treino. O resultado sai otimista e você só descobre no teste.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 12 de 16

A busca terminou com `best_score_ = 0,79` e o teste, tocado uma vez com o `best_estimator_`, deu 0,76. O número que você reporta é:

A 0,76 — o teste é a palavra final; o `best_score_` serviu para escolher, não para reportar

B 0,79 — é a melhor estimativa, obtida com validação cruzada em várias dobras

C a média dos dois, 0,775

D 0,79, informando que o teste foi apenas uma verificação

Pense antes de virar o slide.

Questão 12 — resposta

A busca terminou com `best_score_` = 0,79 e o teste, tocado uma vez com o `best_estimator_`, deu 0,76. O número que você reporta é:

A) 0,76 — o teste é a palavra final; o `best_score_` serviu para escolher, não para reportar

CORRETA

POR QUÊ?

`best_score_` ajuda a ESCOLHER; quem mede é o teste. Aliás, 0,76 perto de 0,79 é o cenário saudável — a busca não se sobreajustou.

O tropeço da turma — um respondente marcou "0,79, a melhor estimativa". Ela serviu para escolher; quem mede é o teste.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 13 de 16

Por que o `best_score_` tende a ser um pouco OTIMISTA?

- A porque a validação cruzada sempre superestima o desempenho
- B porque ele é calculado no conjunto de treino
- C porque o sklearn arredonda o valor para cima
- D porque é o MÁXIMO de muitas medições ruidosas — quem ficou no topo teve, em parte, sorte nas dobras

Pense antes de virar o slide.

Questão 13 — resposta

Por que o `best_score_` tende a ser um pouco OTIMISTA?

D) porque é o MÁXIMO de muitas medições ruidosas — quem ficou no topo teve, em parte, sorte nas dobras

CORRETA

POR QUÊ?

É a maldição do vencedor, vista na Aula 07. Cada média de CV tem ruído; pegar o maior de várias delas seleciona também o ruído favorável. Quanto maior a grade, maior o viés.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 14 de 16

Olhando o `cv_results_`, três combinações empatam dentro do desvio-padrão. O que fazer?

- A aumentar o número de dobras até uma delas se destacar
- B reconhecer o platô e escolher a combinação mais SIMPLES entre as empatadas
- C ficar com a de maior média, mesmo que a diferença esteja dentro do desvio
- D descartar as três e ampliar a grade em volta delas

Pense antes de virar o slide.

Questão 14 — resposta

Olhando o `cv_results_`, três combinações empatam dentro do desvio-padrão. O que fazer?

B) reconhecer o platô e escolher a combinação mais SIMPLES entre as empatadas

CORRETA

POR QUÊ?

Diferença dentro do desvio não é diferença. Num platô, o modelo mais simples (menos regularização exótica, menos profundidade) é mais estável e mais fácil de defender. Por isso vale sempre inspecionar a tabela inteira, e não só o topo.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 15 de 16

Sobre o `busca.best_estimator_`, é CORRETO afirmar:

- A é o Pipeline com a melhor combinação, JÁ TREINADO — é ele que você leva ao teste
- B é apenas um dicionário com os melhores valores encontrados
- C é o modelo com os hiperparâmetros certos, mas ainda sem treino: é preciso chamar `fit` antes de usar
- D é a tabela completa com a média e o desvio de cada combinação

Pense antes de virar o slide.

Questão 15 — resposta

Sobre o `busca.best_estimator_`, é CORRETO afirmar:

A) é o Pipeline com a melhor combinação, JÁ TREINADO — é ele que você leva ao teste

CORRETA

POR QUÊ?

O dicionário com os valores é o `best_params_`; a tabela completa é o `cv_results_`. O `best_estimator_` já vem ajustado (por padrão, `refit=True` treina no conjunto de treino inteiro), pronto para o `predict` no teste.

O tropeço da turma — um respondente marcou "ainda sem treino". Com `refit=True`, o `best_estimator_` já vem treinado no treino inteiro.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Questão 16 de 16

O teste ficou MUITO abaixo do `best_score_` da validação. A leitura mais provável é:

- A o teste está pequeno demais e deve ser ampliado com dados da validação
- B o modelo está subajustado e a grade precisa de valores mais extremos
- C a busca se sobreajustou — grade grande demais para o tamanho dos dados, e o topo veio de sorte nas dobras
- D houve erro de código: os dois números têm de coincidir

Pense antes de virar o slide.

Questão 16 — resposta

O teste ficou MUITO abaixo do `best_score_` da validação. A leitura mais provável é:

C) a busca se sobreajustou — grade grande demais para o tamanho dos dados, e o topo veio de sorte nas dobras

CORRETA

POR QUÊ?

É o sinal de alerta da aula. O caminho é encolher a grade, usar uma CV mais robusta (mais dobras ou repetida) e desconfiar de vazamento no pré-processamento. Alguma diferença é normal — o problema é a diferença GRANDE.

Formulário da Aula 08 · 5 respostas · média 14,8 de 16

Para levar desta revisão

O QUE JÁ ESTÁ FIRME

Parâmetro × hiperparâmetro e o que é busca exaustiva: acerto de todo mundo.

A montagem da busca: prefixo, scoring, CV estratificada e Pipeline — 100% nas questões 8 a 11.

A leitura do resultado: `best_score_` otimista, platô e sinal de alerta.

O QUE VALE REVISAR

Quem escolhe não mede. O teste confirma uma vez; muitas dobras não substituem isso.

O `best_estimator_` já vem treinado e é ele que vai ao teste.

Eixos se multiplicam — e as dobras multiplicam de novo.

Busca que força a validação: validação sobe e nested não; placebo acima do acaso; vencedor instável.

Na aula de hoje (09): busca aleatória e AutoML — como buscar sem testar tudo.