

Aula 09 — Busca aleatória e AutoML

PARTE 1

Relembrando os conceitos

1

Por que sortear vence a grade com o mesmo orçamento

A grade multiplica; o sorteio não. E quase sempre poucos hiperparâmetros importam.

A floresta tem 5 hiperparâmetros. Uma grade modesta — $4 \times 5 \times 4 \times 4 \times 4$ — já dá **1.280 combinações** e, com 5 dobras, **6.400 treinos**. Cada hiperparâmetro novo MULTIPLICA o custo. O sorteio quebra essa conta: você diz quantas medições quer (`n_iter`) e o custo para de depender de quantos hiperparâmetros existem.

GRADE 4×4 — 16 medições

Testa 4 valores de cada um dos dois.

Se só um dos dois importa, você gastou 16 medições para ver 4 valores dele — os outros 12 pontos repetem os mesmos 4, em alturas diferentes do eixo que não importa.

ALEATÓRIA — 16 sorteios

Testa 16 valores DIFERENTES de cada um.

Projetado no eixo que importa, o sorteio cobre 16 posições em vez de 4. É daí que vem a vantagem — não de sorte, de cobertura.

Na base das músicas: grade 4×4 deu 0,615; aleatória de 16 sorteios (semente 0) deu 0,627.

A conta que justifica o sorteio

Qual a chance de pelo menos um dos n sorteios cair na região boa?

$$P(\text{acertar ao menos uma vez}) = 1 - (1 - p)^n$$

p = fração do espaço ocupada pela região boa • n = número de sorteios

p (a região boa ocupa...)	n = 10	n = 16	n = 30	n = 60
5 % do espaço	40 %	56 %	79 %	95 %
10 % do espaço	65 %	81 %	96 %	99,8 %
15 % do espaço	80 %	93 %	99 %	≈ 100 %

O QUE A CONTA NÃO TEM

O número de hiperparâmetros não aparece na fórmula: ela só depende de p e de n. Acrescentar um hiperparâmetro irrelevante não encarece a busca aleatória — numa grade, ele multiplicaria o custo por 4.

Ler o resultado: o pódio, o platô e a borda

O best_params_ é uma linha do cv_results_ — e sozinho ele engana.

posição	AP média	desvio entre dobras
1º	0,627	± 0,11
2º	0,624	± 0,10
3º	0,621	± 0,12
4º	0,617	± 0,11
5º	0,613	± 0,10

O QUE ISSO É

Um platô, não um pódio. A diferença entre o 1º e o 5º é 0,014; o desvio entre dobras é $\pm 0,11$ — oito vezes maior. A diferença cabe no ruído.

O que fazer: entre configurações empatadas, prefira a mais simples ou a mais estável, não a que ficou em primeiro por acaso.

O MELHOR NA BORDA DA FAIXA

Se o melhor ccp_alpha sai no MENOR valor que você definiu, o pico provavelmente está FORA da faixa: a busca foi até onde podia e parou na parede. Amplie e rode de novo. É o gatilho do "grosso ao fino": aleatória larga e em log primeiro, depois uma grade pequena em volta dos melhores — parando quando os números viram platô.

Os três números que saem da mesma busca

Só dois deles podem ser reportados como desempenho.

número	valor na aula	o que ele é	serve para...
best_score_	0,652	o MÁXIMO de 40 medições feitas na validação que escolheu	ESCOLHER — nunca reportar
nested CV	0,615 ± 0,126	a média de rodar a busca inteira dentro de cada dobra	reportar: é a estimativa mais estável
teste guardado	0,711	uma medição única, em dados nunca tocados	reportar, com a ressalva do tamanho

POR QUE O best_score_ NÃO VALE

Quem escolhe não mede (Aula 07). O best_score_ é o maior de 40 números medidos na MESMA validação que serviu para escolher — tomar o máximo de 40 medições ruidosas já é, por construção, otimista. E o 0,711 do teste guardado veio de 38 hits apenas: é um número com ruído alto, por isso vale dizer a faixa, não só o valor.

O mini-AutoML: o que ele automatiza, e o que não

Uma LISTA de espaços dentro do mesmo RandomizedSearchCV — não uma grade maior.

modelo (30 sorteios ao todo)	sorteios	melhor AP	mediana
logística	12	0,721	0,716
floresta	8	0,631	0,607
árvore	10	0,413	0,378

A LEITURA DESSA TABELA

- O espaço é **CONDICIONAL**, não uma grade maior: o C só existe se o sorteio cair na logística, o ccp_alpha só se cair na floresta. Uma grade cruzaria tudo com tudo e geraria combinações impossíveis.
- Escolher o **MODELO** pesou **0,31**; afinar o vencedor pesou **0,005**. Da logística (0,721) à árvore (0,413) vão 0,31; do melhor sorteio da logística à mediana dela, 0,005. Acrescentar sete modelos sem subir o n_iter dá ~3 sorteios por modelo, e a conta $1 - (1 - p)^n$ não fecha.
- O que ele **NÃO automatiza**: deixar a coluna popularidade entrar leva a AP de 0,721 para 0,936 — ele otimizaria com prazer uma variável que vaza o alvo.

PARTE 2

O questionário, questão a questão

2

Questão 1 de 16

A floresta do lab tem 5 hiperparâmetros; uma grade modesta dá $4 \times 5 \times 4 \times 4 \times 4 = 1.280$ combinações. Com 5 dobras, por que isso motiva a busca aleatória?

- A porque o GridSearchCV não aceita mais de dois hiperparâmetros
- B porque a grade perde precisão quando tem muitos eixos
- C porque seriam 6.400 treinos: cada hiperparâmetro novo MULTIPLICA o custo
- D porque combinações demais causam vazamento entre as dobras

Pense antes de virar o slide.

Questão 1 — resposta

A floresta do lab tem 5 hiperparâmetros; uma grade modesta dá $4 \times 5 \times 4 \times 4 \times 4 = 1.280$ combinações. Com 5 dobras, por que isso motiva a busca aleatória?

C) porque seriam 6.400 treinos: cada hiperparâmetro novo MULTIPLICA o custo

CORRETA

POR QUÊ?

$1.280 \times 5 = 6.400$ ajustes. O custo da grade é multiplicativo: um eixo novo com 4 valores multiplica tudo por 4. A busca aleatória troca isso por um ORÇAMENTO que você fixa (n_iter).

Questão 2 de 16

Com o MESMO orçamento de 16 medições, por que o sorteio costuma vencer a grade?

- A porque o sorteio repete menos combinações já testadas
- B porque a grade testa só 4 valores do hiperparâmetro que importa, enquanto o sorteio testa 16 valores diferentes dele
- C porque pontos aleatórios cobrem áreas maiores do espaço do que pontos alinhados
- D porque o sorteio evita as bordas da faixa, onde o desempenho costuma ser pior

Pense antes de virar o slide.

Questão 2 — resposta

Com o MESMO orçamento de 16 medições, por que o sorteio costuma vencer a grade?

B) porque a grade testa só 4 valores do hiperparâmetro que importa, enquanto o sorteio testa 16 valores diferentes dele

CORRETA

POR QUÊ?

É o argumento de Bergstra e Bengio (2012). Numa grade 4×4 , as 16 combinações caem em apenas 4 valores de cada eixo. Se um eixo quase não importa (o `max_features`, nas músicas) e o outro manda (a poda), a grade gastou 12 medições variando o que não serve. O sorteio dá 16 leituras diferentes do eixo que importa — sem você precisar saber de antemão qual é ele.

Questão 3 de 16

Na aula, a aleatória de 16 sorteios deu 0,627 contra 0,615 da grade. Repetir a busca com 100 sementes diferentes mostrou que:

- A metade das sementes ficou abaixo da grade: o ganho foi sorte
- B a média das 100 sementes é o número que se deve reportar
- C a semente 0 foi a melhor das 100, por isso o resultado pareceu bom
- D as 100 ficaram acima da grade (média 0,640), e a semente 0 ficou até abaixo da média

Pense antes de virar o slide.

Questão 3 — resposta

Na aula, a aleatória de 16 sorteios deu 0,627 contra 0,615 da grade. Repetir a busca com 100 sementes diferentes mostrou que:

D) as 100 ficaram acima da grade (média 0,640), e a semente 0 ficou até abaixo da média

CORRETA

POR QUÊ?

O experimento das 100 sementes serve para mostrar que o ganho não dependeu de sorte — e não para virar o número reportado. Na prática roda-se UMA busca, com `random_state` fixo. E a promessa da aleatória é de probabilidade: quase sempre dá bom, não é garantia.

Questão 4 de 16

Pela conta $1 - (1 - p)^n$, se a região boa ocupa $p = 15\%$ do espaço, 16 sorteios acertam ela com:

- A cerca de 93% de chance — e o número de hiperparâmetros não entra na conta
- B cerca de 15% de chance, a mesma de um sorteio
- C cerca de 60% de chance, caindo se houver mais hiperparâmetros
- D 100% de chance, desde que a faixa esteja bem escolhida

Pense antes de virar o slide.

Questão 4 — resposta

Pela conta $1 - (1 - p)^n$, se a região boa ocupa $p = 15\%$ do espaço, 16 sorteios acertam ela com:

A) cerca de 93% de chance — e o número de hiperparâmetros não entra na conta

CORRETA

POR QUÊ?

$1 - (1 - 0,15)^{16} \approx 0,93$. O mais importante é o que NÃO aparece na fórmula: o número de hiperparâmetros. Sejam 2 ou 20, o custo do sorteio é $n_{\text{iter}} \times \text{dobras}$; na grade, cada eixo novo multiplica. A ressalva é que p é a fração do espaço QUE VOCÊ definiu.

A armadilha — a alternativa que diz "93 %, mas mais hiperparâmetros derrubam essa chance". O número de hiperparâmetros NÃO entra em $1 - (1 - p)^n$: a conta só olha p e n .

Questão 5 de 16

No dicionário da busca, "clf__max_features": uniform(0.1, 0.8) sorteia valores entre:

- A 0,1 e 0,8 — início e fim
- B 0,1 e 0,08 — o segundo argumento é uma fração do primeiro
- C 0,1 e 0,9 — o segundo argumento é a LARGURA, somada ao início
- D 0 e 0,8 — o primeiro argumento é apenas o passo mínimo

Pense antes de virar o slide.

Questão 5 — resposta

No dicionário da busca, "clf__max_features": uniform(0.1, 0.8) sorteia valores entre:

C) 0,1 e 0,9 — o segundo argumento é a LARGURA, somada ao início

CORRETA

POR QUÊ?

É o erro mais comum na montagem do dicionário: o `scipy.stats.uniform` recebe (início, largura), não (início, fim). Logo `uniform(0.1, 0.8)` cobre de 0,1 a 0,9.

A armadilha — ler o segundo argumento como o fim da faixa ("de 0,1 a 0,8"). Em `uniform(a, b)`, `b` é a LARGURA: a faixa vai de `a` até `a + b`.

Questão 6 de 16

Por que o C da logística (faixa de 0,01 a 100) se sorteia com loguniform e não com uniform?

- A porque o loguniform evita valores negativos, que quebrariam o modelo
- B porque no uniform cerca de 90% dos sorteios cairiam entre 10 e 100, enquanto o loguniform dá 25% a cada ordem de grandeza
- C porque o uniform só aceita números inteiros
- D porque o loguniform concentra os sorteios perto do valor padrão do modelo

Pense antes de virar o slide.

Questão 6 — resposta

Por que o C da logística (faixa de 0,01 a 100) se sorteia com loguniform e não com uniform?

B) porque no uniform cerca de 90% dos sorteios cairiam entre 10 e 100, enquanto o loguniform dá 25% a cada ordem de grandeza

CORRETA

POR QUÊ?

No uniform a chance é proporcional ao TAMANHO do trecho, e o trecho de 10 a 100 ocupa quase todo o intervalo. O loguniform sorteia o expoente, então cada década (0,01–0,1; 0,1–1; 1–10; 10–100) recebe a mesma chance. Vale para tudo que varia por fator de 10 — C, ccp_alpha, learning_rate.

Questão 7 de 16

Depois da busca, o melhor `ccp_alpha` caiu exatamente no MENOR valor da faixa que você definiu. O que isso sugere?

- A que a busca convergiu: o ótimo foi encontrado
- B que o `n_iter` foi grande demais e houve sobreajuste da faixa
- C que a distribuição deveria ser uniform em vez de loguniform
- D que o pico pode estar FORA da faixa: convém ampliá-la e rodar de novo

Pense antes de virar o slide.

Questão 7 — resposta

Depois da busca, o melhor `ccp_alpha` caiu exatamente no MENOR valor da faixa que você definiu. O que isso sugere?

D) que o pico pode estar FORA da faixa: convém ampliá-la e rodar de novo

CORRETA

POR QUÊ?

Vencedor encostado na borda é sinal de faixa curta. O sorteio só é esperto dentro do espaço que você deu a ele — definir a faixa continua sendo trabalho de cientista de dados.

Formulário da Aula 09 · 2 respostas · 16 e 16 de 16

Questão 8 de 16

Uma RandomizedSearchCV com $n_iter = 40$ e $cv = 5$ custa quantos ajustes de modelo (sem contar o refit final)?

A 200 — $n_iter \times$ dobras, independentemente de quantos hiperparâmetros existam

B 40 — um por sorteio, porque a CV é feita uma vez só

C 1.280 — o mesmo da grade equivalente

D depende do número de hiperparâmetros sorteados

Pense antes de virar o slide.

Questão 8 — resposta

Uma RandomizedSearchCV com $n_iter = 40$ e $cv = 5$ custa quantos ajustes de modelo (sem contar o refit final)?

A) 200 — $n_iter \times$ dobras, independentemente de quantos hiperparâmetros existam

CORRETA

POR QUÊ?

$40 \times 5 = 200$. Esse é o ponto da busca aleatória: VOCÊ decide o custo pelo n_iter , e ele não cresce com o número de eixos do espaço.

A armadilha — achar que o custo cresce com o número de hiperparâmetros. Na busca aleatória o custo é $n_iter \times$ dobras e nada mais — é justamente isso que a separa da grade.

Questão 9 de 16

No `cv_results_` da busca, os cinco primeiros colocados vão de 0,627 a 0,613, com desvio entre dobras de $\pm 0,11$. A leitura correta é:

- A o primeiro lugar é claramente melhor: a diferença é de 0,014
- B a busca falhou e precisa de mais sorteios para separar os candidatos
- C é um platô: a diferença cabe no ruído, e vale preferir a configuração mais simples ou mais estável
- D o desvio alto indica vazamento no Pipeline

Pense antes de virar o slide.

Questão 9 — resposta

No `cv_results_` da busca, os cinco primeiros colocados vão de 0,627 a 0,613, com desvio entre dobras de $\pm 0,11$. A leitura correta é:

C) é um platô: a diferença cabe no ruído, e vale preferir a configuração mais simples ou mais estável

CORRETA

POR QUÊ?

Diferença dentro do desvio não é diferença. O `best_params_` é só a primeira linha de uma tabela ruidosa; olhar a tabela inteira é o que mostra o platô — e que o 1º lugar ganhou em parte por sorte.

Questão 10 de 16

A receita do "grosso ao fino" (coarse-to-fine) é:

- A** grade pequena primeiro, para achar a região, e depois aleatória larga para confirmar
- B** aleatória larga e em log primeiro, depois uma grade pequena em volta dos melhores pontos — parando quando os números viram platô
- C** aumentar o `n_iter` até o `best_score_` parar de subir
- D** rodar a busca várias vezes com sementes diferentes e ficar com o melhor resultado

Pense antes de virar o slide.

Questão 10 — resposta

A receita do "grosso ao fino" (coarse-to-fine) é:

**B) aleatória larga e em log primeiro, depois uma grade pequena em volta dos melhores pontos —
parando quando os números viram platô**

CORRETA

POR QUÊ?

Primeiro saltos longos para achar a encosta certa, depois passos curtos perto do cume. Refinar dentro do ruído é gastar orçamento à toa — nas músicas, o refino 4×4 não achou nada melhor que o ponto que a aleatória já tinha encontrado. E escolher a semente pelo resultado é trapaça.

Questão 11 de 16

Da mesma busca saíram três números: best_score_ 0,652, nested CV $0,615 \pm 0,126$ e teste guardado 0,711. Qual deles NÃO deve ser reportado como desempenho, e por quê?

- A o teste, porque foi medido uma vez só
- B a nested CV, porque usa dobras do treino e não dados novos
- C nenhum: os três medem a mesma coisa e podem ser reportados juntos
- D o best_score_, porque é o MÁXIMO de 40 medições feitas na mesma validação que escolheu

Pense antes de virar o slide.

Questão 11 — resposta

Da mesma busca saíram três números: best_score_ 0,652, nested CV $0,615 \pm 0,126$ e teste guardado 0,711. Qual deles NÃO deve ser reportado como desempenho, e por quê?

D) o best_score_, porque é o MÁXIMO de 40 medições feitas na mesma validação que escolheu

CORRETA

POR QUÊ?

Quem escolhe não mede (Aula 07). O best_score_ serve para ESCOLHER; o número que se reporta vem da nested CV (média $\pm$ desvio) ou do teste guardado, tocado uma única vez. Com só 38 hits no teste, o 0,711 também carrega bastante ruído — por isso vale dizer a faixa, não só um número.

A armadilha — marcar a nested CV como o número a descartar. Ela é a mais confiável dos três; quem não se reporta é o best_score_.

Questão 12 de 16

O que a otimização bayesiana faz que a grade e a aleatória não fazem?

- A** usa as medições já feitas para ajustar um modelo substituto e decidir onde medir em seguida
- B** garante encontrar o ótimo global do espaço de busca
- C** dispensa a validação cruzada ao avaliar cada candidato
- D** testa todas as combinações, mas em ordem inteligente

Pense antes de virar o slide.

Questão 12 — resposta

O que a otimização bayesiana faz que a grade e a aleatória não fazem?

A) usa as medições já feitas para ajustar um modelo substituto e decidir onde medir em seguida

CORRETA

POR QUÊ?

Grade e aleatória não têm memória: a 40ª tentativa ignora as 39 anteriores. A bayesiana ajusta um modelo barato (com incerteza) e mede onde a nota prevista é alta OU onde há pouca informação. O preço: cada ponto depende do anterior, então ela paraleliza mal. Brilha quando cada avaliação custa horas. Ferramentas: Optuna, scikit-optimize.

Questão 13 de 16

No mini-AutoML, o RandomizedSearchCV recebe uma LISTA de espaços (logística, árvore, floresta). Por que isso não é apenas uma grade maior?

- A** porque a lista é percorrida em ordem, e não sorteada
- B** porque cada espaço usa uma métrica diferente
- C** porque o espaço é condicional: o C só existe se o sorteio cair na logística, o ccp_alpha só se cair na floresta
- D** porque o AutoML substitui a validação cruzada por um conjunto de validação fixo

Pense antes de virar o slide.

Questão 13 — resposta

No mini-AutoML, o RandomizedSearchCV recebe uma LISTA de espaços (logística, árvore, floresta). Por que isso não é apenas uma grade maior?

C) porque o espaço é condicional: o C só existe se o sorteio cair na logística, o ccp_alpha só se cair na floresta

CORRETA

POR QUÊ?

O sorteio tem dois passos: primeiro o espaço, depois os valores dele. Cada modelo traz os SEUS hiperparâmetros, então o espaço não é um retângulo. Na literatura isso é o problema CASH — escolha conjunta de algoritmo e hiperparâmetros.

A armadilha — ver a lista de espaços como "uma grade maior". Uma grade cruzaria tudo com tudo e geraria combinações impossíveis (um C para a floresta, um ccp_alpha para a logística).

Questão 14 de 16

Com 30 sorteios, o mini-AutoML deu: logística 0,721 (mediana 0,716), floresta 0,631 e árvore 0,413. O que esses números ensinam?

- A** que a floresta precisaria de uma faixa melhor para vencer
- B** que escolher o MODELO pesou muito mais (0,31 de diferença) do que afinar o vencedor (0,005 entre o melhor e a mediana)
- C** que o AutoML tende a preferir o modelo mais sofisticado
- D** que 30 sorteios são insuficientes para comparar modelos

Pense antes de virar o slide.

Questão 14 — resposta

Com 30 sorteios, o mini-AutoML deu: logística 0,721 (mediana 0,716), floresta 0,631 e árvore 0,413. O que esses números ensinam?

B) que escolher o MODELO pesou muito mais (0,31 de diferença) do que afinar o vencedor (0,005 entre o melhor e a mediana)

CORRETA

POR QUÊ?

A distância entre modelos foi enorme e a distância dentro do modelo, quase nada. É por isso que automatizar a escolha do modelo rende — e repare que venceu o modelo MAIS SIMPLES, a logística.

Questão 15 de 16

Você acrescenta mais sete modelos ao espaço do AutoML e mantém $n_iter = 30$. O risco é:

- A o tempo de execução cair, porque modelos simples treinam rápido
- B o `best_score_` ficar mais confiável, por comparar mais candidatos
- C as distribuições perderem efeito, porque o sorteio passa a ser categórico
- D cada modelo receber ~ 3 sorteios: pouco para cobrir o espaço dele, e a conta $1 - (1 - p)^n$ não fecha

Pense antes de virar o slide.

Questão 15 — resposta

Você acrescenta mais sete modelos ao espaço do AutoML e mantém $n_iter = 30$. O risco é:

D) cada modelo receber ~3 sorteios: pouco para cobrir o espaço dele, e a conta $1 - (1 - p)^n$ não fecha

CORRETA

POR QUÊ?

O orçamento é repartido entre os espaços. Daí os truques do AutoML de verdade: cortar cedo quem vai mal (successive halving — 90 candidatos com 90 músicas, depois os 30 melhores com 270) e começar pelo que funcionou em bases parecidas (meta-aprendizado).

Questão 16 de 16

Nas músicas, deixar a coluna popularidade entrar no modelo leva a AP de 0,721 para 0,936. O que isso diz sobre o AutoML?

- A** que ele otimizaria com prazer uma variável que vaza o alvo: decidir o que entra no modelo continua sendo seu
- B** que o AutoML detecta vazamento automaticamente, por isso a nota sobe
- C** que a popularidade deveria ser mantida, já que melhora a métrica
- D** que o problema some ao usar nested CV em vez do teste guardado

Pense antes de virar o slide.

Questão 16 — resposta

Nas músicas, deixar a coluna popularidade entrar no modelo leva a AP de 0,721 para 0,936. O que isso diz sobre o AutoML?

A) que ele otimizaria com prazer uma variável que vaza o alvo: decidir o que entra no modelo continua sendo seu

CORRETA

POR QUÊ?

O motor do AutoML é validação cruzada: tudo o que está FORA dela continua sendo decisão humana — o problema e a métrica (Aulas 02–04), o esquema de validação (Aulas 06–07), que variáveis podem entrar (vazamento, Aula 01) e a nota honesta. A popularidade praticamente define o hit; a CV só veria a nota subir.