CIÊNCIA DE DADOS 1 · AULA 10

Curvas de validação

Ver o efeito de UM hiperparâmetro no desempenho — do "sem graça" ao "estragado"

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R^2, resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	
9 — 06/10	Busca aleatória e menção a AutoML	Desafio 3 (subst.)

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 13/10	**Curvas de validação**	
20/10	**SEMANA ACADEMICA (SEM AULA)**	
11 — 27/10	Curvas de aprendizado	
12 — 03/11	Seleção e comparação de modelos e Limiar de decisão e calibração	
13 — 10/11	Target Leakage e reprodutibilidade	
14 — 17/11	Seleção de atributos	
15 — 24/11	Estudo de caso integrado e Comunicação e reprodutibilidade dos resultados	**Desafio 6 (subst.)**
16 — 01/12	Revisão integrada e apresentações	**Apresentação final**

De onde viemos: achamos a combinação, mas por quê?

Nas Aulas 08–09 a **busca em grade e a aleatória** devolveram a melhor combinação de hiperparâmetros. Elas dão o **vencedor** — não a **história**. Hoje abrimos a caixa: ver, um eixo de cada vez, o que cada hiperparâmetro faz com o desempenho.

- **O problema —** a busca entrega um valor vencedor, mas não conta por que ele ganhou nem o que acontece perto dele.
- **A ideia de hoje —** fixar tudo, variar **um** hiperparâmetro e plotar treino × validação. É a **curva de validação**.
- **O que ela mostra —** as três regiões (subajuste → ótimo → sobreajuste), o tamanho do **gap** treino–validação e se o topo é um pico ou um platô.

A curva não substitui a busca: ela explica o que a busca encontrou e ajuda a escolher a faixa de valores a buscar.

A curva não é uma busca melhor — é uma pergunta diferente

Com um hiperparâmetro só, as duas entregam quase a mesma coisa. A diferença aparece quando há vários.

	busca em grade (Aulas 08–09)	curva de validação (hoje)
a pergunta	que COMBINAÇÃO vence?	o que ESTE eixo faz, sozinho?
o que varia	várias listas ao mesmo tempo	um hiperparâmetro — todo o resto parado
o que sai	best_params_ e best_score_	a vizinhança inteira: desvio, platô e gap
o custo	multiplica a cada eixo novo	uma varredura barata, antes da busca

A CONCESSÃO — E O QUE SOBRA

Com UM eixo só — a busca com return_train_score=True dá os mesmos números. Aí a curva é conveniência.

Com VÁRIOS eixos, não — a grade diz qual combinação venceu, não o que cada eixo faz sozinho.

Objetivo da aula

Ler a **curva de validação** de um hiperparâmetro e identificar **subajuste, ponto ótimo e sobreajuste** — e saber escolher o valor com a régua certa.

O CAMINHO

A curva — score de treino e de validação conforme se varia o hiperparâmetro.

As três regiões — sem graça (subajuste), no ponto (ótimo) e estragado (sobreajuste).

A régua — escolher pelo máximo da validação, com o desvio na mão.

O uso — diagnóstico e intuição: complementa a busca das Aulas 08–09.

A ANALOGIA DE HOJE

Temperar a comida — pouco sal, sem graça (subajuste); no ponto, saborosa (ótimo); sal demais, estraga (sobreajuste).

A curva de validação é o **provar a comida em cada dose** — só que a prova é feita em dados que o modelo não viu.

Da Aula 09 (achar a combinação) para a Aula 10: enxergar o efeito de cada hiperparâmetro, um de cada vez.

PARTE 1

A curva de validação

1

Fixe tudo, varie um hiperparâmetro e plote treino e validação.

A ideia, a definição e a base de hoje

Fixe tudo, varie **um hiperparâmetro** e plote o score de **treino** e de **validação** em função dele. Cada ponto do eixo x é uma validação cruzada inteira.

COMO SE CONSTRÓI

Um eixo de cada vez — isola o efeito daquele hiperparâmetro; todo o resto fica parado.

Duas curvas — treino e validação, cada uma com média ± desvio das dobras.

Oriente o eixo — da simplicidade à complexidade, para ler as regiões da esquerda para a direita.

Sempre no Pipeline — a padronização se refaz dentro de cada dobra, sem vazar (Aulas 05–07).

A BASE DE HOJE

Pacientes — 850 linhas, 15 variáveis clínicas.

Alvo — alto_risco: 128 casos positivos, 15,1% da base.

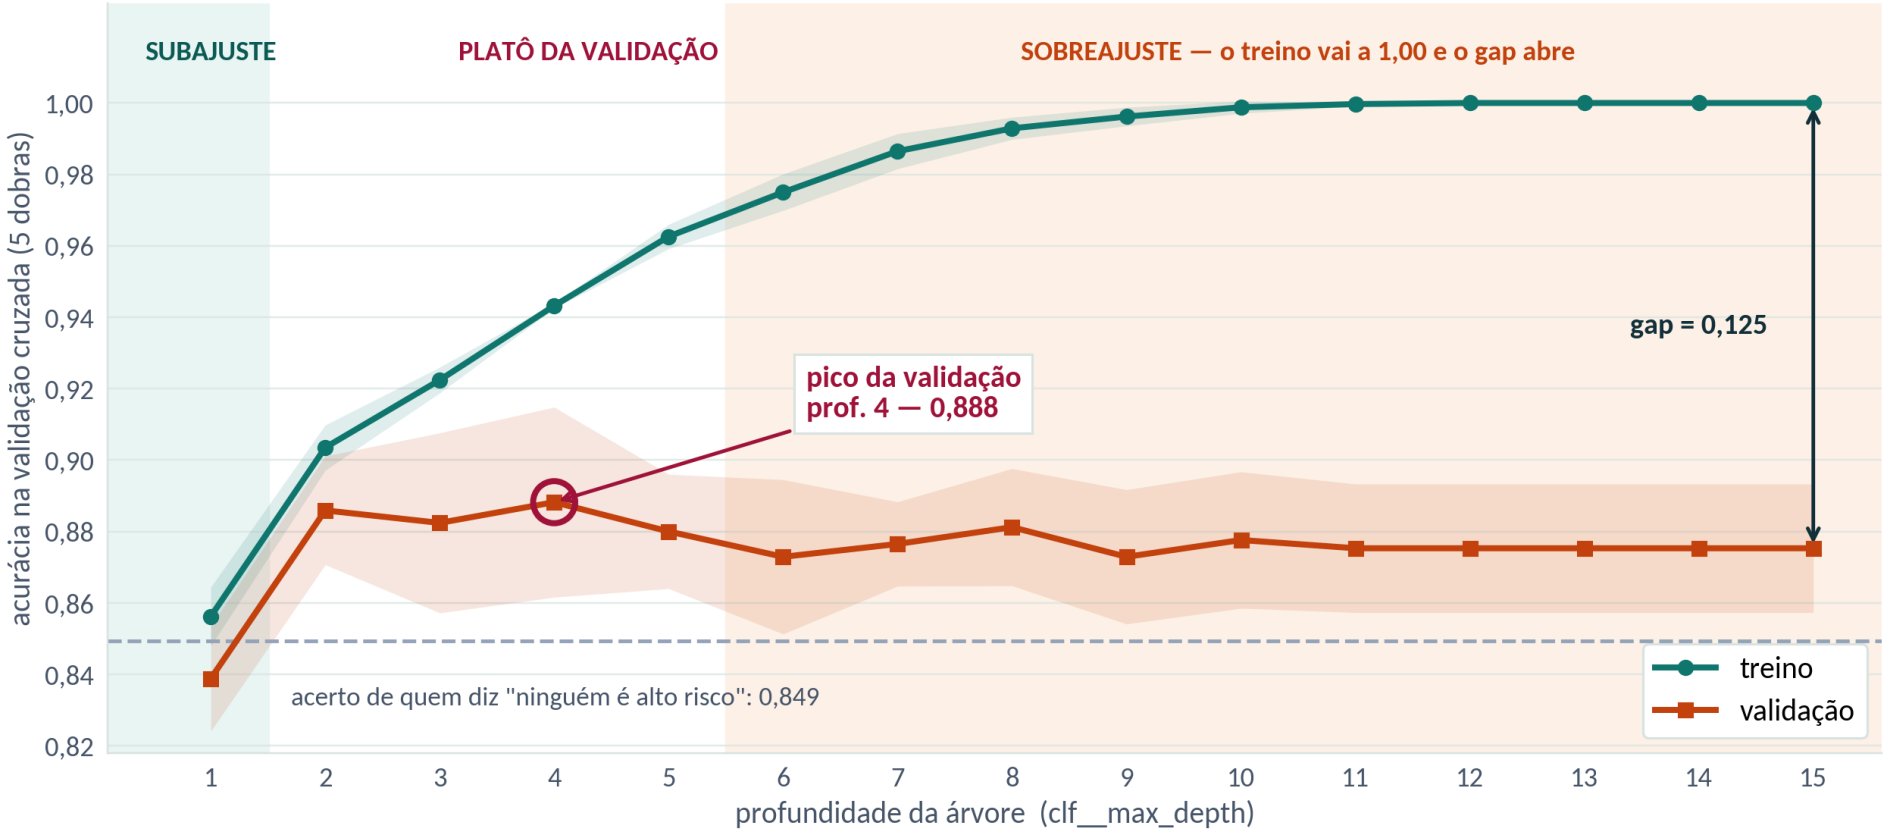
Medida — acurácia, a mesma do caderno de hoje. Linha de base: 0,849 (dizer "ninguém").

Validação — 5 dobras estratificadas, a mesma partição em todos os valores.

É a validação cruzada das Aulas 06–07 aplicada a UM eixo por vez: o retrato do desempenho ao longo dele.

A curva de validação da árvore, na base dos pacientes

Profundidade de 1 a 15, acurácia; cada ponto é a média de 5 dobras e a faixa é ± um desvio.



Treino sobe sempre (mais profundidade, mais o modelo decora). A validação sobe, chega ao máximo na prof. 4 e depois PARA — o que continua crescendo é o gap. Repare na prof. 1: ela acerta MENOS que a linha de base.

Os mesmos números, em tabela

Seis dos quinze valores testados. Gap = treino − validação, no mesmo ponto.

profundidade	acurácia treino	acurácia validação	gap	leitura
1	0,856	0,839	0,017	subajuste: acerta menos que a linha de base (0,849)
2	0,903	0,886	0,018	já praticamente no topo
4	**0,943**	**0,888**	**0,055**	**PICO DA VALIDAÇÃO**
5	0,963	0,880	0,083	desce — e o gap já é 1,5× o da prof. 4
8	0,993	0,881	0,112	treino quase perfeito, validação parada
15	1,000	0,875	0,125	treino perfeito: decorou o treino inteiro

O QUE A TABELA DIZ

Da prof. 1 para a 2 — a validação salta de 0,839 para 0,886 e passa a linha de base: até ali a árvore era simples demais.

Da prof. 4 para a 15 — a validação fica parada (0,888 → 0,875) e o gap mais que dobra (0,055 → 0,125).

A assinatura do sobreajuste não é a validação despencar — é o treino subir sozinho. No pico, o desvio da validação é de ± 0,027; esse número volta no slide da escolha.

validation_curve na prática

```
from sklearn.model_selection import validation_curve

profundidades = range(1, 16)          # os valores do eixo x
tr, va = validation_curve(arvore, X, y,   # arvore = Pipeline(scaler, árvore)
        param_name="clf__max_depth",      # passo__parâmetro
        param_range=profundidades,
        cv=5, scoring="accuracy")        # uma CV inteira por valor

tr.mean(axis=1), va.mean(axis=1), va.std(axis=1)  # média e desvio
```

DOIS DETALHES QUE MUDAM O RESULTADO

O nome do parâmetro — dentro de um Pipeline é **passo__parâmetro** (dois sublinhados): clf__max_depth, nunca max_depth.

As duas matrizes — uma linha por valor, uma coluna por dobra: a média vai no axis=1 e o desvio vira a faixa do gráfico.

PARTE 2

Como ler a curva

2

Três regiões, uma regra de escolha e o tradeoff viés-variância.

As três regiões — e a regra de escolha

À direita, o que cada região é na curva da árvore que acabamos de ver.

região	treino	validação	gap	na nossa curva
subajuste	baixo	baixo	pequeno	prof. 1 — 0,856 e 0,839, gap 0,017
ótimo	alto	máximo	moderado	prof. 4 — 0,943 e 0,888, gap 0,055
sobreajuste	≈ 1,00	não melhora	grande	prof. 15 — 1,000 e 0,875, gap 0,125

A REGRA

Escolha o valor que MAXIMIZA a validação — nunca o que maximiza o treino: esse seria sempre o mais complexo, o que decorou.

Havendo empate dentro do desvio, prefira o mais simples — mesmo desempenho, gap menor e menos risco de o resultado ser sorte da partição.

O gap é o termômetro — ele cresce muito antes de a validação cair. Quando a validação cai, já passou da hora.

O tradeoff viés-variância — e por que o pico não decide sozinho

Da esquerda para a direita a curva sai do viés alto (rígido demais) para a variância alta (sensível demais ao dado). O ótimo é o equilíbrio.

ESQUERDA — SIMPLES DEMAIS (VIÉS ALTO)

Erra por **rigidez**: não captura o padrão nem no treino. Sintoma: as duas curvas baixas e juntas.

Na nossa curva — prof. 1: treino 0,856, validação 0,839, gap 0,017.

DIREITA — COMPLEXO DEMAIS (VARIÂNCIA ALTA)

Muda demais com o dado: **decora** o treino e não generaliza. Sintoma: treino em 1,00 e gap grande.

Na nossa curva — prof. 15: treino 1,000, validação 0,875, gap 0,125.

O PLATÔ: A PARTE QUE O PICO NÃO CONTA

O pico é a prof. 4 (0,888), mas a prof. 2 marca 0,886 — diferença de 0,002, menos que o desvio de ± 0,027 do próprio pico.

Conclusão — o topo é um platô: entre a prof. 2 e a 4 a acurácia é a mesma dentro do erro, e a árvore rasa tem gap de 0,018 em vez de 0,055.

Um platô largo é um bom sinal: a escolha é robusta e pequenas mudanças no valor não derrubam a nota.

PARTE 3

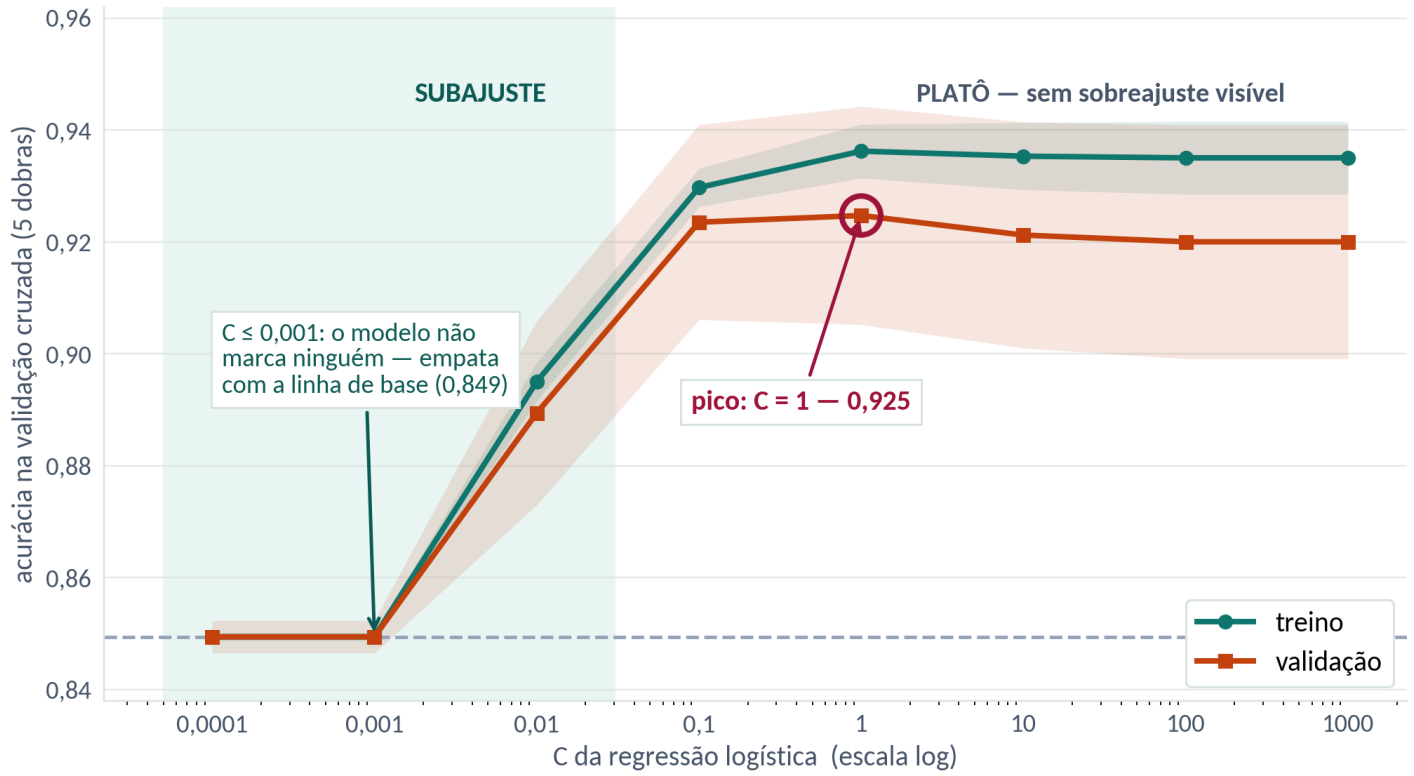
Outro modelo, e os erros

3

A mesma leitura num hiperparâmetro diferente — e o que costuma dar errado.

Exemplo 2: o C da regressão logística

C pequeno = regularização forte = modelo simples. Como C varia por ordens de grandeza, o eixo é log.



COMO SE LÊ ESTA CURVA

À esquerda — C ≤ 0,001: a regularização é tão forte que o modelo não marca ninguém — ele empata com a linha de base (0,849).

A subida — entre 0,01 e 0,1 a validação vai de 0,889 para 0,923.

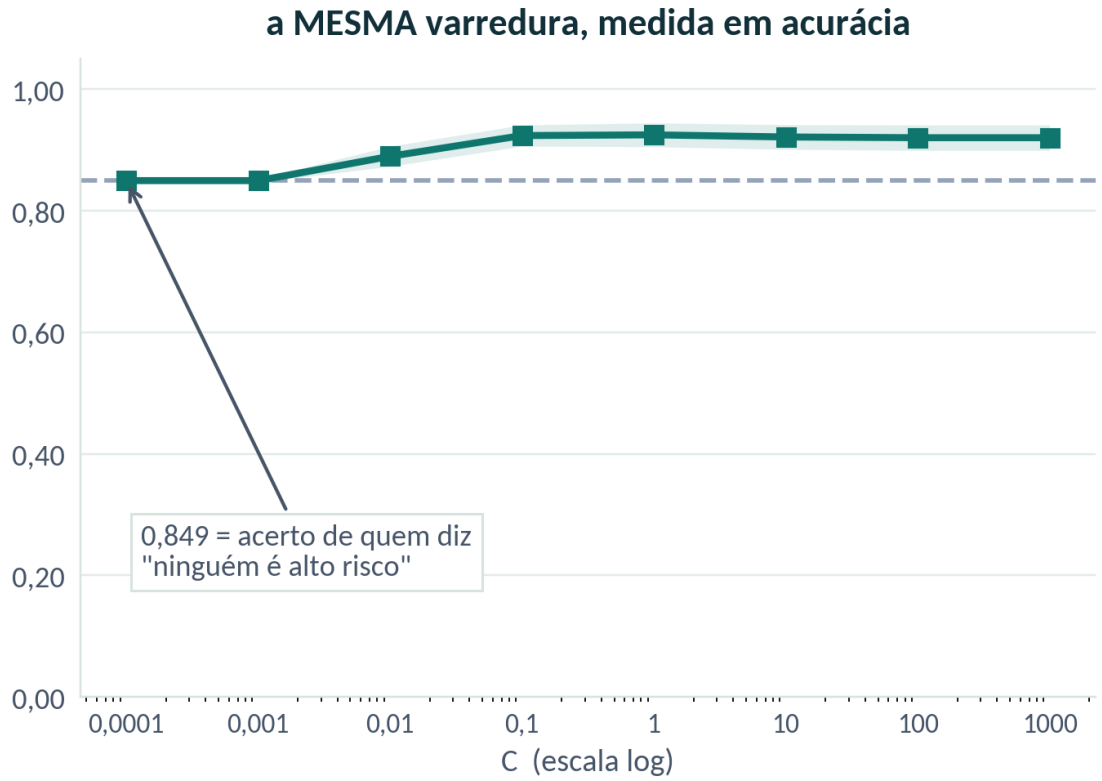
O pico — C = 1, validação 0,925.

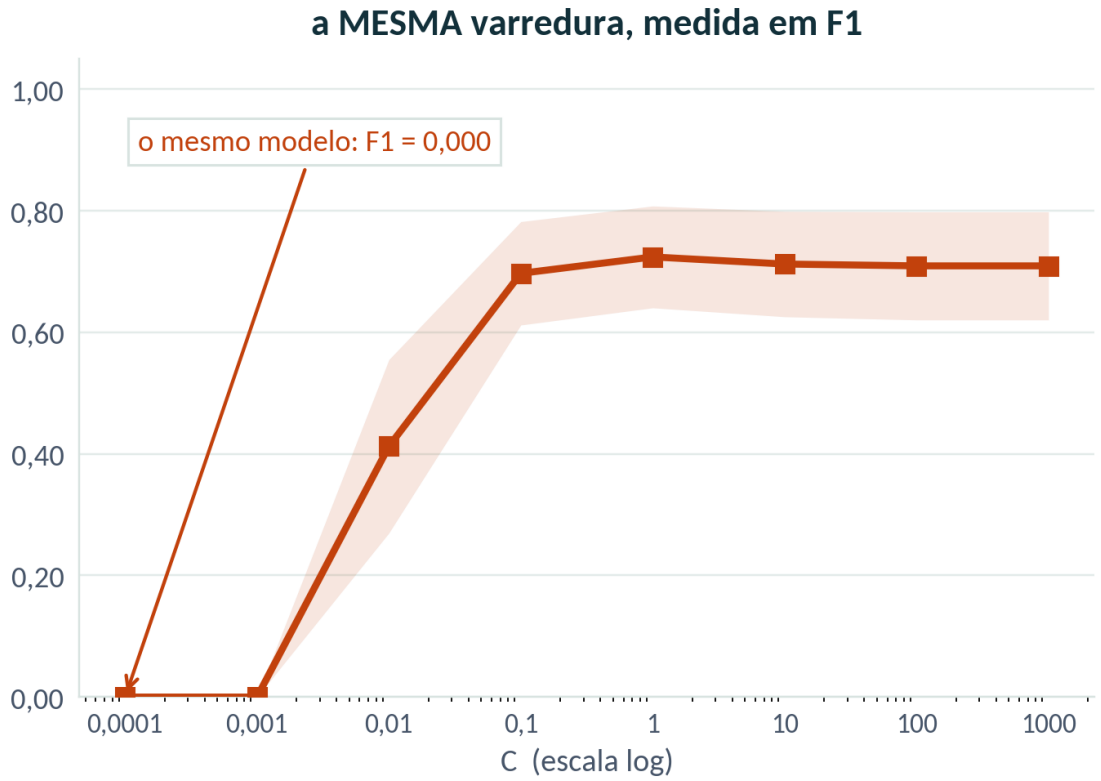
À direita — platô. O gap só vai de 0,011 a 0,015: um modelo linear tem pouca complexidade para exagerar.

Mesma leitura, modelo diferente — e uma diferença honesta: aqui não há sobreajuste visível. Nem toda curva tem as três regiões.

O ponto cego da acurácia

A MESMA varredura de C, medida de duas maneiras — e as duas contam histórias diferentes.





Com C = 0,0001 a acurácia marca 0,849 e parece aceitável — mas é só o acerto de quem diz "ninguém é alto risco" (15,1% de positivos).

Em F1 o mesmo modelo marca 0,000. A curva não mudou: mudou a régua. Com base desbalanceada, confira a leitura numa segunda métrica (Aulas 02–03).

Curva de validação × busca em grade: são complementares

Uma explica um eixo; a outra decide a combinação. Nenhuma das duas faz o trabalho da outra.

CURVA DE VALIDAÇÃO

Responde — o que acontece ao longo de UM hiperparâmetro.

Entrega — as três regiões, o gap e a largura do platô.

Não responde — qual a melhor combinação de vários juntos.

BUSCA EM GRADE / ALEATÓRIA

Responde — que combinação de VÁRIOS hiperparâmetros vence.

Entrega — o best_params_ e o best_score_ (Aulas 08–09).

Não responde — por que aquele valor ganhou nem o que há em volta.

NA PRÁTICA, NESTA ORDEM

1. Curva em cada hiperparâmetro importante → **delimitar a faixa**. 2. Busca dentro dessa faixa → **escolher a combinação**. 3. Nested CV ou teste guardado → **a nota honesta** do relatório.

Erros comuns e boas práticas

ERROS COMUNS

Ler a curva pelo treino — leva sempre ao modelo mais complexo.

Escala linear em hiperparâmetro de escala — C, alpha e gamma pedem log.

Plotar só a média — sem a faixa de desvio, um platô vira um pico.

Construir a curva fora do Pipeline — a padronização vaza para a validação.

Trocar a métrica no meio do caminho — a curva, a busca e o relatório têm de usar a mesma.

Confundir "entender um eixo" com "ajustar tudo" — a curva não substitui a busca.

BOAS PRÁTICAS

Escolha pelo máximo da validação — e olhe o desvio antes de comemorar.

Log para hiperparâmetros de escala — valores igualmente espaçados em ordem de grandeza.

Plote média ± desvio — a faixa é que mostra se o topo é platô.

Sempre sobre o Pipeline — e com a mesma partição em todos os valores.

Reporte o gap no ponto escolhido — é a medida mais direta do sobreajuste.

Empatou? Fique com o mais simples — menos gap, menos sorte.

Na próxima aula: curvas de APRENDIZADO — o eixo passa a ser o tamanho do treino. Pergunta para levar: mais dados de treino sempre ajudam o modelo?