CIÊNCIA DE DADOS 1 · CURVAS DE APRENDIZADO

Curvas de aprendizado: vale a pena coletar mais dados?

Desempenho em função do TAMANHO do treino — diagnosticar viés/variância e decidir (Aula 11)

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R^2, resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	
9 — 06/10	Busca aleatória e menção a AutoML	Desafio 3 (subst.)

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 13/10	Curvas de validação	
20/10	SEMANA ACADEMICA (SEM AULA)	
11 — 27/10	Curvas de aprendizado	
12 — 03/11	Seleção e comparação de modelos e Limiar de decisão e calibração	
13 — 10/11	Target Leakage e reprodutibilidade	
14 — 17/11	Seleção de atributos	
15 — 24/11	Estudo de caso integrado e Comunicação e reprodutibilidade dos resultados	**Desafio 6 (subst.)**
16 — 01/12	Revisão integrada e apresentações	**Apresentação final**

De onde viemos: variar o tamanho, não o hiperparâmetro

Na Aula 10 a **curva de validação** mostrou o desempenho variando **um hiperparâmetro** (subajuste/ótimo/sobreajuste). Hoje variamos o **tamanho do treino**.

- **O problema (recap) —** a curva de validação achou o melhor valor de um hiperparâmetro — mas não diz se falta DADO.
- **A ideia de hoje —** treinar o mesmo modelo com bases cada vez maiores e ver treino × validação em função do tamanho.
- **E mais —** ler a forma das curvas para responder: 'coletar mais dados ajuda, ou o gargalo é o modelo?'

Objetivo da aula

Usar a **curva de aprendizado** para diagnosticar **viés e variância** e decidir, com evidência, se **mais dados** vão ajudar.

O CAMINHO

- **A curva —** treino e validação conforme o nº de exemplos cresce.
- **O diagnóstico —** a assinatura de viés alto e a de variância alta.
- **A decisão —** quando mais dados ajuda, quando não, quando já basta.

A ANALOGIA DE HOJE

- **Estudar mais horas —** no começo, cada hora rende muito; depois satura — mais uma hora quase não muda a nota.
- A curva de aprendizado é isso com os dados.

Da Aula 10 (varia o hiperparâmetro) para a Aula 11 (varia o tamanho do treino): duas curvas, dois usos.

PARTE 1

A curva de aprendizado

1

Desempenho conforme o treino cresce.

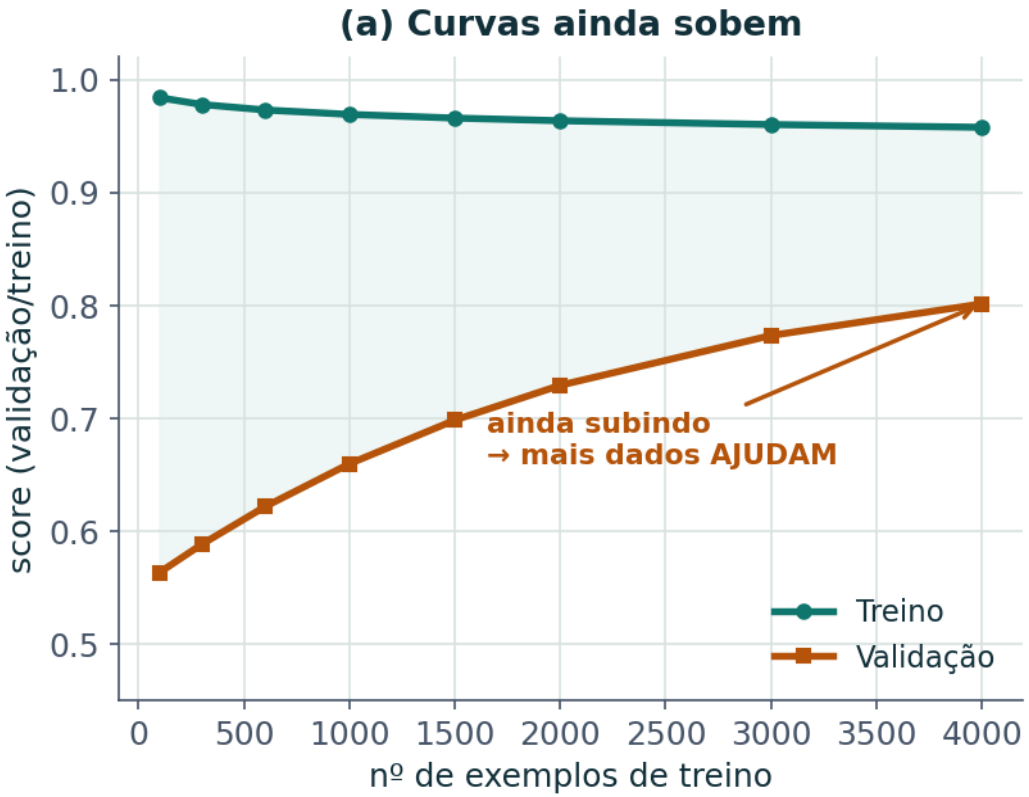
O que é e como se constrói

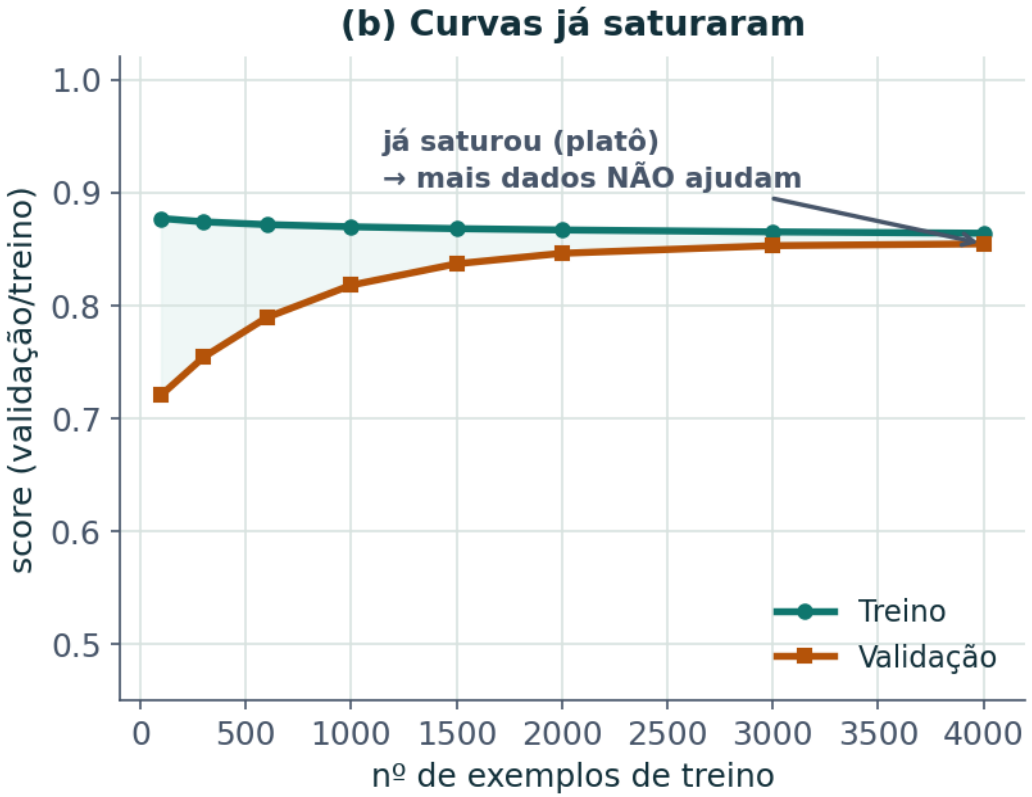
Treine o **mesmo modelo** com treinos cada vez maiores e plote o **score de treino e de validação** em função do tamanho.

- **Treino cai um pouco —** com mais exemplos, fica mais difícil 'decorar' tudo — o score de treino desce de leve.
- **Validação sobe —** com mais exemplos, o modelo generaliza melhor — o score de validação cresce.
- **Elas se aproximam —** a distância entre as duas (o gap) tende a encolher conforme o dado aumenta.

O eixo x é o TAMANHO do treino — não um hiperparâmetro (esse era o da Aula 10).

Duas curvas, dois cenários





(a) a validação ainda sobe no fim → mais dados devem render. (b) já saturou num platô com gap pequeno → mais dados quase não mudam nada.

Exemplo na mão: onde a validação satura

Medindo o score de validação para bases crescentes, o ganho **encolhe** a cada dobro de dados — até quase parar.

nº de exemplos	score validação	ganho
100	0,70	—
500	0,80	+0,10
1000	0,84	+0,04
2000	0,85	+0,01
4000	0,855	+0,005

A LEITURA

- De 2000 para 4000 (o dobro!) o score foi de 0,85 para 0,855.
- Dobrar o custo de coleta para ganhar 0,005 não compensa.
- O sinal: a curva estagnou.

É a analogia de estudar: as primeiras horas rendem muito; as últimas, quase nada. A curva torna isso visível.

learning_curve na prática

No scikit-learn, **learning_curve** treina e valida (com CV) para vários tamanhos de treino — sempre sobre o **Pipeline**.

```
from sklearn.model_selection import learning_curve
import numpy as np
tam, tr, va = learning_curve(pipe, X_tr, y_tr,
        train_sizes=np.linspace(0.1, 1.0, 8),
        cv=5, scoring="roc_auc")
tr.mean(axis=1), va.mean(axis=1)   # score por tamanho
```

Sempre sobre o Pipeline; a CV se refaz a cada tamanho de treino — sem vazamento (recap das Aulas 05-07).

PARTE 2

Diagnóstico: viés ou variância

2

A forma da curva revela o problema.

As duas assinaturas

Viés alto (subajuste)

- **A forma —** as duas curvas se encontram num patamar BAIXO.
- **O gap —** pequeno — treino e validação já quase se tocam.
- **O que diz —** o modelo é simples demais; falta capacidade, não dado.

Variância alta (sobreajuste)

- **A forma —** treino ALTO, validação bem abaixo.
- **O gap —** grande — mas ainda encolhendo com mais dados.
- **O que diz —** o modelo decora; mais dados (ou regularizar) ajudam.

A inclinação final da validação é o sinal-chave: se ainda sobe, há o que ganhar com mais dados.

Como ler cada padrão: tabela de decisão

Padrão na curva	Diagnóstico	O que fazer
Ambos baixos, gap pequeno, platô	Viés alto	modelo mais rico / mais atributos
Treino alto, gap grande que encolhe	Variância alta	mais dados / regularizar
Ambos altos e próximos	Está bom	talvez já esteja no ponto

Leia SEMPRE a curva de validação (não a de treino): é ela que estima o desempenho no mundo real.

PARTE 3

A decisão: coletar mais dados?

3

A curva transforma intuição em decisão.

Vale a pena coletar mais dados?

Olhe a **inclinação final** da linha de validação: se ainda **sobe**, mais dados provavelmente rende; se **estagnou** num platô, o ganho será pequeno.

- **Ainda subindo —** a curva não achatou no fim → coletar mais dados é o investimento certo.
- **Já num platô —** a curva achatou → coletar mais dados custa caro e muda quase nada.
- **Vira decisão de negócio —** a figura justifica (ou não) o custo de rotular/coletar mais — com evidência, não achismo.

Quando ajuda, quando não

Mais dados AJUDA quando

- Há variância alta (gap grande).
- A validação ainda sobe no fim da curva.
- O teto do modelo ainda não foi atingido.

Mais dados NÃO ajuda quando

- Há viés alto (platô baixo, gap pequeno).
- A validação já estagnou.
- O gargalo é o modelo, não a quantidade de dados.

É o mesmo diagnóstico de viés × variância — agora lido para tomar UMA decisão prática.

Se mais dados não resolve, o que fazer?

- **Se for viés alto —** modelo mais rico, novas features (atributos), menos regularização — dar mais capacidade.
- **Se for variância alta —** regularizar, simplificar o modelo, ou (aí sim) coletar mais dados.
- **Sempre —** revisar o pré-processamento e a qualidade dos rótulos — dado ruim não vira bom com quantidade.

Diagnostique ANTES de decidir: coletar dados é caro; a curva evita gastar no lugar errado.

PARTE 4

Aprendizado × validação

4

Duas curvas, dois eixos, dois usos.

Curva de aprendizado × curva de validação

Curva de aprendizado (hoje)

- **Eixo x —** tamanho do treino (nº de exemplos).
- **Responde —** mais dados ajuda? é viés ou variância?
- **Uso —** decidir sobre COLETA e diagnóstico geral.

Curva de validação (Aula 10)

- **Eixo x —** um hiperparâmetro (ex.: profundidade, C).
- **Responde —** qual VALOR do hiperparâmetro é o melhor?
- **Uso —** ajustar UM hiperparâmetro específico.

São complementares: uma diagnostica os DADOS; a outra, os HIPERPARÂMETROS.

Erros comuns e boas práticas

Erros comuns

- Ler a curva de treino, não a de validação.
- Concluir 'mais dados' quando é viés alto.
- Usar poucos tamanhos (curva 'quebrada').
- Construir a curva fora do Pipeline (vaza).
- Decidir coletar sem diagnosticar antes.

Boas práticas

- Olhe a inclinação FINAL da validação.
- Diagnostique viés/variância antes de decidir.
- Use vários tamanhos de treino.
- Sempre sobre o Pipeline, com CV.
- Transforme a curva em decisão de negócio.

Na próxima (Aula 12): seleção e comparação de modelos — escolher, com CV, entre candidatos concorrentes.