CIÊNCIA DE DADOS 1 · AULAS 12 E 13

Do modelo escolhido à decisão confiável

Comparar candidatos com justiça, escolher o limiar pelo objetivo e confiar na probabilidade

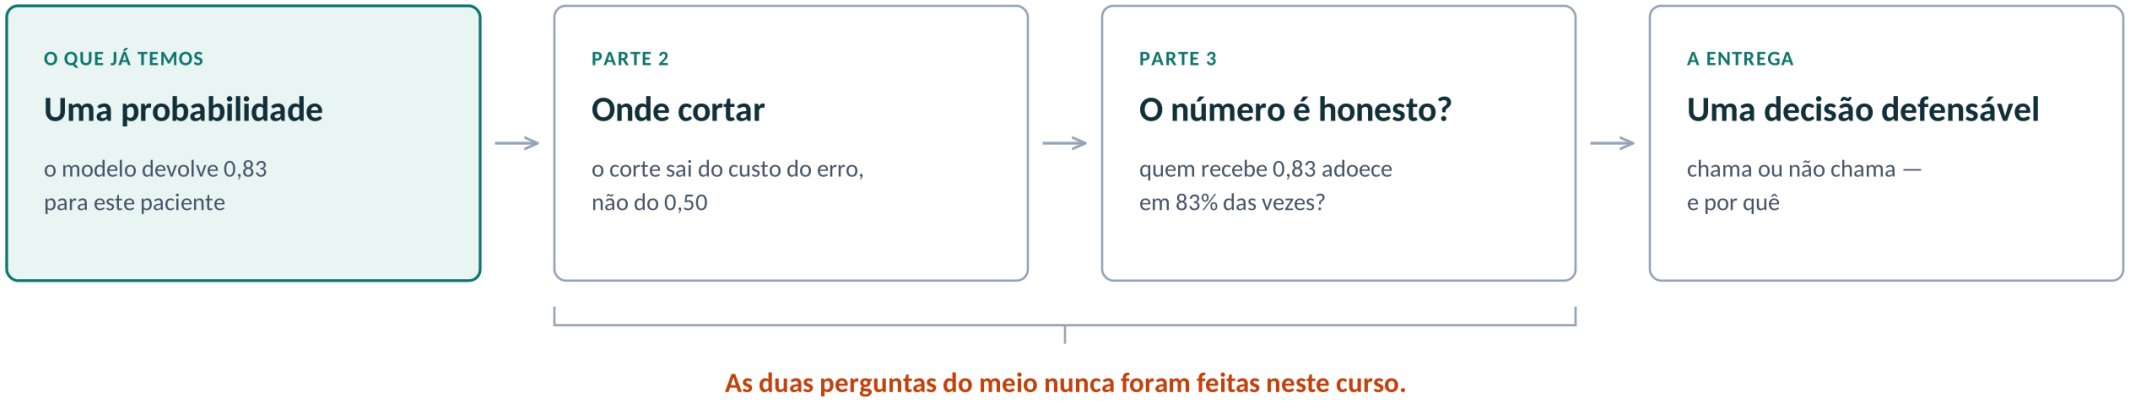
O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R^2, resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	
9 — 06/10	Busca aleatória e menção a AutoML	Desafio 3 (subst.)

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 13/10	Curvas de validação	
20/10	SEMANA ACADEMICA (SEM AULA)	
11 — 27/10	Curvas de aprendizado	
12 — 03/11	**Seleção e comparação de modelos e Limiar de decisão e calibração**	
13 — 10/11	Target Leakage e reprodutibilidade	
14 — 17/11	Seleção de atributos	
15 — 24/11	Estudo de caso integrado e Comunicação e reprodutibilidade dos resultados	**Desafio 6 (subst.)**
16 — 01/12	Revisão integrada e apresentações	**Apresentação final**

O que esta aula trata



EM UMA FRASE

O modelo já está escolhido — hoje a gente transforma a probabilidade que ele devolve numa decisão com preço, e confere se esse número merece confiança.

De onde viemos: a escolha do modelo já está resolvida

Três aulas seguidas trataram de escolher bem. Hoje a gente fecha isso em três slides e gasta o resto da aula no que vem depois.

O QUE JÁ ESTÁ DADO

Aula 9 — o pódio da busca tem platô, e o best_score_ é otimista: quem escolhe não mede.

Aula 10 — o pico da curva não decide sozinho; dentro da incerteza, vale o mais estável.

Aula 7 — comparação justa é comparação pareada, nas mesmas dobras.

O QUE NUNCA FIZEMOS

Transformar probabilidade em decisão — o modelo devolve 0,73; a operação precisa de um sim ou um não.

Checar se o número vale — quando ele diz 0,8, acontece em 80% das vezes? Nenhuma aula do curso perguntou isso até agora.

POR QUE ISSO IMPORTA AGORA

É a última milha do projeto de vocês — sem corte e sem calibração, o que vocês entregam é um score, não uma decisão.

Objetivo da aula

Ao sair daqui, você sabe **escolher o corte de decisão a partir do custo do erro** e **verificar se a probabilidade do modelo é honesta** — e sabe defender as duas escolhas para um cliente.

O QUE A AULA ENTREGA

1. Um corte justificado — saído de uma meta de recall ou de uma razão de custo, não do default.

2. Um número honesto — o previsto contra o observado, o log-loss da aula 3, e o que fazer quando não bate.

3. Uma frase para a reunião — quanto custa, para você, cada tipo de erro?

O EXEMPLO DE HOJE, DO COMEÇO AO FIM

1_pacientes.csv — 850 pacientes, 17 variáveis clínicas, alvo: risco metabólico alto.

Classe rara: 15% — e é por isso que ela serve. Com classe equilibrada, o 0,50 já está quase certo e a aula perderia a graça.

Esta aula não é mais uma sobre escolher modelo: é sobre o que fazer depois que ele foi escolhido.

PARTE 1

Fechar a escolha

1

Quatro candidatos, uma régua que não depende do corte

595 pacientes de treino, 10 dobras, as mesmas para todos. Métrica: ROC-AUC, da aula 3. A faixa de empate é o melhor score menos um desvio dele — a mesma regra da aula 10, quando o pico da curva não decidia sozinho.

candidato	ROC-AUC (validação)	dentro da faixa de empate (≥ 0,946)?
Regressão logística	**0,960 ± 0,014**	**SIM — e é a mais simples**
Random Forest (200 árvores)	**0,945 ± 0,025**	**fora por um milésimo — na prática, empate**
kNN (k = 25)	0,940 ± 0,035	não
Árvore (prof. 4)	0,803 ± 0,135	não

POR QUE ROC-AUC E NÃO ACURÁCIA

Acurácia é acurácia no corte 0,50 — comparar por ela seria escolher o modelo já com um corte embutido, justo o corte que a Parte 2 vai mostrar que está errado. O ROC-AUC olha a ordem inteira e não depende de corte nenhum.

O quase-empate que decide a aula

A logística tem 0,960 e a floresta 0,945, com desvios de 0,014 e 0,025. A floresta fica um milésimo fora da faixa — eu não defenderia uma escolha baseada nessa diferença.

A DECISÃO

Pela ordem, as duas são equivalentes — 0,960 contra 0,945, com as barras se sobrepondo. Escolher uma pela outra por 0,015 seria decidir no ruído.

Vai a logística — pela regra da aula 10: empatadas, fica a mais simples, com coeficientes que dão para explicar ao médico.

GUARDEM A FLORESTA

Ela volta na Parte 3 — porque esses dois modelos ordenam os pacientes quase igual e NÃO são igualmente confiáveis no valor da probabilidade.

E o ROC-AUC não avisa — é esse o ponto cego que a terceira parte ataca.

A LEITURA HONESTA DA TABELA

A árvore com 0,803 ± 0,135 — aquele desvio enorme é o aviso: com 90 positivos em 595 linhas, uma árvore rasa muda de ideia a cada dobra.

PARTE 2

O limiar

2

O modelo devolve probabilidade. Quem transforma isso em decisão é você — e a escolha tem preço.

Antes de cortar: o que é esse número

Na aula 2 eu disse numa linha que o modelo devolve uma probabilidade, e segui. Hoje a gente volta nessa frase, porque a aula inteira depende dela.

idade	IMC	glicemia	HbA1c	cintura	P(risco alto)	era de risco alto?
18	20,5	68	4,2	61	0,000	não
65	28,1	85	4,2	88	0,010	não
54	23,6	107	5,1	78	0,156	não
56	37,0	107	6,0	88	**0,832**	**não**
70	30,5	143	6,6	90	0,995	sim

O QUE ESSE NÚMERO AFIRMA

Não é uma nota de 0 a 1 — é uma afirmação que dá para conferir: entre todos os pacientes a quem o modelo deu 0,8, uns 80% deveriam ser de risco alto. A Parte 3 vai conferir.

E olha a quarta linha — 0,832 num paciente que não era de risco alto. É o erro confiante que o log-loss da aula 3 punia. Guardem, porque é para lá que a aula vai.

O que o .predict() faz por baixo dos panos

Nada de mágica: ele compara a probabilidade com 0,50 e pronto.

```
proba = modelo.predict_proba(X_te)[:, 1]      # P(risco alto) de cada paciente

pred  = (proba >= 0.50).astype(int)           # é literalmente isto
np.array_equal(pred, modelo.predict(X_te))    # True
```

DE ONDE VEM O 0,50

É o ponto neutro — quando os dois erros custam igual e as classes estão equilibradas. Nos nossos pacientes, nenhuma das duas condições vale: 15% de positivos e um FN que é muito pior que um FP.

O QUE A AULA 2 DEIXOU EM ABERTO

Lá vocês testaram quatro cortes à mão — e a instrução foi "escolha o que melhor equilibra recall e precisão". Equilibra segundo quem? Hoje a gente troca esse "equilíbrio" por um critério que o cliente assina: o custo do erro.

Quatro cortes, lado a lado



Mesmo modelo, mesmas probabilidades, 595 pacientes da validação. Só muda onde eu corto.

corte	VN	FP	FN	VP	precisão	recall	custo = VN·c_VN + FP·c_FP + FN·c_FN + VP·c_VP ; c_FP = 1, c_FN=5
0,15	444	61	10	80	0,567	0,889	111
0,30	467	38	15	75	0,664	0,833	113
0,50 (default)	486	19	33	57	0,750	0,633	**184**
0,70	500	5	40	50	0,909	0,556	205

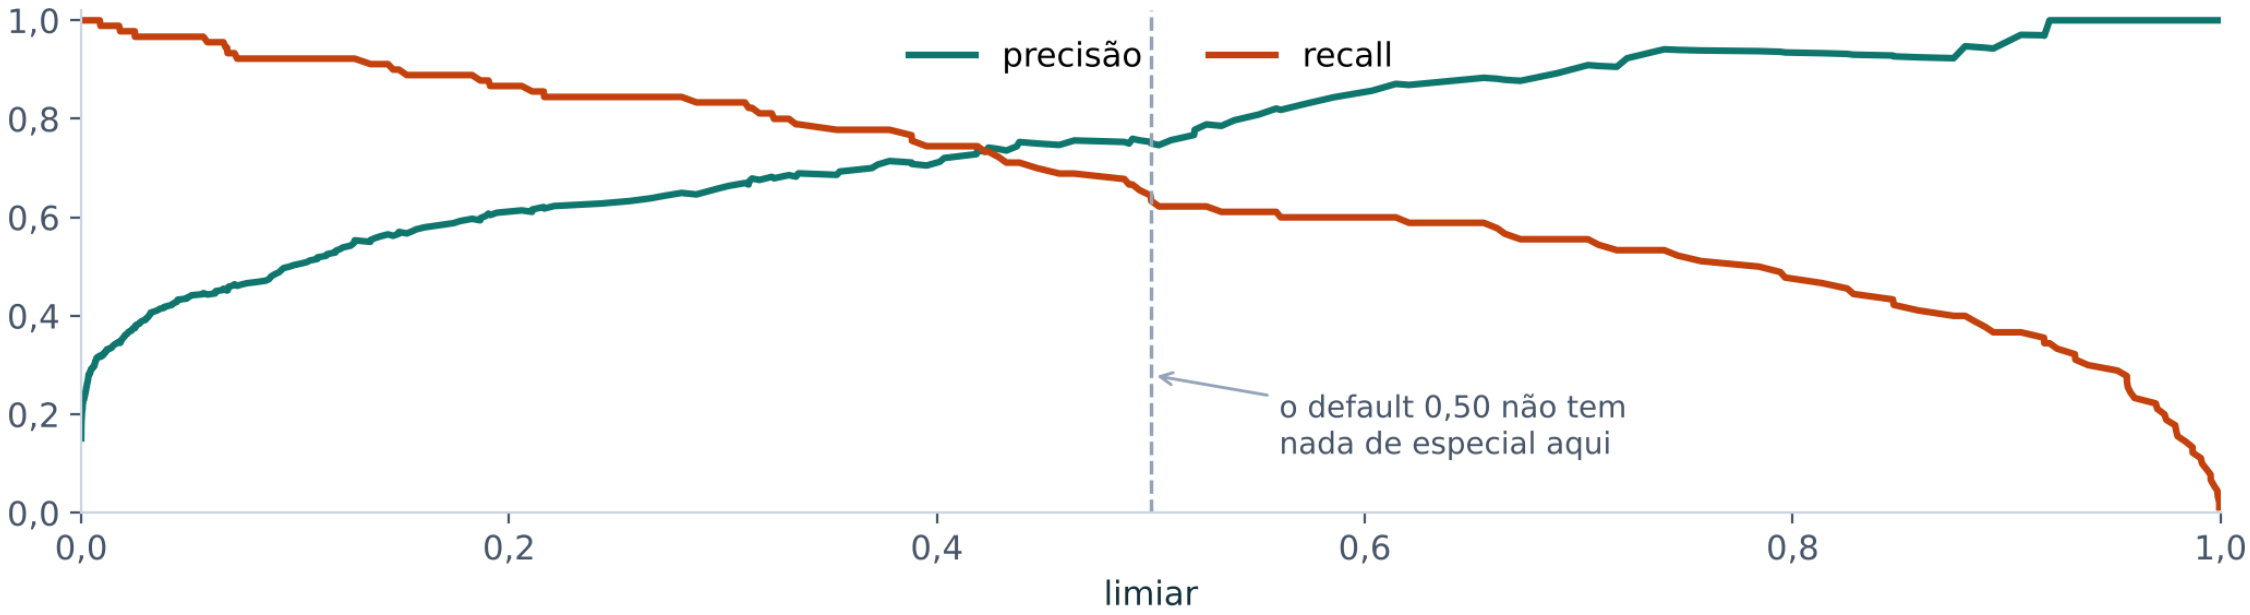
O QUE A TABELA MOSTRA

Subir o corte troca um erro pelo outro — do 0,15 ao 0,70 a precisão sobe de 0,567 para 0,909 e o recall cai de 0,889 para 0,556. Não existe corte que melhore os dois.

E a última coluna decide — se deixar passar um paciente de alto risco custa cinco vezes um exame a mais, o default 0,50 é o pior dos quatro cortes da tabela.

Em vez de quatro cortes, varra todos

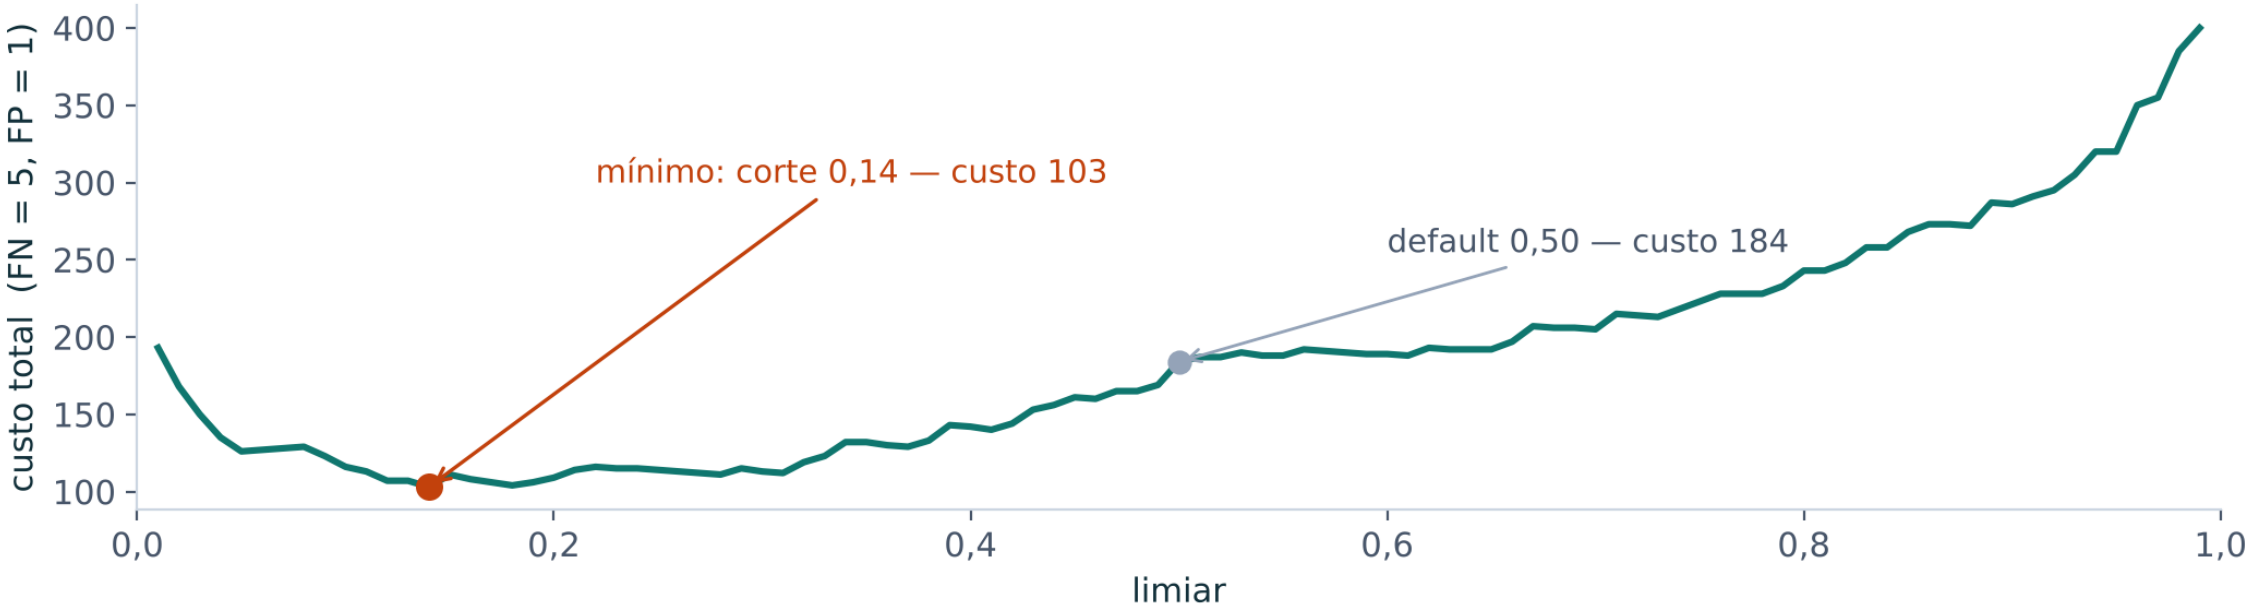
precision_recall_curve devolve precisão, recall e os limiares de uma vez só. Repare onde cai o 0,50: no meio da curva, sem nada de especial.



É o trade-off da aula 2, agora inteiro em vez de quatro pontos: o cruzamento não é ponto ótimo de nada, e a varredura continua sendo feita na validação.

A curva de custo: onde o corte vira dinheiro

Custo total na validação, com um falso negativo valendo cinco falsos positivos. O mínimo está em 0,14; o default 0,50 custa 78% a mais.



Custo 103 contra 184: o corte 0,14 custa 44% menos que o default, sem treinar nada de novo. E não persigam o mínimo exato — cada degrau da curva é um paciente mudando de lado.

Dois jeitos de traduzir o objetivo do negócio em um corte

A área não fala em limiar. Ela fala em meta ou em custo — e cada uma vira uma conta diferente.

CAMINHO 1 — META DE RECALL

Quando a área diz — "tenho de pegar pelo menos 90% dos casos". Triagem, fraude, segurança.

A conta — varra a curva e pegue o MAIOR limiar que ainda cumpre a meta; assim você maximiza a precisão dentro da restrição.

Na nossa base — limiar 0,148: recall 0,900 com precisão 0,570.

CAMINHO 2 — CUSTO ASSIMÉTRICO

Quando a área diz — "deixar passar custa cinco vezes mais que chamar à toa".

A conta — calcule o custo total em toda a varredura e pegue o mínimo.

Na nossa base — limiar 0,14, custo 103, contra 184 no default.

A PERGUNTA QUE PRECEDE AS DUAS

Quanto custa, para o cliente, cada tipo de erro? — sem essa resposta todo limiar é chute, inclusive o 0,50 — que é um chute disfarçado de padrão técnico.

PARTE 3

A calibração

3

A aula 3 já tinha feito esta pergunta — "quando o filtro diz 95% spam, é mesmo perto de 95%?" — e respondido com o log-loss. Hoje: a figura por trás dela, e o conserto.

Quase a mesma AUC, honestidades diferentes

Os dois modelos da Parte 1, agora olhados pelo valor da probabilidade e não pela ordem. Em cada faixa: o que o modelo prometeu, e o que aconteceu.

faixa de probabilidade	logística: prometeu → aconteceu	floresta: prometeu → aconteceu
0,00 a 0,05	0,006 → 0,008	0,014 → 0,007
0,05 a 0,20	0,111 → 0,127	0,107 → 0,061
0,20 a 0,50	0,354 → 0,412	0,325 → 0,309
0,50 a 1,00	0,815 → 0,750	**0,677 → 0,806**

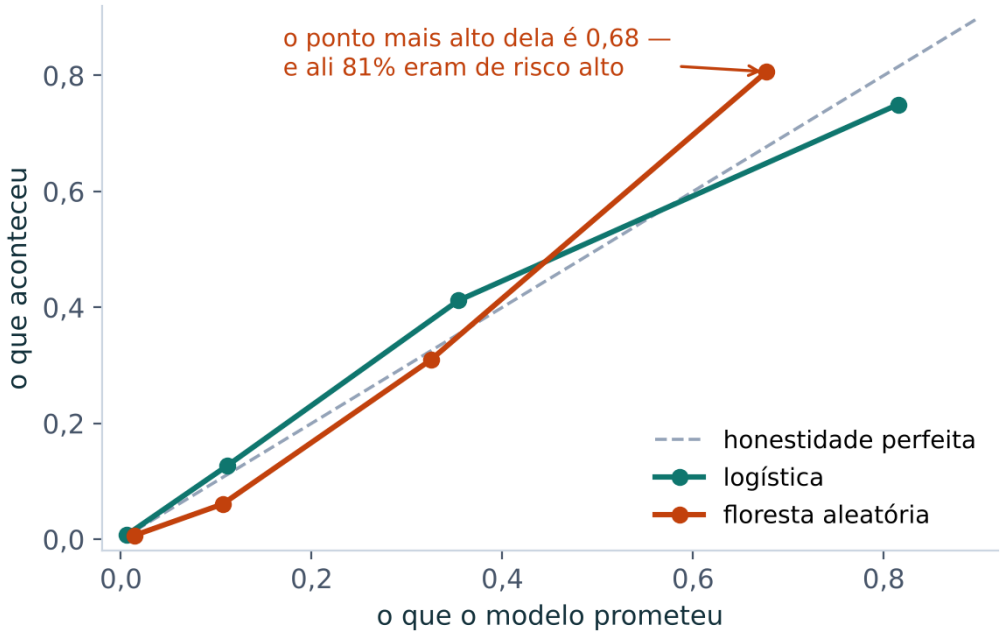
LEIA A ÚLTIMA LINHA

A floresta não passa de 0,677 — esse é o maior número que ela consegue dizer. E naquela faixa 80,6% dos pacientes eram de risco alto. Ela subestima justamente os piores casos.

O motivo é o próprio modelo — ela é a média de 200 árvores: para dizer 0,95 seriam precisas 190 concordando, o que quase nunca acontece. A logística, que é uma conta só, chega a 0,82.

O reliability diagram — e como ele se monta

Eixo x: o que o modelo prometeu. Eixo y: o que aconteceu. A diagonal é a honestidade perfeita.



A CONTA, EM UMA LINHA

Separa por faixa e conta — junta os casos em que o modelo falou ~0,3 e vê quantos foram positivos. Repete faixa por faixa.

No scikit-learn — calibration_curve(y_val, proba, n_bins=5, strategy="quantile").

Não é acurácia — não tem corte nenhum nessa conta. A acurácia precisa de uma linha em 0,50 e depois só olha de que lado o caso caiu.

E já tínhamos um número para isso — o log-loss da aula 3: 0,177 na logística contra 0,213 na floresta, com o chute da prevalência em 0,425. Esta figura é o desenho daquele número.

Cuidado com o número de faixas: poucas escondem a distorção, muitas deixam cada faixa com caso de menos e a coluna "aconteceu" vira ruído.

Então eu calibro? Aqui, não.

A pergunta certa não é como consertar o modelo torto. É se você precisa dele.

A REGRA: TROQUE DE MODELO

Existe outro candidato que ordena igual e já é honesto? Use ele. Acabou. Nenhuma etapa nova, nenhum dado reservado, nada a mais no relatório.

É o nosso caso — a logística ordena como a floresta (0,960 contra 0,945) e já diz a verdade no valor. A entrega desta aula é a logística, sem calibração nenhuma.

E não é sorte — a logística é treinada minimizando o log-loss, que é a própria métrica da honestidade. Ela sai calibrada porque foi otimizada para isso.

A EXCEÇÃO: CORRIJA A SAÍDA

Só quando trocar não é opção — o modelo torto é o único que ordena bem, ou já está em produção e ninguém vai trocar por sua causa.

Aí existe conserto — CalibratedClassifierCV, no scikit-learn, seção 1.16 da documentação. Ele precisa de dados que o modelo não viu: calibrar no próprio treino é vazamento.

VALE PARA OS DOIS CAMINHOS

Mexer na escala não melhora o ranking — a ordem e o ROC-AUC continuam os mesmos; o que muda é o significado do número.

Trocou o modelo ou corrigiu a escala? O corte sai do lugar

As três partes da aula não são independentes: a terceira desfaz a escolha da segunda.

O QUE ACONTECE

O corte vive na escala do modelo — o corte de custo mínimo da floresta é 0,23; o da logística é 0,14. São modelos que ordenam quase igual, e os cortes não são intercambiáveis.

Corrigir a escala move o corte do mesmo jeito — na floresta, depois da correção, o 0,23 vira 0,11. Caiu pela metade.

A ORDEM CERTA

1. Escolha o modelo — com métrica de ordenação, que não depende de corte nem de escala.

2. Confira a honestidade do número — e, se for o caso, troque de modelo ou corrija a escala. Isso não mexe no ranking, então o passo 1 continua valendo.

3. Só então varra o limiar — sobre a escala final, na validação.

E QUANDO A HONESTIDADE DO NÚMERO NÃO IMPORTA

Se você só ordena a fila — pegar os 100 de maior risco para ligar não exige número honesto, exige ordem certa, e o ROC-AUC já respondeu. A honestidade vira obrigatória quando o número entra numa conta: vira preço, vira corte de custo, vira score que alguém lê e interpreta.

PARTE 4

Fechar a entrega

4

A pergunta que abre o projeto, a tabela que guia a decisão, e o teste — aberto uma vez.

A tabela de decisão das duas metades

A pergunta nunca é "que técnica eu uso". É "em que situação eu estou".

situação	o que fazer	por quê
Dois modelos dentro de um desvio	fica o mais simples	mesma AUC, menos risco e mais fácil de explicar
Falso negativo é caro	baixe o limiar	troca alarme falso por caso não perdido
Falso positivo é caro	suba o limiar	troca cobertura por precisão
A área deu uma meta de recall	o maior limiar que cumpre a meta	cumpre a restrição com a melhor precisão possível
O número vai entrar numa conta	confira o previsto × observado	probabilidade torta gera decisão torta
O número saiu torto	troque pelo modelo honesto, se houver	é mais barato do que remendar a saída de um modelo torto

NO RELATÓRIO DO PROJETO

Escrevam qual linha desta tabela se aplicou ao caso de vocês, e por quê — são três parágrafos, e é o que separa um relatório que descreve o que foi feito de um que justifica o que foi decidido.

A auditoria: a validação cumpriu o que prometeu?

O teste, aberto uma vez: 255 pacientes guardados desde o passo 2, 38 de alto risco. Custo por paciente, para os dois tamanhos ficarem comparáveis.

	validação (595 pacientes)	teste (255 pacientes)
corte 0,50 — o default, que ninguém escolheu	**184 → 0,309 por paciente**	**79 → 0,310 por paciente**
corte 0,14 — escolhido olhando a validação	103 → 0,173 por paciente	35 → 0,137 por paciente
ROC-AUC	0,960 ± 0,014	0,959

AS DUAS LEITURAS

A linha do default é o controle — ninguém escolheu o 0,50 olhando dado nenhum, e mesmo assim validação e teste bateram na terceira casa: 0,309 contra 0,310. É a prova de que a validação estima bem o que vai acontecer.

A linha do corte escolhido saiu melhor que o prometido — 0,173 previsto, 0,137 entregue. Isso é sorte do sorteio, não mérito. Se tivesse saído um pouco pior também seria sorte; o que condenaria o método seria sair pior toda vez.

Erros comuns e boas práticas

ERROS COMUNS

Entregar o .predict() sem nunca ter olhado o limiar.

Escolher o corte no conjunto de teste.

Comparar modelos por acurácia e depois dizer que o 0,50 é arbitrário.

Ler AUC alta como garantia de probabilidade confiável.

Avaliar a honestidade do número nos mesmos dados do treino.

Trocar de modelo ou corrigir a escala e não revarrer o limiar.

BOAS PRÁTICAS

Perguntar o custo de cada erro na primeira reunião.

Varrer o limiar na validação e reportar o corte escolhido.

Comparar com métrica de ordenação quando o corte ainda será decidido.

Reportar ROC-AUC e log-loss: ordem e valor são coisas diferentes.

Preferir o modelo honesto a remendar o modelo torto.

Ordem: escolher, conferir o número, cortar, testar uma vez.

Na próxima aula (10/11): target leakage e reprodutibilidade — como garantir que este número continue honesto fora da sua máquina.