PUC-SP • MAPEAMENTO DE DECISÕES DE MACHINE LEARNING

# Aula 12: Limiar de Decisão e Calibração de Modelos

## Do Modelo Escolhido à Decisão Confiável no Negócio

**Autora: Profa. Fabiana Campanari | Mindful AI Research**
Curso: Ciência de Dados & Machine Learning (2026) | Departamento de Ciência da Computação

# A acurácia tradicional falha em cenários com classes desbalanceadas e custos assimétricos

## A Falácia do Limiar 0,50

• Assumir o corte neutro em 0,50 pressupõe custos iguais e dados 50/50 balanceados.

• Em triagem médica (15% prevalência), o 0,50 perde >52% dos doentes.

• Um modelo 'preguiçoso' que diz que todos são saudáveis atinge 85% de acurácia, mas tem utilidade nula.

## Custos Assimétricos de Erro

• Falso Positivo (FP): Paciente saudável mantido para teste extra (custo operacional baixo).

• Falso Negativo (FN): Paciente doente enviado para casa sem tratamento (custo crítico/alto).

• Princípio: Custo(FN) >> Custo(FP). A otimização deve refletir o impacto real.

## Dois Pilares da Confiabilidade

1. Capacidade de Ordenação: Habilidade de separar casos positivos de negativos (medida via ROC-AUC).

2. Honestidade Probabilística: Alinhamento entre a probabilidade prevista e a taxa real observada (medida via Diagramas de Confiabilidade).

# A Regressão Logística venceu o benchmark por apresentar alta capacidade de ordenação e maior estabilidade

| Algoritmo | ROC-AUC | Desvio Padrão (σ) | Status |
|---|---|---|---|
| Logistic Regression | 0.960 | ±0.014 | SELECIONADO (Campeão) |
| Random Forest (200 Trees) | 0.945 | ±0.025 | Empate Técnico |
| K-Nearest Neighbors (K=15) | 0.940 | ±0.021 | Eliminado |
| Decision Tree | 0.803 | ±0.038 | Eliminado |

## Regra de Desempate por Variância

- Sobreposição Estatística:
  Regressão Logística (0,960 - 0,014 = 0,946) empata com Random Forest (0,945 + 0,025 = 0,970).

- Regra de Decisão:
  Havendo empate na margem, escolhe-se o modelo de menor variância (σ = 0,014 vs σ = 0,025).

- Por que ROC-AUC?
  Avalia a ordenação pura em TODOS os limiares possíveis sem fixar 0,50 antecipadamente.

# Reduzir o limiar para τ = 0,14 reduziu o custo operacional de erro em 44%

**Função de Custo Operacional: Custo Total = (1.0 × Falsos Positivos) + (5.0 × Falsos Negativos)**

## Default Cutoff (τ = 0.50)

- Falsos Positivos (FP): 7 casos (Custo = 7)
- Falsos Negativos (FN): 35 casos (Custo = 175)

- CUSTO OPERACIONAL TOTAL = 182 unidades

- Impacto: Acurácia no papel é alta, mas perde 35 pacientes graves por conta de um limiar exigente demais.

## Optimal Cost Cutoff (τ = 0.14)

- Falsos Positivos (FP): 67 casos (Custo = 67)
- Falsos Negativos (FN): 7 casos (Custo = 35)

- CUSTO OPERACIONAL TOTAL = 102 unidades

- Impacto: Redução de 44% no Custo! Aceita fazer exames extras (FP) para salvar quase todos os pacientes (FN).

# Alta ROC-AUC não garante probabilidades honestas: o Random Forest sofreu de compressão probabilística

## Logistic Regression (Naturally Calibrated)

- Comportamento no Diagrama:
  Segue quase perfeitamente a linha diagonal de 45° no calibration_curve.

- Significado Real:
  Quando prevê 80% de risco, exatamente 80 em cada 100 pacientes parecidos têm a doença.

- Usabilidade:
  Probabilidades são honestas e diretamente utilizáveis para pontuação de risco e decisões.

## Random Forest (Probability Compression)

- Efeito de Média:
  A média de 200 árvores 'empurra' as probabilidades em direção ao meio (~0,15 a 0,67).

- Defasagem de Confiança:
  Mesmo para pacientes gravíssimos, raramente supera 67% porque exige unanimidade nas árvores.

- Diretriz de MLOps:
  Prefira um modelo naturalmente calibrado a tentar 'remendar' as saídas de um modelo desalinhado.

# A ordem rigorosa de avaliação previne vazamento de dados e otimização ilusória

**PASSO 1** — **Selecionar Arquitetura**
Escolher pela capacidade de ordenação via ROC-AUC em validação cruzada.

**PASSO 2** — **Verificar Calibração**
Confirmar a honestidade das probabilidades via Diagrama de Confiabilidade.

**PASSO 3** — **Varrer Limiar de Decisão**
Otimizar o corte $\tau$ estritamente na Validação usando a matriz de custo.

**PASSO 4** — **Avaliar no Teste (Passo Único)**
Travar modelo e corte $\tau$; avaliar UMA ÚNICA VEZ no conjunto de Teste.

# Decisões confiáveis exigem alinhar métricas estatísticas aos custos reais do negócio

## Principais Lições para Sistemas de IA/ML

**1. Pare de usar o limiar padrão de 0,50 cegamente:**
O corte 0,50 pressupõe dados balanceados e custos iguais. Sempre ajuste o limiar $\tau$ contra uma matriz de custo ou meta de recall/precisão.

**2. Avalie Discriminação e Calibração separadamente:**
A ROC-AUC mede o quão bem o modelo ordena os casos, enquanto o Diagrama de Confiabilidade mede a honestidade das probabilidades. Ambos são vitais.

**3. Evite Vazamento de Dados na Otimização do Limiar:**
Nunca otimize o limiar $\tau$ no conjunto de teste. O ajuste de limiar é um hiperparâmetro e deve ocorrer estritamente na validação.

**4. Escolha Arquitetural sobre Remendos Post-Hoc:**
Quando as probabilidades forem distorcidas (ex: compressão em ensembles), dê preferência a arquiteturas naturalmente calibradas como a Regressão Logística.