CIÊNCIA DE DADOS 1 · AULA 13

Vazamento e reprodutibilidade

Quando a métrica boa é falsa, e como refazer o trabalho igual

O curso, semana a semana (1/2)

Aula (Dia/Mês)	Assunto	Evento
1 — 04/08	Introdução: fundamentos da avaliação de modelos	
2 — 11/08	Métricas de classificação I (confusão, precisão, recall, F1)	Lançamento do projeto
3 — 18/08	Métricas de classificação II (ROC-AUC, PR, log-loss)	
4 — 25/08	Métricas de regressão (MAE, RMSE, R^2, resíduos)	Projeto: proposta
5 — 01/09	Validação hold-out e Pipeline	
6 — 08/09	Validação cruzada I (k-fold, estratificado)	
7 — 15/09	Validação cruzada II (grupos, temporal, aninhada)	
8 — 22/09	Busca exaustiva de hiperparâmetros (grid search)	
9 — 06/10	Busca aleatória e menção a AutoML	Desafio 3 (subst.)

O curso, semana a semana (2/2)

Aula (Dia/Mês)	Assunto	Evento
10 — 13/10	Curvas de validação	
20/10	SEMANA ACADÊMICA (SEM AULA)	
11 — 27/10	Curvas de aprendizado	
12 — 03/11	Seleção e comparação de modelos · Limiar de decisão e calibração	
13 — 10/11	**Target leakage e reprodutibilidade**	
14 — 17/11	Seleção de atributos	
15 — 24/11	Estudo de caso integrado · Comunicação dos resultados	Desafio 6 (subst.)
16 — 01/12	Revisão integrada e apresentações	Apresentação final

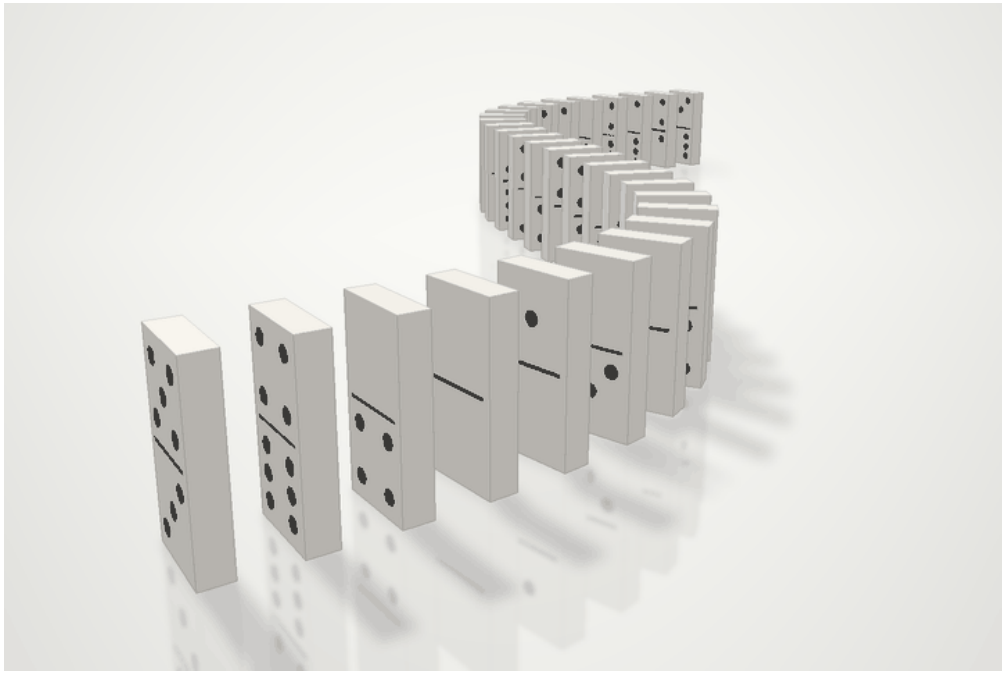
Até aqui, a gente confiou na métrica

Na Aula 12 vocês escolheram o limiar e calibraram a probabilidade.

Tudo isso supõe uma coisa:

que o número medido é **verdadeiro**.

Hoje: e se ele não for?



Três blocos hoje

1

Target leakage

a coluna que entrega a resposta

2

Vazamento temporal

o futuro dentro do treino

3

Reprodutibilidade

mesmo código, mesmo número, modelo salvo

O vazamento não dá erro. Ele dá um resultado bom.

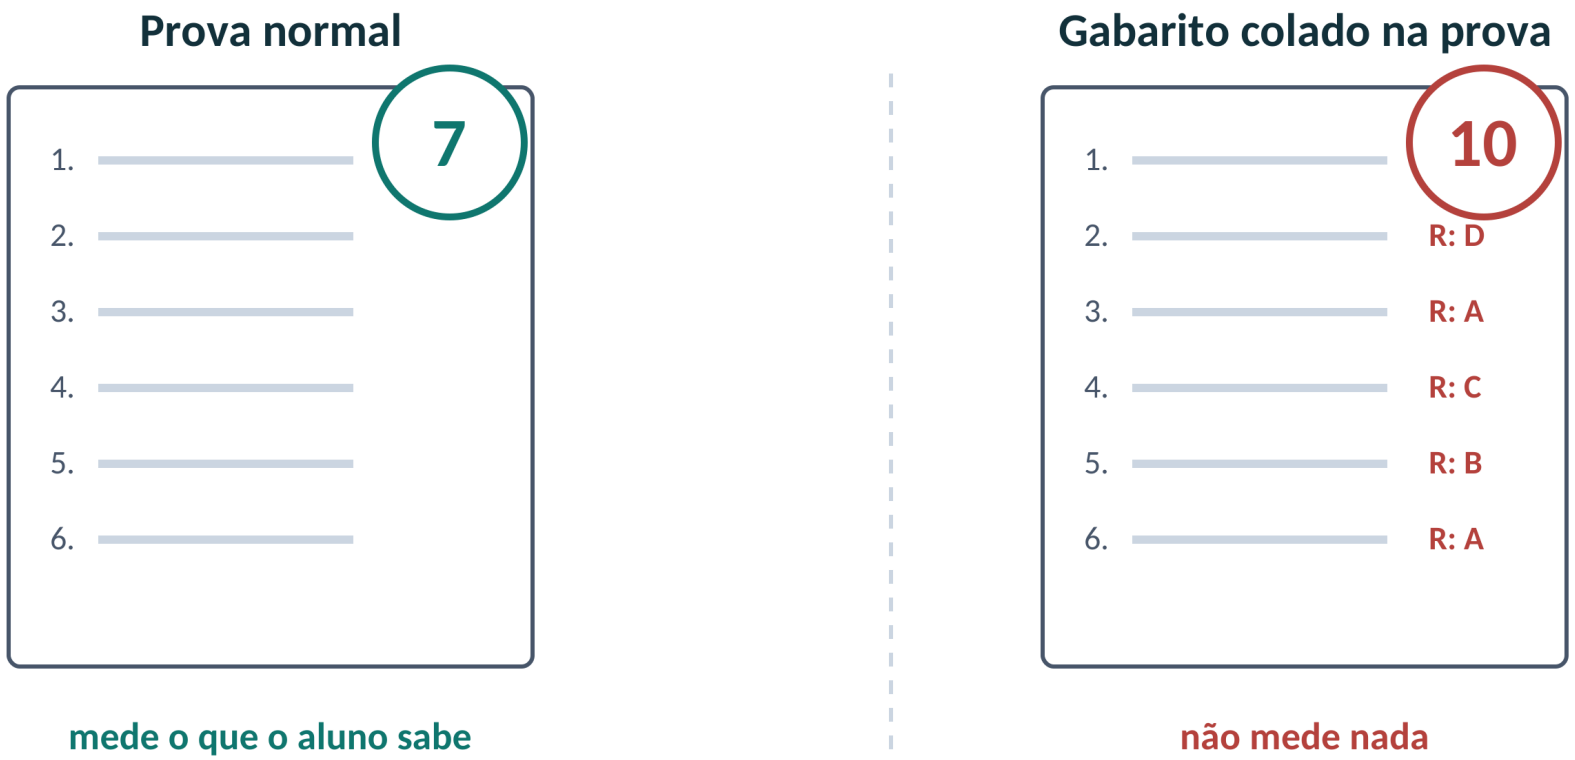
PARTE 1

Target leakage

1

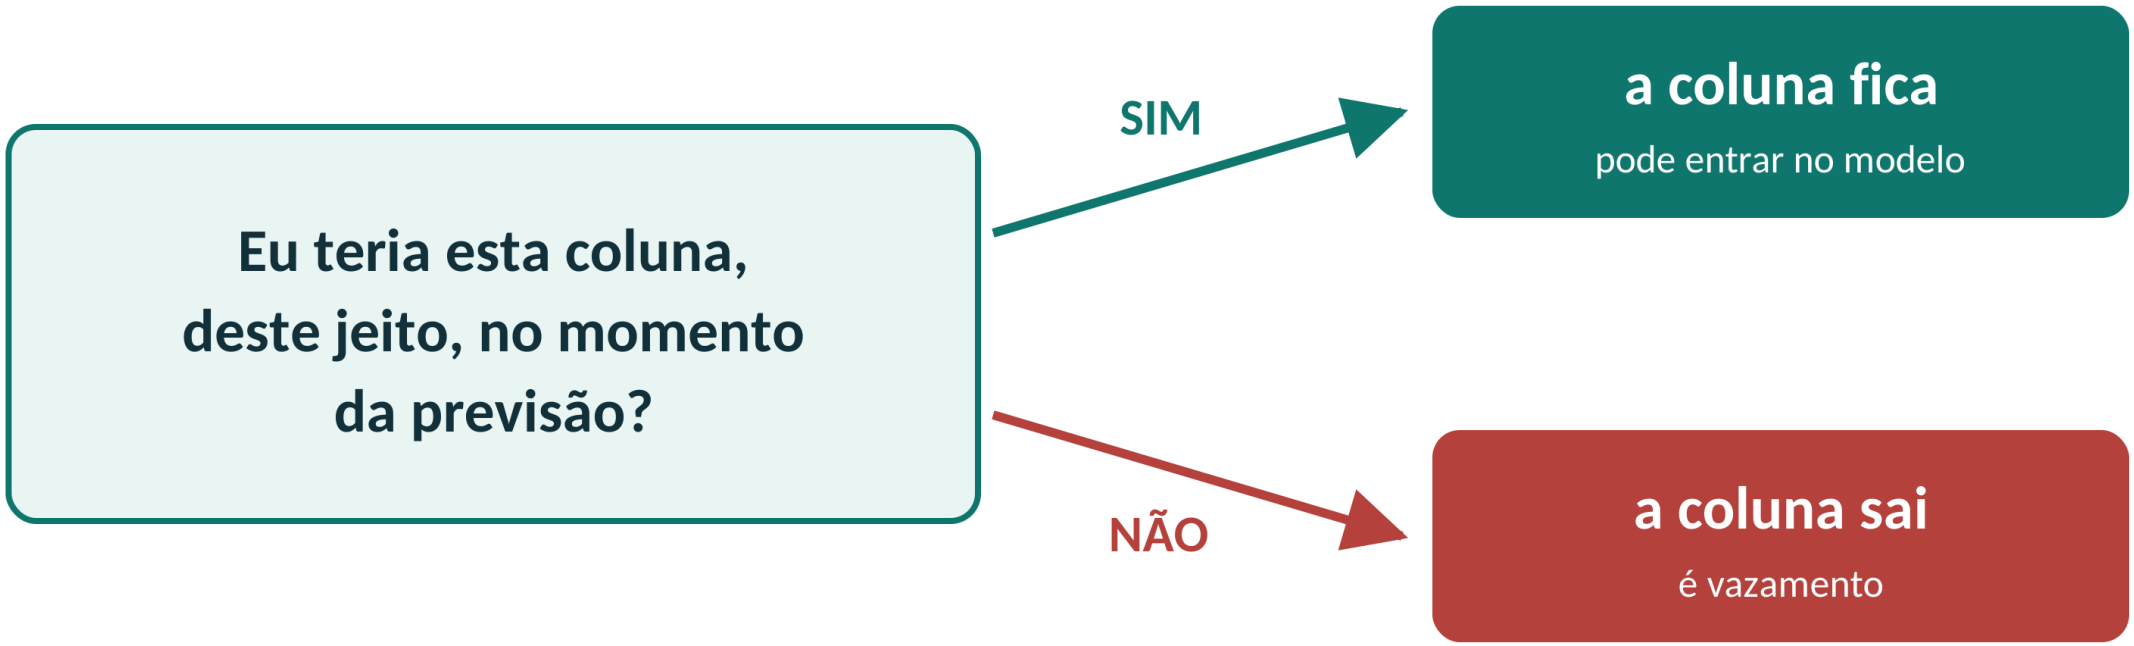
Uma coluna que carrega a resposta.

Vazamento é o gabarito colado na prova



Se a resposta está nos dados, a acurácia alta não mede o modelo.

Uma pergunta decide se a coluna fica



É uma pergunta sobre quando a coluna nasce, não sobre estatística.

Exemplo: prever na semana 6 quem vai reprovar

Alvo: reprovou (sim ou não) · momento da previsão: semana 6

curso	semestre_ingresso	nota_P1	faltas_ate_semana_6	frequentou_monitoria
✓	✓	✓	✓	?
existe desde a matrícula	existe desde a matrícula	saiu na semana 5	medida na semana 6	foi antes ou depois da semana 6?

faltas_no_semestre	nota_P2	fez_substitutiva	media_final	sala_prova_final
✗	✗	✗	✗	✗
mesmo dado, mas só existe no fim	só sai na semana 12	só faz quem foi mal: nasce por causa do alvo	é praticamente o alvo	só é definida no fim do semestre

O mesmo padrão em qualquer área

Saúde

prever infecção



`tomou_antibiótico`

o remédio vem DEPOIS
do diagnóstico

Fraude

prever fraude no cartão



`pediu_estorno`

o estorno vem DEPOIS
da fraude

Crédito

prever calote

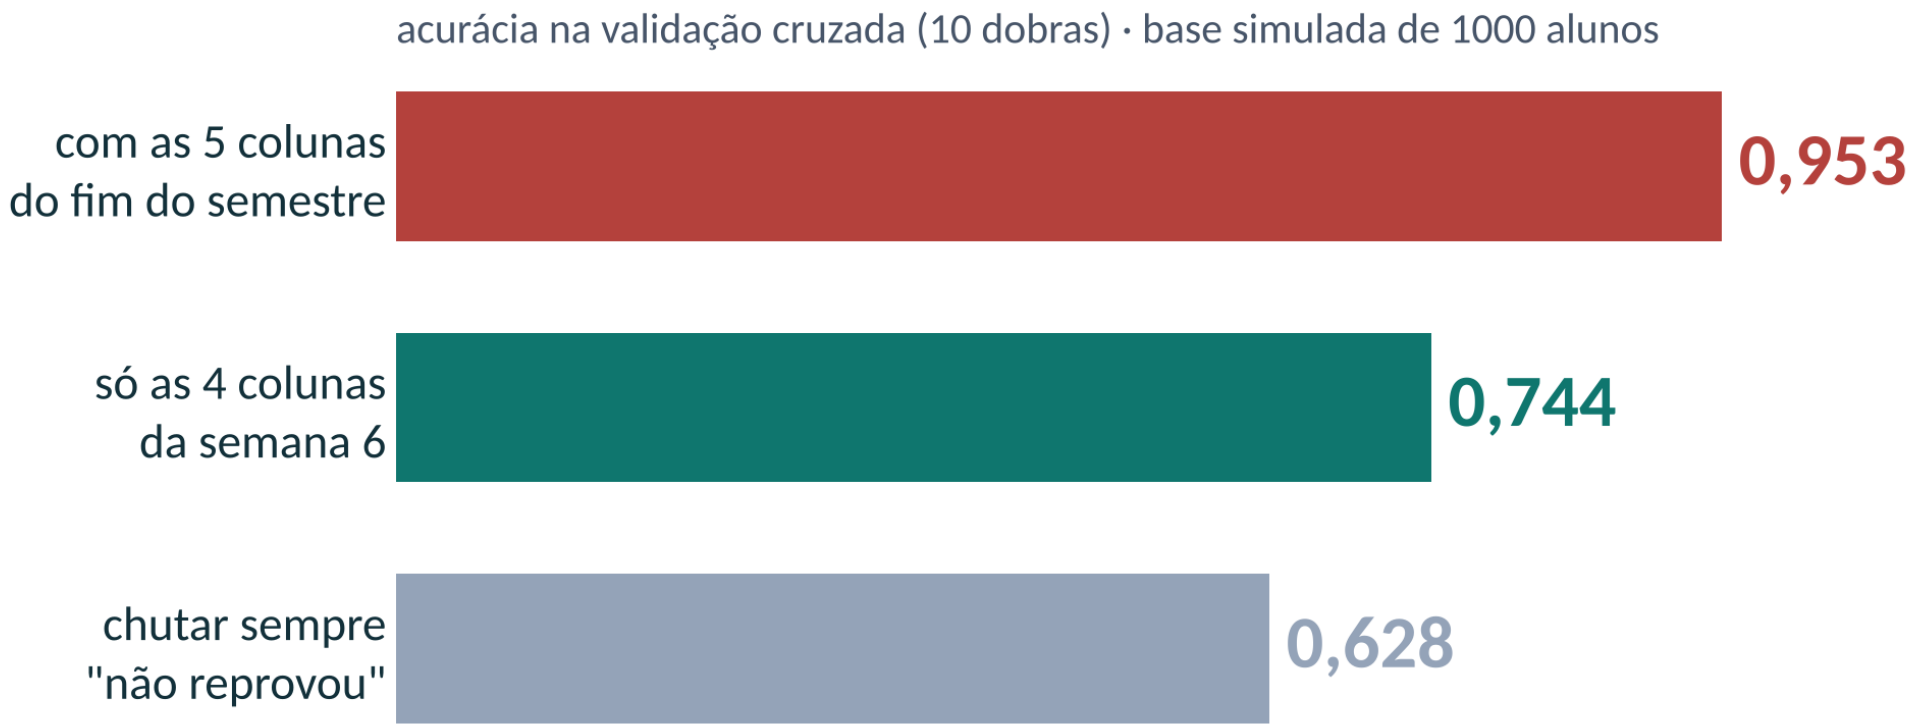


`valor_recuperado`

a cobrança vem DEPOIS
do calote

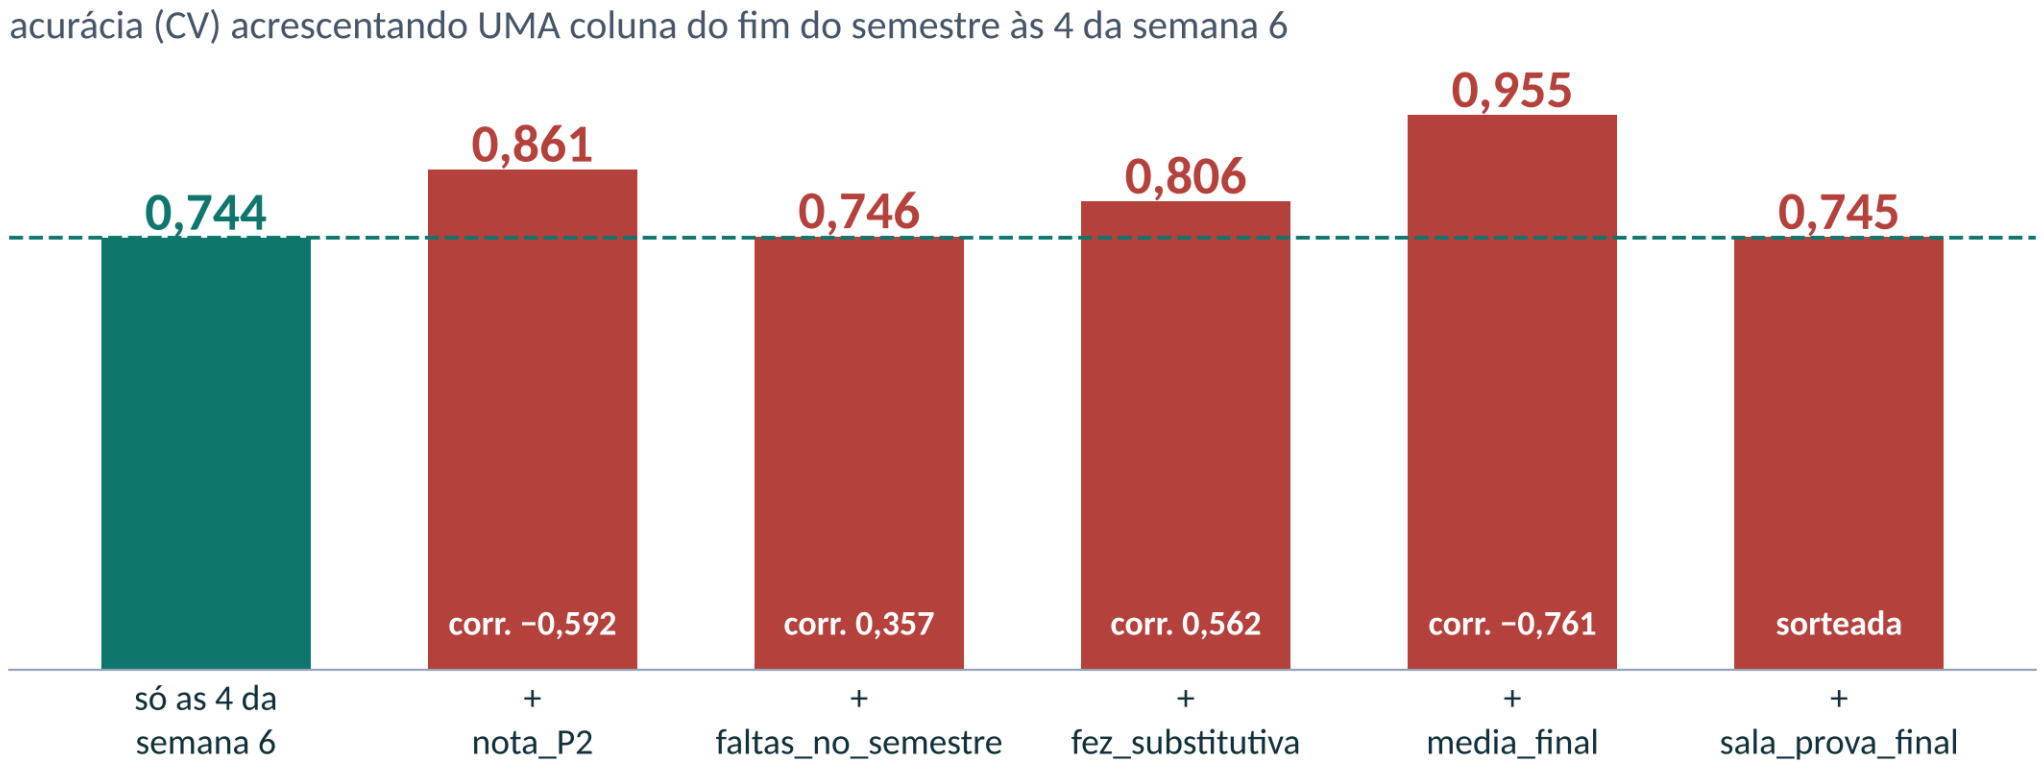
Exemplos: H2O.ai (antibiótico) · IBM (estorno) · Larsen e Becker, 2019 (crédito)

Com as colunas do fim do semestre, o modelo só lê o boletim



0,744 é o número honesto. 0,953 é leitura do boletim. (base simulada de 1000 alunos)

A regra é a origem da coluna, não o quanto ela ajuda



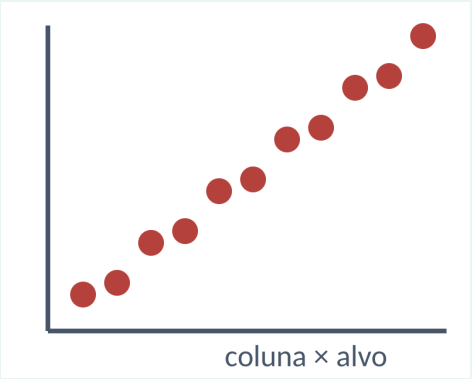
A sala da prova final não muda a acurácia, e mesmo assim sai.

Três sinais de alerta



Bom demais

métrica altíssima logo de primeira



Correlação quase perfeita

uma coluna acompanha o alvo



Nasce depois

a coluna só existe após o evento

Audite as colunas antes de treinar. Na dúvida, remova.

PARTE 2

Vazamento temporal

2

O futuro não pode entrar no treino.

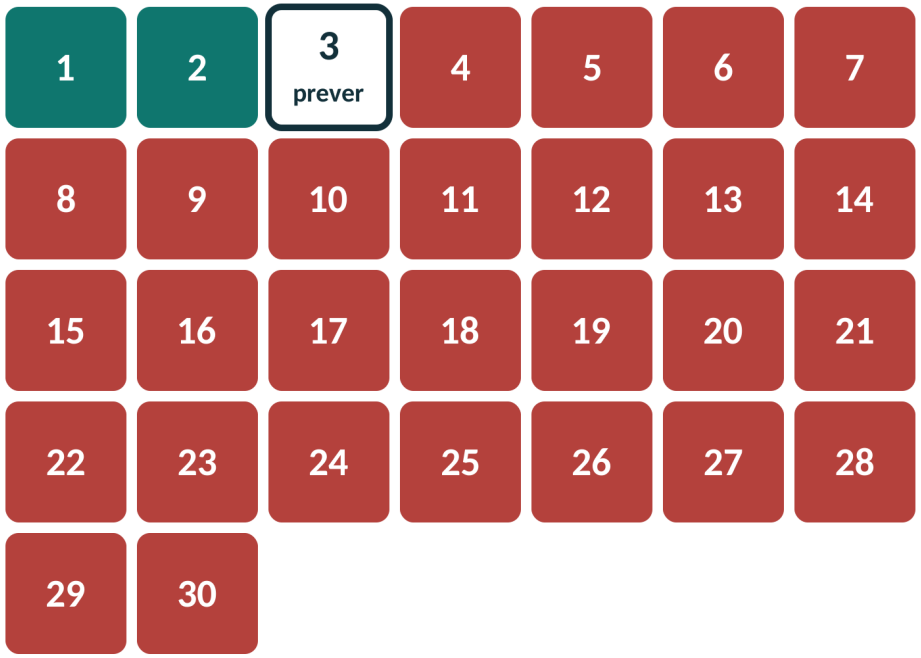
Com data, embaralhar deixa o futuro entrar no treino



Médias e somas também podem olhar o futuro

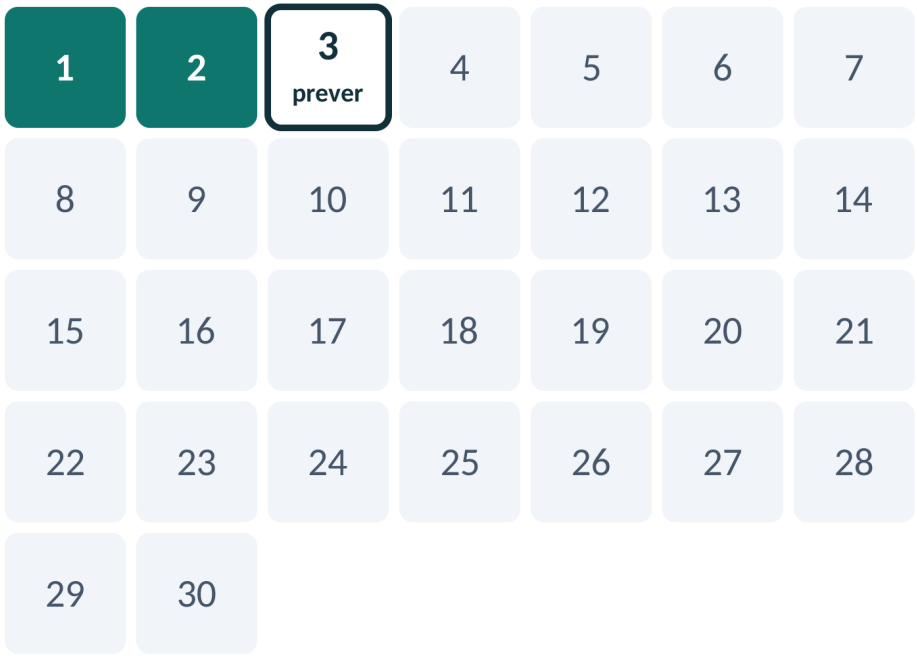
Errado: média do mês inteiro

usa os dias 4 a 30, que ainda não aconteceram



Certo: média até ontem

usa só os dias 1 e 2



Toda feature agregada usa só o que aconteceu antes da previsão.

PARTE 3

Reprodutibilidade

3

O mesmo experimento deve dar o mesmo resultado.

Vazamento só aparece quando alguém consegue refazer o trabalho

294

artigos científicos com vazamento, em 17 áreas

Kapoor e Narayanan, Patterns, 2023

Se o resultado não pode ser refeito, o erro fica escondido.

random_state fixa o sorteio: mesmo split, mesmo número




```
train_test_split(X, y, test_size=0.2, random_state=42)
```

A semente não é um botão para melhorar o resultado. Fixe uma e não mexa.

Quando desconfiar, e o que fazer

Situação	O que fazer
Métrica quase perfeita de primeira	Auditar a origem das colunas
Coluna muito correlacionada com o alvo	Perguntar quando ela nasce
Base com data	Validar para frente (TimeSeriesSplit)
Comparar experimentos	Fixar o random_state
Entregar o modelo	Salvar o Pipeline inteiro + model card

Na dúvida sobre uma coluna: eu teria isto no momento da previsão?

A rotina, em três passos

1

Audite

antes de treinar, pergunte de onde vem cada coluna

2

Remova

na dúvida, a coluna sai

3

Documente

semente fixa, Pipeline salvo, model card

Próxima aula (17/11): seleção de atributos — quais colunas entram, de propósito.